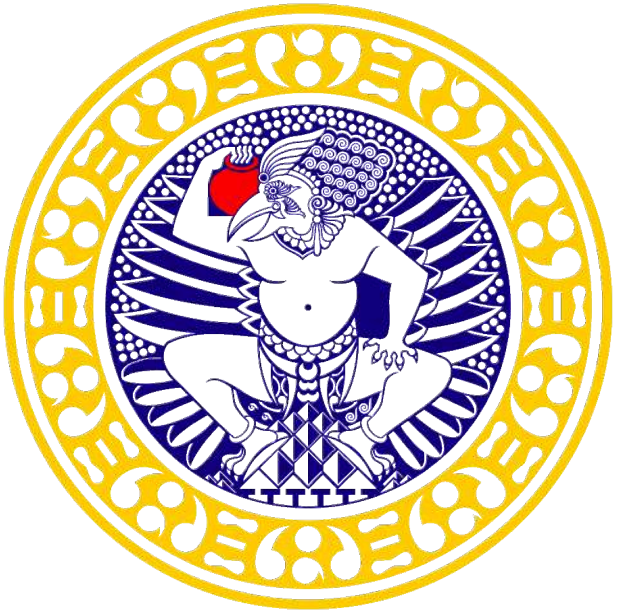
LAPORAN
PRAKTIKUM PEMBELAJARAN MESIN
CLUSTERING



Dosen Pengampu :
Barry Nuqoba, S.Si., M.Kom., Ph.D

Disusun Oleh :

MELLINDA IMPIAWATI DWINORI	434231032
OCTAVIA NUZULUL AZMI	434241040
GLENNOVIAN BENHUR UNITED L.	434241044

PROGRAM STUDI D4 TEKNIK INFORMATIKA
FAKULTAS VOKASI
UNIVERSITAS AIRLANGGA SURABAYA

TAHUN AJARAN 2026/2027

Daftar Isi

BAB I 3
PENDAHULUAN 3
1.1 Latar Belakang 3
1.2 Rumusan Masalah 3
1.3 Tujuan Penelitian 4
1.4 Manfaat Penelitian 4
1.5 Batasan Masalah 4
BAB II
METODOLOGI PENELITIAN 5
2.1 Alur Penelitian 5
2.2 Dataset Penelitian 5
2.2.1 Dataset Mall Customers 5
2.2.2 Dataset Marketing Campaign 6
2.3 Pembagian Metode Clustering 7
2.4 Tahapan Preprocessing Data 7
2.5 Penerapan Metode Clustering 9
2.5.1 K-Modes 9
2.5.2 Fuzzy C-Means 10
2.5.3 DBSCAN 11
BAB III 12
HASIL DAN PEMBAHASAN 12
3.1 Hasil Clustering Fuzzy C-Means pada Dataset Mall Customers 12
3.1.1 Hasil Evaluasi Clustering 12
3.1.2 Visualisasi Hasil Clustering 13
3.1.3 Karakteristik Setiap Cluster 13
3.2 Hasil Clustering Fuzzy C-Means pada Dataset Marketing Campaign 14
3.2.1 Hasil Evaluasi Clustering 14
3.2.2 Visualisasi Hasil Clustering 15
3.2.3 Karakteristik Setiap Cluster 16
3.3 Hasil Clustering K-Modes pada Dataset Mall Customers 17
3.3.1 Hasil Evaluasi Clustering 17
3.3.2 Visualisasi Hasil Clustering 18
3.3.3 Karakteristik Setiap Cluster 20
3.4 Hasil Clustering K-Modes pada Dataset Marketing Campaign 20
3.4.1 Hasil Evaluasi Clustering 21
3.4.2 Visualisasi Hasil Clustering 22
3.4.3 Karakteristik Setiap Cluster 23
3.5 Hasil Clustering DBSCAN pada Dataset Mall Customers 25
3.5.1 Hasil Evaluasi Clustering 25
3.5.2 Visualisasi Hasil Clustering 26

3.5.3 Karakteristik Setiap Cluster 27
3.6 Hasil Clustering DBSCAN pada Dataset Marketing Campaign 28
3.6.1 Hasil Evaluasi Clustering 28
3.6.2 Visualisasi Hasil Clustering 29
3.6.3 Karakteristik Setiap Cluster 31
3.7 Analisis Perbandingan Kinerja Metode Clustering terhadap K-Means 31

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi menyebabkan jumlah data yang dihasilkan dan dikumpulkan semakin meningkat. Data tersebut dapat dimanfaatkan untuk memperoleh informasi yang berguna dalam mendukung proses pengambilan keputusan. Salah satu teknik pengolahan data yang dapat digunakan untuk menemukan pola atau karakteristik tertentu adalah data mining.

Salah satu teknik dalam data mining adalah clustering atau pengelompokan data. Clustering merupakan proses mengelompokkan sejumlah objek berdasarkan kemiripan karakteristik sehingga objek yang memiliki karakteristik serupa dapat berada dalam kelompok yang sama. Teknik ini dapat digunakan untuk berbagai kebutuhan, salah satunya adalah segmentasi pelanggan berdasarkan karakteristik dan perilaku mereka.

Dalam penelitian ini, dilakukan implementasi beberapa metode clustering, yaitu K-Modes, Fuzzy C-Means, dan DBSCAN. Ketiga metode tersebut memiliki pendekatan yang berbeda dalam membentuk kelompok data. K-Modes digunakan untuk mengelompokkan data kategorikal, Fuzzy C-Means memungkinkan suatu objek memiliki derajat keanggotaan pada beberapa cluster, sedangkan DBSCAN membentuk cluster berdasarkan kepadatan data dan dapat mengidentifikasi data yang dianggap sebagai noise.

Dataset yang digunakan dalam penelitian ini terdiri dari Mall Customers dan Marketing Campaign. Dataset Mall Customers berisi informasi pelanggan seperti usia, jenis kelamin, pendapatan tahunan, dan skor pengeluaran. Sementara itu, dataset Marketing Campaign memuat informasi pelanggan yang berkaitan dengan pendapatan, riwayat pembelian produk, serta aktivitas transaksi dan kampanye pemasaran.

Sebelum proses clustering dilakukan, data melalui tahap preprocessing yang meliputi pemilihan fitur, penanganan missing value, serta penyesuaian data sesuai kebutuhan masing-masing metode. Selanjutnya, setiap metode diterapkan dan dievaluasi menggunakan metrik yang sesuai untuk mengetahui karakteristik serta kualitas hasil pengelompokan.

Melalui penelitian ini, diharapkan dapat diketahui bagaimana penerapan metode K-Modes, Fuzzy C-Means, dan DBSCAN pada kedua dataset, serta bagaimana perbedaan hasil pengelompokan yang dihasilkan oleh masing-masing metode. Hasil penelitian juga diharapkan dapat memberikan gambaran mengenai karakteristik kelompok pelanggan berdasarkan data yang dianalisis.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana proses preprocessing pada dataset Mall Customers dan Marketing Campaign sebelum dilakukan clustering?
2. Bagaimana penerapan metode K-Modes, Fuzzy C-Means, dan DBSCAN pada kedua dataset?
3. Bagaimana hasil pengelompokan pelanggan yang dihasilkan oleh masing-masing metode?

4. Bagaimana kualitas hasil clustering berdasarkan metrik evaluasi yang digunakan?
5. Apa perbedaan karakteristik hasil pengelompokan dari metode K-Modes, Fuzzy C-Means, dan DBSCAN?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Melakukan proses *preprocessing* data pada *dataset Mall Customers* dan *Marketing Campaign* sebagai tahapan penyiapan data sebelum dilakukan proses *clustering*.
2. Mengimplementasikan metode K-Modes, Fuzzy C-Means (FCM), dan DBSCAN untuk mengelompokkan data pada kedua *dataset* tersebut.
3. Menganalisis hasil pengelompokan pelanggan (*customer segmentation*) yang terbentuk dari masing-masing metode algoritma.
4. Menguji dan mengevaluasi kualitas hasil *clustering* berdasarkan metrik evaluasi yang relevan (seperti *Silhouette Score*, *Davies-Bouldin Index*, atau *Purity*).
5. Membandingkan perbedaan karakteristik dan performa hasil pengelompokan antara metode K-Modes, Fuzzy C-Means, dan DBSCAN dalam menangani tipe data pada kedua *dataset*.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Manfaat akademis: Menambah pemahaman mengenai penerapan berbagai metode clustering dalam proses analisis data.
2. Manfaat praktis: Memberikan gambaran mengenai segmentasi pelanggan berdasarkan karakteristik dan perilaku pembelian.
3. Manfaat teknis: Memberikan pengalaman dalam melakukan preprocessing, implementasi algoritma clustering, visualisasi, serta evaluasi hasil pengelompokan menggunakan Python.

1.5 Batasan Masalah

Agar pembahasan penelitian lebih terarah, batasan masalah yang digunakan adalah:

1. Penelitian menggunakan dua dataset, yaitu Mall Customers dan Marketing Campaign.
2. Metode clustering yang dibahas adalah K-Modes, Fuzzy C-Means, dan DBSCAN.
3. Proses pengolahan dan implementasi dilakukan menggunakan bahasa pemrograman Python.
4. Tahap preprocessing disesuaikan dengan karakteristik dataset dan kebutuhan setiap algoritma.
5. Evaluasi hasil clustering menggunakan metrik yang sesuai dengan metode yang diterapkan.
6. Pembahasan difokuskan pada proses pengelompokan, hasil evaluasi, visualisasi, dan interpretasi karakteristik cluster.

BAB II
METODOLOGI PENELITIAN

2.1 Alur Penelitian

Penelitian ini dilakukan melalui beberapa tahapan, mulai dari persiapan dataset, pemeriksaan dan preprocessing data, penerapan metode clustering, hingga evaluasi dan analisis hasil pengelompokan.

Penelitian menggunakan dua dataset, yaitu Mall Customers dan Marketing Campaign. Kedua dataset tersebut diolah menggunakan tiga metode clustering, yaitu K-Modes, Fuzzy C-Means, dan DBSCAN. Secara umum, tahapan penelitian meliputi:

1. Mengumpulkan dan mempersiapkan dataset.
2. Memeriksa struktur dan karakteristik data.
3. Melakukan preprocessing sesuai kebutuhan masing-masing metode.
4. Menerapkan metode K-Modes, Fuzzy C-Means, dan DBSCAN.
5. Melakukan evaluasi terhadap hasil clustering.
6. Membandingkan dan menganalisis hasil pengelompokan.

2.2 Dataset Penelitian

Penelitian ini menggunakan dua dataset sebagai objek penerapan metode clustering, yaitu Mall Customers dan Marketing Campaign. Kedua dataset memiliki karakteristik dan atribut yang berbeda sehingga dapat digunakan untuk menganalisis pola pengelompokan pelanggan.

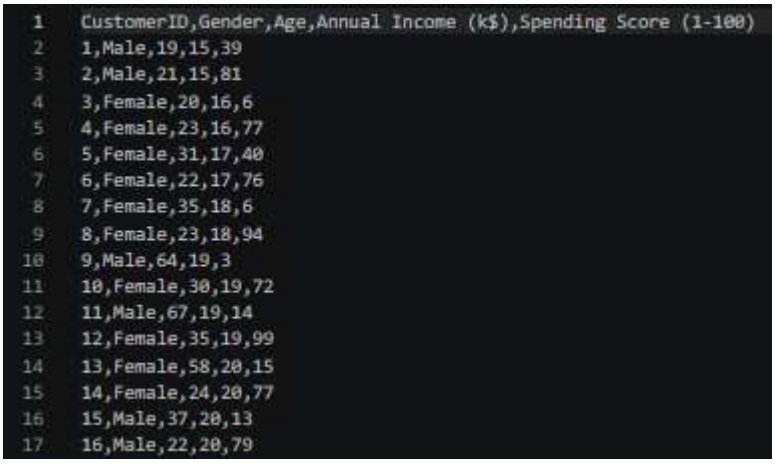
2.2.1 Dataset Mall Customers

Dataset Mall Customers berisi informasi mengenai pelanggan pusat perbelanjaan. Dataset ini digunakan untuk mengelompokkan pelanggan berdasarkan karakteristik pendapatan tahunan dan perilaku pengeluaran.

Pada penerapan Fuzzy C-Means, atribut yang digunakan adalah Annual Income (k$) dan Spending Score (1-100). Kedua atribut tersebut digunakan untuk melihat pola kelompok pelanggan berdasarkan tingkat pendapatan dan skor pengeluaran.

Pada penerapan K-Modes, atribut yang digunakan adalah Gender, Age, Annual Income (k$), dan Spending Score (1-100). Atribut CustomerID tidak digunakan karena hanya berfungsi sebagai pengenal pelanggan. Karena K-Modes bekerja pada data kategorikal, atribut numerik dikelompokkan menjadi kategori terlebih dahulu. Age dibagi menjadi empat kelompok (Muda ≤25, Dewasa Muda 26-35, Dewasa 36-50, dan Senior >50), Annual Income menjadi tiga tingkat (Rendah <40k, Sedang 40-70k, dan Tinggi >70k), dan Spending Score menjadi tiga tingkat (Rendah 1-33, Sedang 34-66, dan Tinggi 67-100).

Pada penerapan DBSCAN, atribut yang digunakan sama dengan Fuzzy C-Means, yaitu Annual Income (k$) dan Spending Score (1-100). Penggunaan fitur numerik yang sama bertujuan agar hasil pengelompokan serta nilai evaluasi antara metode berbasis kepadatan (DBSCAN), Fuzzy C-Means, dan K-Means dapat dibandingkan secara langsung.



```
CustomerID,Gender,Age,Annual Income (k$),Spending Score (1-100)
1,Male,19,15,39
2,Male,21,15,81
3,Female,20,16,6
4,Female,23,16,77
5,Female,31,17,40
6,Female,22,17,76
7,Female,35,18,6
8,Female,23,18,94
9,Male,64,19,3
10,Female,30,19,72
11,Male,67,19,14
12,Female,35,19,99
13,Female,58,20,15
14,Female,24,20,77
15,Male,37,20,13
16,Male,22,20,79
```

Gambar 2.1 Dataset Mall Customers.

2.2.2 Dataset Marketing Campaign

Dataset Marketing Campaign berisi informasi pelanggan dan aktivitas pembelian dalam suatu kampanye pemasaran. Dataset ini digunakan untuk menganalisis karakteristik pelanggan berdasarkan pendapatan, riwayat pembelian produk, dan aktivitas transaksi.

Pada penerapan Fuzzy C-Means, digunakan beberapa atribut numerik, seperti Income, Recency, jumlah pembelian berbagai kategori produk, jumlah pembelian melalui beberapa saluran, dan jumlah kunjungan ke situs web per bulan.

Pada penerapan K-Modes, atribut yang digunakan bersifat kategorikal, yaitu Education, Marital_Status, Kidhome, Teenhome, kelompok usia (diturunkan dari Year_Birth), tingkat pendapatan (diturunkan dari Income), jumlah kampanye yang diterima (diturunkan dari AcceptedCmp1 sampai AcceptedCmp5), dan Response. Atribut ID tidak digunakan sebagai fitur clustering. Kelompok usia dihitung dari tahun 2014 dan dibagi menjadi ≤35, 36-50, 51-65, dan >65 tahun. Income dibagi menjadi tiga tingkat (Rendah, Sedang, Tinggi) dengan batas tertil, dan jumlah kampanye yang diterima dikelompokkan menjadi 0, 1, dan 2+.

Pada penerapan DBSCAN, digunakan 13 atribut numerik yang sama dengan Fuzzy C-Means, yaitu Income, Recency, enam atribut jumlah pembelian kategori produk (MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds), empat atribut saluran pembelian (NumDealsPurchases, NumWebPurchases, NumCatalogPurchases, NumStorePurchases), serta NumWebVisitsMonth.

ID	Year_Birth	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Customer	Recency	MntWines	MntFruits	MntMeatProducts	MntFishProducts	MntSweetProducts
5524	1957	Graduation	Single	58138	0	0	04-09-2012	58	635	88	546	172	88	88	3	8	10	4	7	0	0	0	0	0	0	3	11	1
2174	1954	Graduation	Single	46344	1	1	08-03-2014	38	11	1	6	2	1	6	2	1	1	2	5	0	0	0	0	0	0	3	11	0
4141	1965	Graduation	Together	71613	0	0	21-08-2013	26	426	49	127	111	21	42	1	8	2	10	4	0	0	0	0	0	0	3	11	0
6182	1984	Graduation	Together	26646	1	0	10-02-2014	26	11	4	20	10	3	5	2	2	0	4	6	0	0	0	0	0	0	3	11	0
5324	1981	PhD	Married	58293	1	0	19-01-2014	94	173	43	118	46	27	15	5	5	3	6	5	0	0	0	0	0	0	3	11	0
7446	1967	Master	Together	62513	0	1	09-09-2013	16	520	42	98	0	42	14	2	6	4	10	6	0	0	0	0	0	0	3	11	0
965	1971	Graduation	Divorced	55635	0	1	13-11-2012	34	235	65	164	50	49	27	4	7	3	7	6	0	0	0	0	0	0	3	11	0
6177	1985	PhD	Married	33454	1	0	08-05-2013	32	76	10	56	3	1	23	2	4	0	4	8	0	0	0	0	0	0	3	11	0
4855	1974	PhD	Together	30351	1	0	06-06-2013	19	14	0	24	3	3	2	1	3	0	2	9	0	0	0	0	0	0	3	11	1
5899	1950	PhD	Together	5648	1	1	13-03-2014	68	28	0	6	1	1	13	1	1	0	0	20	1	0	0	0	0	0	3	11	0
1994	1983	Graduation	Married	1	0	0	15-11-2013	11	5	5	6	0	2	1	1	1	0	2	7	0	0	0	0	0	0	3	11	0
387	1976	Basic	Married	7500	0	0	13-11-2012	59	6	16	11	11	1	16	1	2	0	3	8	0	0	0	0	0	0	3	11	0
2125	1959	Graduation	Divorced	63033	0	0	15-11-2013	82	194	61	480	225	112	30	1	3	4	8	2	0	0	0	0	0	0	3	11	0
8180	1952	Master	Divorced	59354	1	1	15-11-2013	53	233	2	53	3	5	14	3	6	1	5	6	0	0	0	0	0	0	3	11	0
2569	1987	Graduation	Married	17323	0	0	10-10-2012	38	3	14	17	6	1	5	1	1	0	3	8	0	0	0	0	0	0	3	11	0
2114	1946	PhD	Single	82800	0	0	24-11-2012	23	1006	22	115	59	68	45	1	7	6	12	3	0	0	1	1	0	0	3	11	1
9736	1980	Graduation	Married	41850	1	1	24-12-2012	51	53	5	19	2	13	4	3	3	0	3	8	0	0	0	0	0	0	3	11	0
4939	1946	Graduation	Together	37760	0	0	31-08-2012	20	84	5	38	150	12	28	2	4	1	6	7	0	0	0	0	0	0	0	3	11	0
6565	1949	Master	Married	76995	0	1	28-03-2013	91	1012	80	498	0	16	176	2	11	4	9	5	0	0	0	1	0	0	3	11	0
2278	1985	2n Cycle	Single	33812	1	0	03-11-2012	86	4	17	19	30	24	39	2	2	1	3	6	0	0	0	0	0	0	3	11	0
9360	1982	Graduation	Married	37040	0	0	08-08-2012	41	86	2	73	69	38	48	1	4	2	5	8	0	0	0	0	0	0	3	11	0

Gambar 2.2 Dataset Marketing Campaign.

2.3 Pembagian Metode Clustering

Pada penelitian ini, digunakan tiga metode clustering, yaitu K-Modes, Fuzzy C-Means, dan DBSCAN. Ketiga metode tersebut diterapkan pada dua dataset, yaitu Mall Customers dan Marketing Campaign. Penerapan ketiga metode pada masing-masing dataset menghasilkan enam program yang dikerjakan secara terpisah. Pembagian program dalam penelitian ini adalah sebagai berikut:

No.	Nama Program	Metode	Dataset
1	01_kmodes_mall_customers.py	K-Modes	Mall Customers
2	02_fuzzy_cmeans_mall_customers.py	Fuzzy C-Means	Mall Customers
3	03_dbscan_mall_customers.py	DBSCAN	Mall Customers
4	04_kmodes_marketing_campaign.py	K-Modes	Marketing Campaign
5	05_fuzzy_cmeans_marketing_campaign.py	Fuzzy C-Means	Marketing Campaign
6	06_dbscan_marketing_campaign.py	DBSCAN	Marketing Campaign

Tabel 2.1 Pembagian Metode Clustering

Pembagian pengerjaan dilakukan berdasarkan metode yang menjadi tanggung jawab setiap anggota kelompok. Dengan pembagian tersebut, setiap metode dapat diterapkan dan dievaluasi pada kedua dataset.

2.4 Tahapan Preprocessing Data

Preprocessing data merupakan tahap persiapan data sebelum dilakukan proses clustering. Tahap ini bertujuan untuk memastikan data berada dalam kondisi yang sesuai sehingga dapat diproses oleh algoritma clustering.

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(data)

# Fuzzy C-Means membutuhkan format fitur x sampel
X_fcm = X_scaled.T
```

Gambar 2.3 Preprocessing Mall Customers.

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(data_clean)
```

Gambar 2.4 Preprocessing Marketing Campaign.

Pada K-Modes, data tidak distandardisasi karena seluruh atribut berbentuk kategori. Persiapan data berupa kategorisasi atribut numerik pada kedua dataset. Pada dataset Marketing Campaign, atribut Income memiliki 24 nilai kosong. Nilai tersebut diisi dengan modus, yaitu kategori yang paling sering muncul, setelah Income dikategorikan. Kategori Marital_Status yang jarang muncul digabungkan: Alone, Absurd, dan YOLO menjadi Single, sedangkan Together dan Married menjadi Partner.

Pada DBSCAN, tahapan preprocessing dimulai dengan konversi tipe data numerik dan penanganan nilai tak hingga (infinite) atau kosong menggunakan nilai median (median imputation), khususnya pada 24 nilai kosong di atribut Income pada dataset Marketing Campaign. Selanjutnya, seluruh fitur numerik pada kedua dataset distandardisasi menggunakan StandardScaler karena DBSCAN mengandalkan perhitungan jarak Euclidean dalam menentukan kepadatan lokal, sehingga perbedaan rentang satuan antaratribut harus disamakan terlebih dahulu.

```
data_cat = pd.DataFrame(index=df.index)
data_cat["Gender"] = df["Gender"].astype(str)

data_cat["Age_Group"] = pd.cut(
    df["Age"],
    bins=[0, 25, 35, 50, 200],
    labels=["Muda (<=25)", "Dewasa Muda (26-35)", "Dewasa (36-50)", "Senior (>50)"],
).astype(str)

data_cat["Income_Level"] = pd.cut(
    df["Annual Income (k$)"],
    bins=[0, 39, 70, 1000],
    labels=["Rendah (<40k)", "Sedang (40-70k)", "Tinggi (>70k)"],
).astype(str)

data_cat["Spending_Level"] = pd.cut(
    df["Spending Score (1-100)"],
    bins=[0, 33, 66, 100],
    labels=["Rendah (1-33)", "Sedang (34-66)", "Tinggi (67-100)"],
).astype(str)

FEATURES = list(data_cat.columns)
```

Gambar 2.5 Kategorisasi Atribut Mall Customers untuk K-Modes.

```
data_cat["Education"] = df["Education"].astype(str)
data_cat["Marital_Status"] = (
    df["Marital_Status"]
    .replace({"Alone": "Single", "Absurd": "Single", "YOLO": "Single",
              "Together": "Partner", "Married": "Partner"})
    .astype(str)
)

data_cat["Kidhome"] = df["Kidhome"].astype(str)
data_cat["Teenhome"] = df["Teenhome"].astype(str)

REF_YEAR = 2014
usia = REF_YEAR - df["Year_Birth"]
data_cat["Age_Group"] = pd.cut(
    usia,
    bins=[0, 35, 50, 65, 200],
    labels=["<=35", "36-50", "51-65", ">65"],
).astype(str)

income_level = pd.qcut(df["Income"], q=3, labels=["Rendah", "Sedang", "Tinggi"])
data_cat["Income_Level"] = income_level.astype(object)

campaign_cols = ["AcceptedCmp1", "AcceptedCmp2", "AcceptedCmp3",
                 "AcceptedCmp4", "AcceptedCmp5"]
n_acc = df[campaign_cols].sum(axis=1)
data_cat["Campaign_Accepted"] = n_acc.clip(upper=2).map(
    {0: "0", 1: "1", 2: "2+"}
)
data_cat["Response"] = df["Response"].astype(str)
```

Gambar 2.6 Kategorisasi dan Penanganan Missing Value Marketing Campaign untuk K-Modes.

Tahapan preprocessing dalam penelitian ini disesuaikan dengan karakteristik masing-masing dataset dan kebutuhan metode yang digunakan. Secara umum, tahapan yang dilakukan meliputi:

1. Pemeriksaan Data
   Memeriksa jumlah baris dan kolom, tipe data, serta keberadaan nilai kosong (missing values) pada dataset.
2. Penanganan Missing Values
   Menangani nilai kosong agar tidak mengganggu proses pengolahan data. Teknik penanganan disesuaikan dengan jenis data dan implementasi masing-masing metode.
3. Pemilihan Fitur
   Memilih atribut yang relevan dengan tujuan pengelompokan pelanggan.
4. Transformasi Data
   Melakukan transformasi data apabila diperlukan, seperti normalisasi atau standardisasi fitur numerik agar perbedaan skala antaratribut tidak terlalu memengaruhi proses clustering.
5. Persiapan Data Berdasarkan Metode
   Menyesuaikan format data dengan kebutuhan algoritma K-Modes, Fuzzy C-Means, dan DBSCAN.

Dengan tahapan tersebut, data diharapkan siap digunakan untuk proses clustering dan evaluasi hasil pengelompokan.

2.5 Penerapan Metode Clustering

Setelah tahap preprocessing selesai, proses selanjutnya adalah menerapkan metode clustering pada kedua dataset. Penelitian ini menggunakan tiga algoritma, yaitu K-Modes, Fuzzy C-Means, dan DBSCAN. Setiap algoritma memiliki cara kerja dan karakteristik yang berbeda dalam mengelompokkan data.

2.5.1 K-Modes

K-Modes merupakan metode clustering yang digunakan untuk mengelompokkan data kategorikal. Metode ini menentukan kelompok berdasarkan kesamaan kategori pada atribut data.

Pada penelitian ini, K-Modes diterapkan pada dataset Mall Customers dan Marketing Campaign. Proses pengelompokan dilakukan menggunakan atribut yang telah disiapkan sesuai kebutuhan metode.

```
cost_rows = []
for k in K_RANGE:
    km = KModes(
        n_clusters=k,
        init=INIT_METHOD,
        n_init=N_INIT,
        random_state=RANDOM_STATE,
    )
    km.fit(X)
    cost_rows.append({"k": k, "cost": km.cost_})
    print(f"k = {k:2d} | cost = {km.cost_:.0f}")

cost_df = pd.DataFrame(cost_rows)
cost_df["penurunan_cost"] = -cost_df["cost"].diff()
cost_df.to_csv(OUT_DIR / "kmodes_cost.csv", index=False)
```

Gambar 2.5 Implementasi Metode K-Modes.

2.5.2 Fuzzy C-Means

Fuzzy C-Means (FCM) merupakan metode clustering yang digunakan untuk mengelompokkan data berdasarkan derajat keanggotaan. Dalam penelitian ini, metode Fuzzy C-Means diterapkan pada dua dataset, yaitu Mall Customers dan Marketing Campaign.

Pada dataset Mall Customers, atribut yang digunakan adalah Annual Income (k$) dan Spending Score (1-100). Sebelum proses clustering dilakukan, data distandardisasi menggunakan StandardScaler agar setiap fitur memiliki skala yang sebanding.

```
cntr, u, u0, d, jm, p, fpc = fuzz.cluster.cmeans(
    data=X_fcm,
    c=k,
    m=FUZZINESS,
    error=0.005,
    maxiter=1000,
    init=None,
    seed=RANDOM_STATE
)

labels = np.argmax(u, axis=0)

silhouette = silhouette_score(X_scaled, labels)
dbi = davies_bouldin_score(X_scaled, labels)
ch_score = calinski_harabasz_score(X_scaled, labels)

evaluation_results.append({
    "Jumlah Cluster": k,
    "FPC": fpc,
    "Silhouette Score": silhouette,
    "Davies-Bouldin Index": dbi,
    "Calinski-Harabasz Score": ch_score,
    "Objective Function": jm[-1]
})
```

Gambar 2.6 Implementasi Algoritma Fuzzy C-Means pada Dataset Mall Customers.

Pada dataset Marketing Campaign, atribut yang digunakan meliputi Income, Recency, berbagai kategori pembelian produk, jumlah transaksi berdasarkan saluran pembelian, dan jumlah kunjungan ke situs web. Nilai kosong pada atribut Income ditangani menggunakan median sebelum data distandarisasi.

```
cntr, u, u0, d, jm, p, fpc = fuzz.cluster.cmeans(
    data=X,
    c=k,
    m=2,
    error=0.005,
    maxiter=1000,
    init=None,
    seed=42
)

labels = np.argmax(u, axis=0)

sil = silhouette_score(X_scaled, labels)
dbi = davies_bouldin_score(X_scaled, labels)
ch = calinski_harabasz_score(X_scaled, labels)
```

Gambar 2.7 Implementasi Algoritma Fuzzy C-Means pada Dataset Marketing Campaign.

Proses clustering dilakukan menggunakan library Scikit-Fuzzy dengan parameter fuzziness sebesar 2. Pengujian dilakukan menggunakan beberapa variasi jumlah cluster untuk memperoleh hasil pengelompokan yang sesuai.

Hasil clustering kemudian dievaluasi menggunakan beberapa metrik, yaitu Fuzzy Partition Coefficient (FPC), Silhouette Score, Davies-Bouldin Index (DBI), dan Calinski-Harabasz Index (CH).

2.5.3 DBSCAN

DBSCAN merupakan metode clustering berbasis kepadatan data. Metode ini mengelompokkan data berdasarkan kedekatan dan kepadatan titik data serta dapat mengidentifikasi data yang tidak termasuk dalam kelompok sebagai noise.

Pada penelitian ini, DBSCAN diterapkan pada dataset Mall Customers dan Marketing Campaign untuk mengetahui pola pengelompokan berdasarkan kepadatan data.

Algoritma DBSCAN (Density-Based Spatial Clustering of Applications with Noise) bekerja menggunakan dua parameter utama, yaitu epsilon (eps) yang menentukan radius jarak ketetanggaan maksimum dari suatu titik, serta min_samples yang menentukan jumlah titik minimum di dalam radius eps agar suatu titik dapat dikategorikan sebagai titik inti (core point). Titik yang berada dalam jangkauan eps dari core point tetapi tidak memiliki cukup tetangga disebut border point, sedangkan titik yang tidak termasuk dalam jangkauan cluster mana pun diidentifikasi sebagai noise (diberi label -1).

Penentuan nilai awal eps dibantu menggunakan grafik K-Distance (jarak ke tetangga terdekat ke-k yang diurutkan), kemudian dilanjutkan dengan pengujian kombinasi parameter (grid search) terhadap berbagai kandidat nilai eps dan min_samples. Pada dataset Mall Customers (2 fitur), diuji kandidat min_samples = [3, 5, 8, 10] dan eps = [0,2 hingga 1,2]. Pada dataset Marketing Campaign (13 fitur), mengacu pada aturan umum untuk data berdimensi tinggi (2 × jumlah fitur = 26), diuji kandidat min_samples = [15, 20, 26, 35, 50] dan eps = [1,0 hingga 4,0]. Evaluasi dilakukan menggunakan Silhouette Score, Davies-Bouldin Index (DBI), dan Calinski-Harabasz Index (CH) pada titik-titik non-noise, serta dibandingkan terhadap metode K-Means sebagai baseline.

```
for min_samples in MIN_SAMPLES_CANDIDATES:
    for eps in EPS_CANDIDATES:
        model = DBSCAN(eps=eps, min_samples=min_samples)
        labels = model.fit_predict(X_scaled)

        n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
        n_noise = int((labels == -1).sum())

dbscan_final = DBSCAN(eps=FINAL_EPS, min_samples=FINAL_MIN_SAMPLES)
labels = dbscan_final.fit_predict(X_scaled)

mask = labels != -1
sil = silhouette_score(X_scaled[mask], labels[mask])
dbi = davies_bouldin_score(X_scaled[mask], labels[mask])
ch = calinski_harabasz_score(X_scaled[mask], labels[mask])
```

Gambar 2.8 Implementasi Metode DBSCAN.

BAB III
HASIL DAN PEMBAHASAN

3.1 Hasil Clustering Fuzzy C-Means pada Dataset Mall Customers

Dataset Mall Customers memiliki 200 data pelanggan dengan 5 atribut. Pada penerapan metode Fuzzy C-Means, atribut yang digunakan adalah Annual Income (k$) dan Spending Score (1-100).

Sebelum proses clustering, kedua atribut tersebut distandardisasi menggunakan StandardScaler. Selanjutnya, dilakukan pengujian dengan beberapa variasi jumlah cluster untuk memperoleh hasil pengelompokan yang paling sesuai.

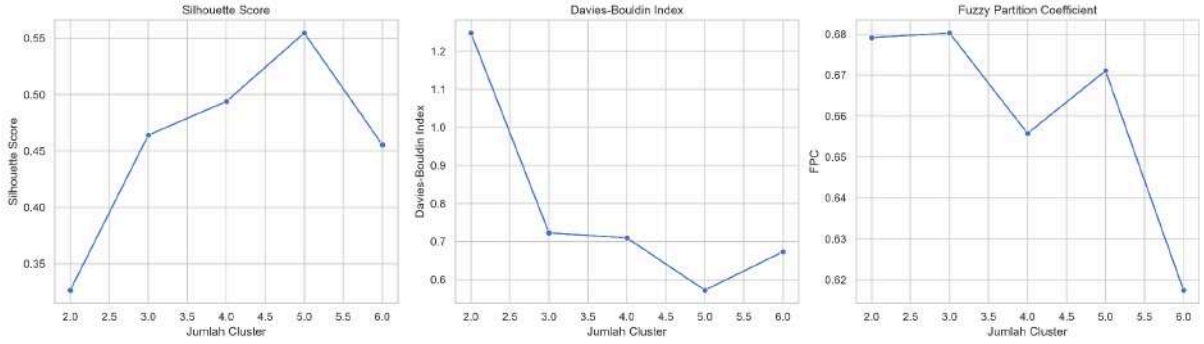
Berdasarkan hasil pengujian, jumlah cluster terbaik yang diperoleh adalah 5 cluster dengan nilai Silhouette Score sebesar 0,5547.

3.1.1 Hasil Evaluasi Clustering

Jumlah Cluster	FPC	Silhoutte Score	DBI	CH
3	0,6803	0,4641	0,7230	150,1808
4	0,6557	0,4939	0,7096	174,5952
5	0,6711	**0,5547**	**0,5722**	**248,6493**
6	0,6174	0,4556	0,6732	232,0150

Tabel 3.1 Hasil Evaluasi Fuzzy C-Means pada Dataset Mall Customers.

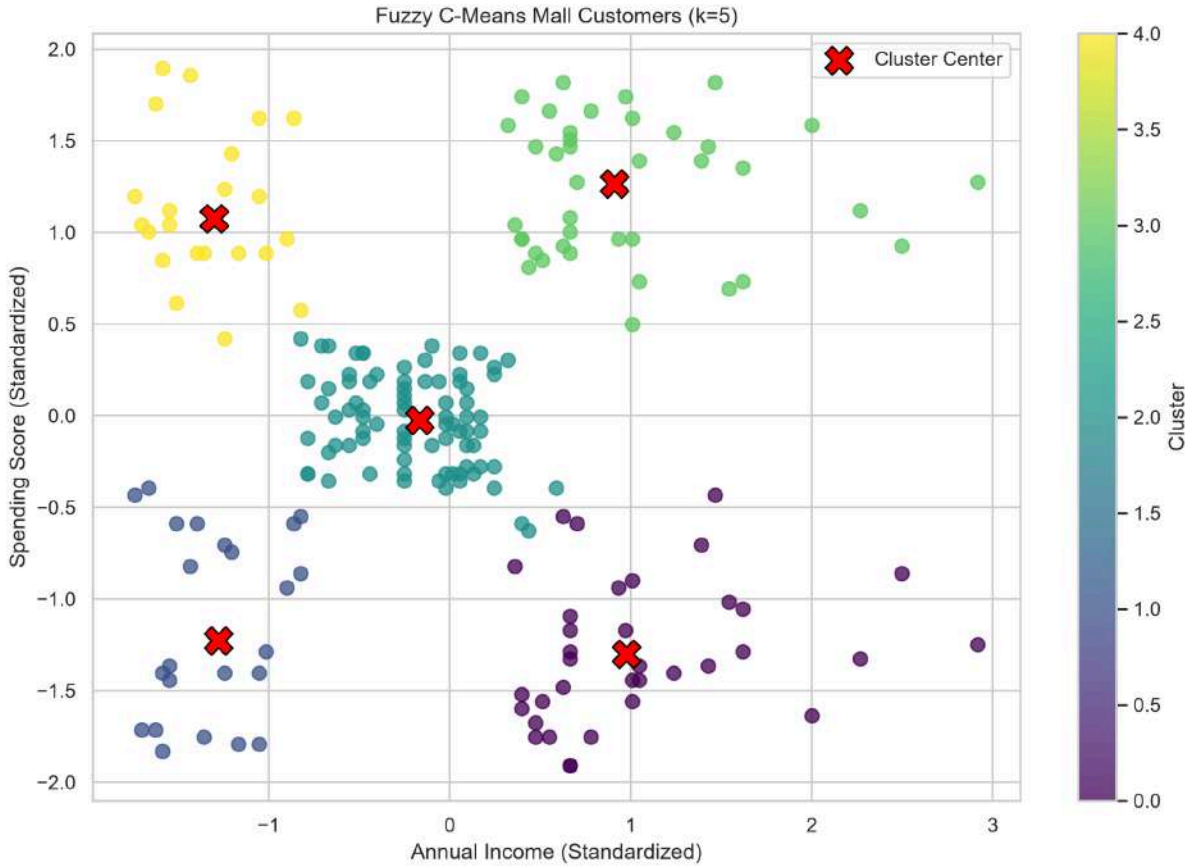
Berdasarkan tabel evaluasi, jumlah cluster sebanyak 5 menghasilkan nilai Silhouette Score tertinggi, yaitu 0,5547. Selain itu, nilai Davies-Bouldin Index sebesar 0,5722 merupakan nilai terendah dibandingkan variasi jumlah cluster yang ditampilkan, sedangkan nilai Calinski-Harabasz Index sebesar 248,6493 merupakan nilai tertinggi. Berdasarkan hasil tersebut, jumlah 5 cluster dipilih sebagai hasil terbaik untuk pengelompokan dataset Mall Customers.



Gambar 3.1 Grafik Evaluasi Fuzzy C-Means pada Dataset Mall Customers.

3.1.2 Visualisasi Hasil Clustering

Hasil pengelompokan menggunakan 5 cluster divisualisasikan dalam bentuk scatter plot berdasarkan atribut Annual Income dan Spending Score. Setiap warna menunjukkan kelompok pelanggan yang berbeda, sedangkan tanda silang merah menunjukkan pusat cluster.



Gambar 3..2 Visualisasi Hasil Clustering Fuzzy C-Means pada Dataset Mall Customers.

Visualisasi tersebut memperlihatkan adanya perbedaan karakteristik pelanggan berdasarkan tingkat pendapatan dan skor pengeluaran.

3.1.3 Karakteristik Setiap Cluster

Cluster	Jumlah Pelanggan	Rata-rata Pendapatan	Rata-rata Spending Score
C0	35	88,20	17,11
C1	23	26,30	20,91
C2	81	55,30	49,52
C3	39	86,54	82,13
C4	22	25,73	79,36

Tabel 3.2 Profil Cluster Dataset Mall Customers.

Berdasarkan profil cluster, diperoleh lima kelompok pelanggan dengan karakteristik yang berbeda.

- Cluster 0 terdiri dari 35 pelanggan dengan pendapatan rata-rata tinggi dan skor pengeluaran rendah.
- Cluster 1 terdiri dari 23 pelanggan dengan pendapatan rata-rata rendah dan skor pengeluaran rendah.
- Cluster 2 merupakan kelompok terbesar dengan 81 pelanggan yang memiliki pendapatan dan skor pengeluaran pada tingkat menengah.
- Cluster 3 terdiri dari 39 pelanggan dengan pendapatan dan skor pengeluaran tinggi.
- Cluster 4 terdiri dari 22 pelanggan dengan pendapatan rendah dan skor pengeluaran tinggi.

Hasil tersebut menunjukkan bahwa metode Fuzzy C-Means mampu membagi pelanggan Mall Customers menjadi lima kelompok berdasarkan karakteristik pendapatan dan perilaku pengeluaran.

3.2 Hasil Clustering Fuzzy C-Means pada Dataset Marketing Campaign

Dataset Marketing Campaign memiliki 2.240 data pelanggan dengan 29 atribut. Pada penerapan metode Fuzzy C-Means, digunakan beberapa atribut numerik yang berkaitan dengan pendapatan, aktivitas pembelian produk, dan interaksi pelanggan.

Sebelum proses clustering dilakukan, nilai kosong pada atribut Income sebanyak 24 data ditangani menggunakan metode median imputation. Selanjutnya, data distandardisasi menggunakan StandardScaler agar setiap fitur memiliki skala yang sebanding.

Pengujian Fuzzy C-Means dilakukan menggunakan beberapa variasi jumlah cluster, yaitu 2 hingga 6 cluster. Berdasarkan hasil evaluasi, jumlah cluster terbaik yang diperoleh adalah 2 cluster dengan nilai Silhouette Score sebesar 0,3577.

3.2.1 Hasil Evaluasi Clustering

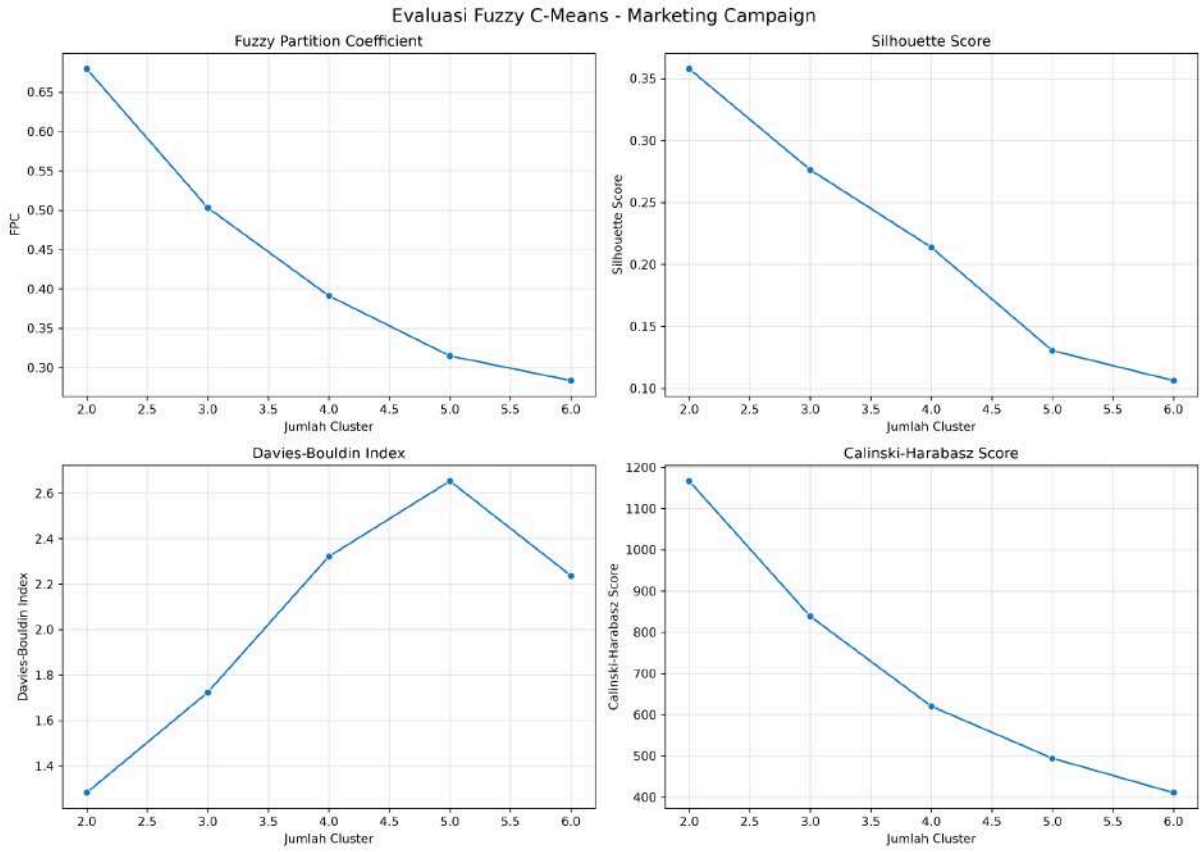
Evaluasi clustering dilakukan untuk mengetahui kualitas pengelompokkan data menggunakan metode Fuzzy C-Means. Pengujian dilakukan dengan variasi jumlah cluster (k) dari 2 hingga 6. Beberapa metrik yang digunakan adalah Fuzzy Partition Coefficient (FPC), Silhoutte Score, Davies-Bouldin Index (DBI), dan Calinski-Harabasz Index (CH).

Berdasarkan hasil pengujian, jumlah cluster terbaik adalah 2 cluster dengan nilai Silhouette Score sebesar 0,3577, DBI sebesar 1,2822, dan CH sebesar 1166,8225. Hasil tersebut menunjukkan bahwa pembagian menjadi 2 cluster memberikan kualitas pengelompokan terbaik dibandingkan jumlah cluster lainnya berdasarkan nilai Silhouette Score.

Jumlah Cluster (k)	FPC	Silhoutte Score	DBI	CH
2	0,6795	0,3577	1,2822	1166,8225
3	0,5031	0,2763	1,7240	838,4121
4	0,3913	0,2137	2,3217	620,2938

5	0,3149	0,1304	2,6540	493,9415
6	0,2836	0,1064	2,2371	410,7101

Tabel 3.3 Hasil Evaluasi Fuzzy C-Means pada Dataset Marketing Campaign.

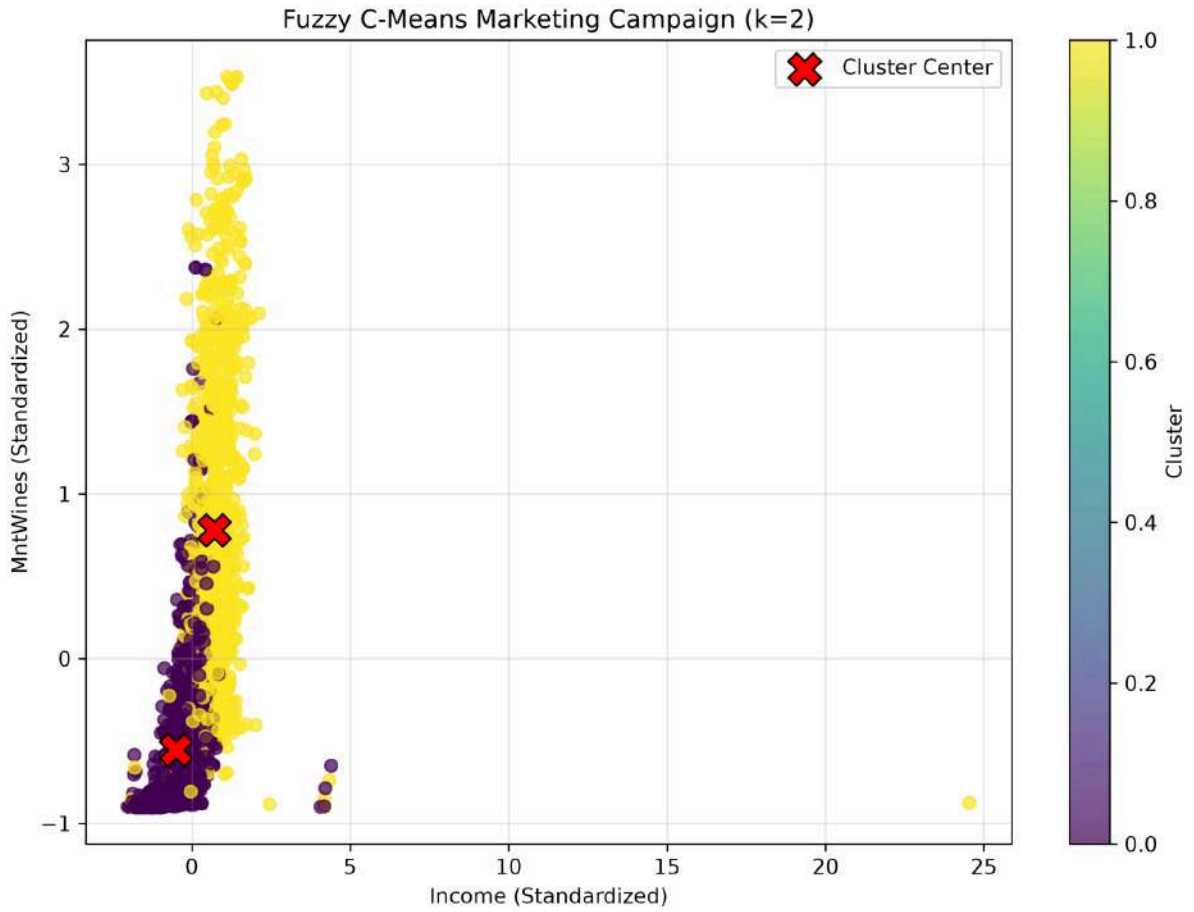


Gambar 3.3 Grafik Evaluasi Fuzzy C-Means pada Dataset Marketing Campaign.

3.2.2 Visualisasi Hasil Clustering

Visualisasi hasil clustering digunakan untuk melihat pola pengelompokan pelanggan berdasarkan karakteristik pembelian dan aktivitas pelanggan. Hasil pengelompokan Fuzzy C-Means ditampilkan dalam bentuk grafik scatter plot dengan warna yang berbeda untuk setiap cluster.

Berdasarkan hasil visualisasi, data pelanggan terbagi menjadi dua kelompok. Setiap kelompok menunjukkan karakteristik pelanggan yang berbeda berdasarkan atribut yang digunakan dalam proses clustering. Visualisasi ini membantu memperlihatkan distribusi data serta perbedaan pola antara kedua cluster.



Gambar 3.4 Visualisasi Hasil Clustering Fuzzy C-Means pada Dataset Marketing Campaign.

3.2.3 Karakteristik Setiap Cluster

Berdasarkan hasil clustering Fuzzy C-Means dengan jumlah 2 cluster, diperoleh pengelompokan pelanggan dengan karakteristik yang berbeda. Perbedaan tersebut dapat dilihat dari rata-rata pendapatan, aktivitas pembelian produk, dan frekuensi transaksi pelanggan.

- **Cluster 0** terdiri dari 1.332 pelanggan dengan rata-rata pendapatan sebesar 38.843,16. Kelompok ini memiliki rata-rata pembelian produk wine sebesar 103,22, pembelian produk daging sebesar 35,70, serta rata-rata pembelian melalui web sebanyak 2,92 kali dan melalui toko sebanyak 3,90 kali. Secara umum, cluster ini menggambarkan pelanggan dengan pendapatan dan aktivitas pembelian yang relatif lebih rendah.
- **Cluster 1** terdiri dari 908 pelanggan dengan rata-rata pendapatan sebesar 71.887,64. Kelompok ini memiliki rata-rata pembelian produk wine sebesar 598,38 dan produk daging sebesar 359,49. Rata-rata pembelian melalui web sebanyak 5,80 kali dan melalui toko sebanyak 8,56 kali. Hal ini menunjukkan bahwa pelanggan pada cluster ini memiliki pendapatan dan aktivitas pembelian yang lebih tinggi dibandingkan Cluster 0.

Dengan demikian, hasil clustering menunjukkan dua kelompok pelanggan, yaitu kelompok dengan tingkat pendapatan dan aktivitas pembelian relatif lebih rendah serta kelompok dengan tingkat pendapatan dan aktivitas pembelian relatif lebih tinggi.

Cluster	Jumlah Pelanggan	Rata-rata Income	Rata-rata Recency	Rata-rata MntWines	Rata-rata MntMeatProducts
Cluster0	1.332	38.843,16	48,71	103,22	35,70
Cluster1	908	71.887,64	49,70	598,38	359,49

Tabel 3.4 Karakteristik Cluster pada Dataset Marketing Campaign.

3.3 Hasil Clustering K-Modes pada Dataset Mall Customers

Dataset Mall Customers memiliki 200 data pelanggan dengan 5 atribut dan tidak memiliki missing values. Pada penerapan K-Modes, atribut yang digunakan adalah Gender, Age_Group, Income_Level, dan Spending_Level. Tiga atribut terakhir diperoleh dengan mengkategorikan Age, Annual Income (k$), dan Spending Score (1-100).

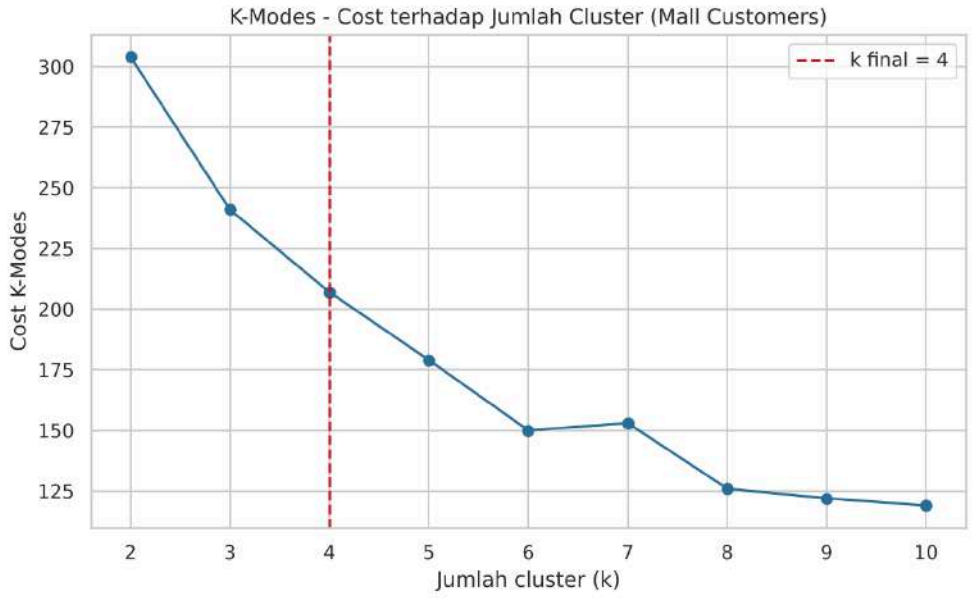
Pengujian dilakukan dengan jumlah cluster k = 2 sampai k = 10. Evaluasi menggunakan nilai cost, yaitu total ketidakcocokan kategori antara setiap data dan modus clusternya. Semakin kecil nilai cost, semakin mirip anggota dalam satu cluster. Jumlah cluster yang digunakan adalah 4 cluster dengan nilai cost sebesar 207.

3.3.1 Hasil Evaluasi Clustering

Cost K-Modes menurun dari 304 pada k = 2 menjadi 119 pada k = 10. Penurunan terbesar terjadi dari k = 2 ke k = 3 (63), lalu berkurang menjadi 34 dari k = 3 ke k = 4 dan 28 dari k = 4 ke k = 5. Pada k = 7 cost naik sedikit menjadi 153 dari 150 pada k = 6. Hal ini dapat terjadi karena hasil K-Modes dipengaruhi pemilihan modus awal. Grafik cost tidak menunjukkan titik siku yang tajam, sehingga k = 4 dipilih sebagai keseimbangan antara penurunan cost dan kemudahan menafsirkan setiap cluster.

Jumlah Cluster (k)	Cost	Penurunan Cost
2	304	-
3	241	63
4	207	34
5	179	28
6	150	29
7	153	-3
8	126	27
9	122	4
10	119	3

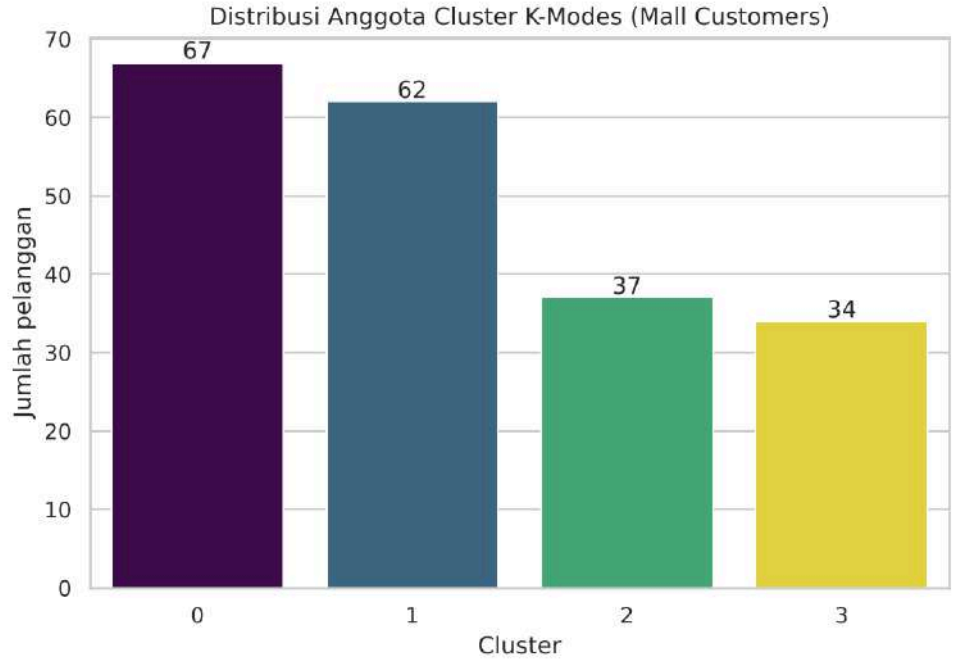
Tabel 3.5 Hasil Evaluasi K-Modes pada Dataset Mall Customers.



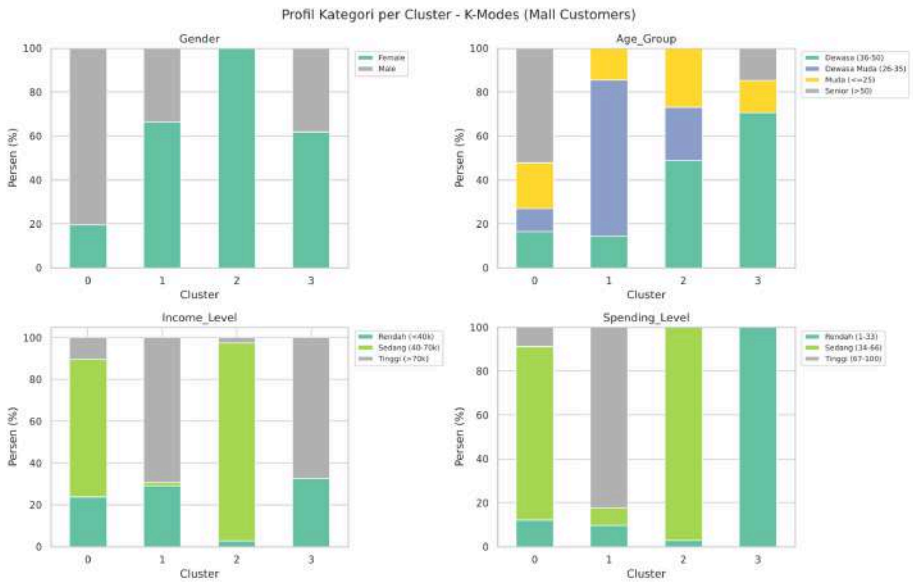
Gambar 3.5 Grafik Cost K-Modes pada Dataset Mall Customers.

3.3.2 Visualisasi Hasil Clustering

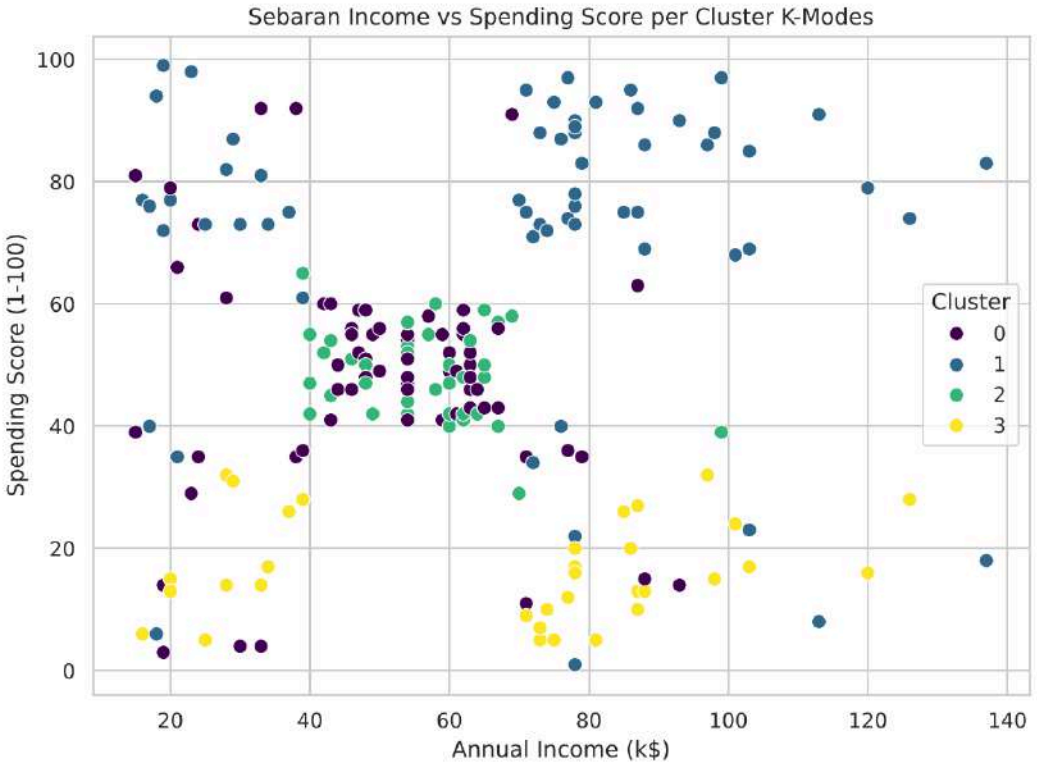
Hasil pengelompokan dengan 4 cluster divisualisasikan dalam bentuk diagram batang jumlah anggota, diagram komposisi kategori pada setiap cluster, dan sebaran Annual Income terhadap Spending Score. Karena K-Modes tidak menghitung jarak numerik, tidak ada pusat cluster berupa titik seperti pada Fuzzy C-Means. Pusat cluster pada K-Modes adalah kombinasi kategori yang paling sering muncul (modus).



Gambar 3.6 Distribusi Anggota Cluster K-Modes pada Dataset Mall Customers.



Gambar 3.7 Profil Kategori Setiap Cluster K-Modes pada Dataset Mall Customers.



Gambar 3.8 Sebaran Annual Income dan Spending Score Menurut Cluster K-Modes.

Visualisasi tersebut memperlihatkan bahwa cluster terbentuk dari kombinasi kategori jenis kelamin, kelompok usia, tingkat pendapatan, dan tingkat pengeluaran.

3.3.3 Karakteristik Setiap Cluster

Cluster	Jumlah Pelanggan	Persentase	Rata-rata Usia	Rata-rata Pendapatan	Rata-rata Spending Score
C0	67	33,5%	46,85	50,78	48,21
C1	62	31,0%	31,02	69,66	72,16
C2	37	18,5%	35,24	56,24	48,30
C3	34	17,0%	41,29	67,94	16,15

Tabel 3.6 Profil Cluster K-Modes pada Dataset Mall Customers.

Cluster	Gender	Kelompok Usia	Tingkat Pendapatan	Tingkat Spending
C0	Male (80,6%)	Senior >50 (52,2%)	Sedang (65,7%)	Sedang (79,1%)
C1	Female (66,1%)	Dewasa Muda 26-35 (71,0%)	Tinggi (69,3%)	Tinggi (82,3%)
C2	Female (100%)	Dewasa 36-50 (48,6%)	Sedang (94,6%)	Sedang (97,3%)
C3	Female (61,8%)	Dewasa 36-50 (70,6%)	Tinggi (67,7%)	Rendah (100%)

Tabel 3.7 Kategori Dominan (Modus) Setiap Cluster K-Modes pada Dataset Mall Customers.

Berdasarkan profil cluster, diperoleh empat kelompok pelanggan dengan karakteristik yang berbeda.

- Cluster 0 terdiri dari 67 pelanggan, didominasi laki-laki (80,6%) dengan usia di atas 50 tahun (52,2%), serta pendapatan dan skor pengeluaran pada tingkat sedang.
- Cluster 1 terdiri dari 62 pelanggan, sebagian besar perempuan (66,1%) berusia 26-35 tahun (71,0%), dengan pendapatan tinggi (69,3%) dan skor pengeluaran tinggi (82,3%).
- Cluster 2 terdiri dari 37 pelanggan yang seluruhnya perempuan, sebagian besar berusia 36-50 tahun (48,6%), dengan pendapatan dan skor pengeluaran pada tingkat sedang.
- Cluster 3 terdiri dari 34 pelanggan, sebagian besar perempuan (61,8%) berusia 36-50 tahun (70,6%), dengan pendapatan tinggi (67,7%) tetapi seluruhnya memiliki skor pengeluaran rendah.

Pada Cluster 1 dan Cluster 3, sekitar sepertiga anggota (29,0% dan 32,4%) berpendapatan rendah, sehingga kategori pendapatan tinggi menjadi kategori terbanyak tetapi tidak mutlak. Secara umum, K-Modes membagi pelanggan Mall Customers menjadi empat kelompok berdasarkan kombinasi jenis kelamin, usia, pendapatan, dan pengeluaran.

3.4 Hasil Clustering K-Modes pada Dataset Marketing Campaign

Dataset Marketing Campaign memiliki 2.240 data pelanggan dengan 29 atribut. Pada penerapan K-Modes, atribut yang digunakan adalah Education, Marital_Status, Kidhome,

Teenhome, Age_Group, Income_Level, Campaign_Accepted, dan Response. Atribut ID tidak digunakan sebagai fitur.

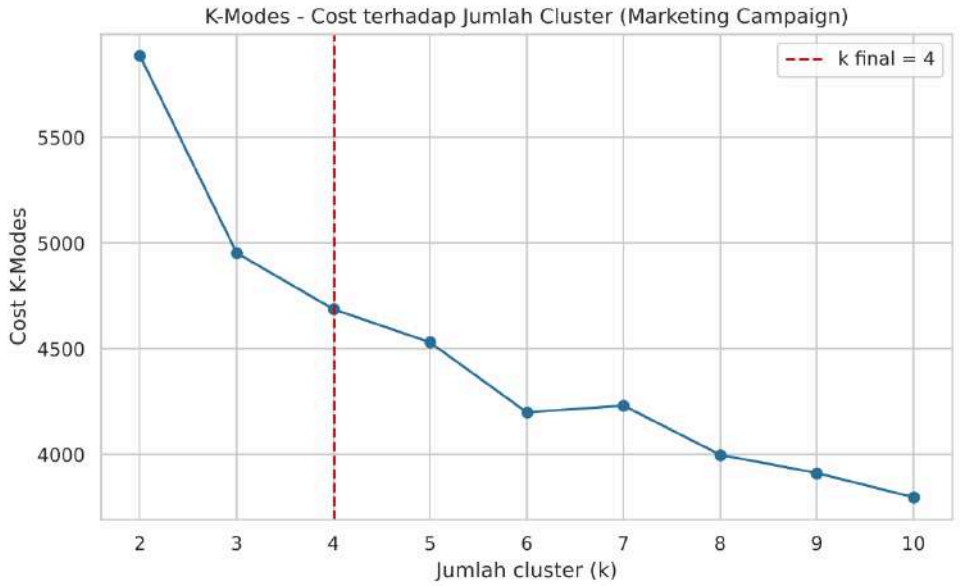
Sebelum proses clustering, nilai kosong pada atribut Income sebanyak 24 data ditangani dengan mengisinya menggunakan modus (kategori yang paling sering muncul) setelah Income dikategorikan. Pengujian dilakukan dengan k = 2 sampai k = 10 dan dievaluasi menggunakan nilai cost. Jumlah cluster yang digunakan adalah 4 cluster dengan nilai cost sebesar 4.688.

3.4.1 Hasil Evaluasi Clustering

Cost K-Modes menurun dari 5.887 pada k = 2 menjadi 3.798 pada k = 10. Penurunan terbesar terjadi dari k = 2 ke k = 3 (933). Penurunan berikutnya lebih kecil, yaitu 266 pada k = 4 dan 157 pada k = 5, kemudian 331 pada k = 6. Pada k = 7 cost naik sedikit menjadi 4.232 dari 4.200 pada k = 6, yang dapat terjadi karena hasil K-Modes dipengaruhi pemilihan modus awal. Jumlah cluster k = 4 dipilih sebagai keseimbangan antara penurunan cost dan kemudahan menafsirkan setiap cluster.

Jumlah Cluster (k)	Cost	Penurunan Cost
2	5.887	-
3	4.954	933
4	4.688	266
5	4.531	157
6	4.200	331
7	4.232	-32
8	3.999	233
9	3.913	86
10	3.798	115

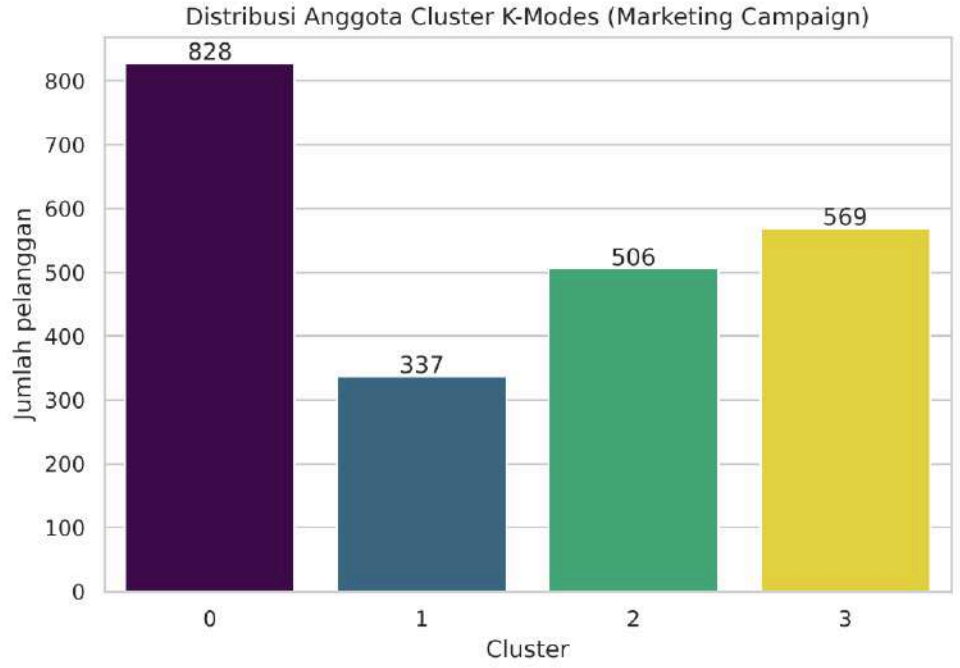
Tabel 3.8 Hasil Evaluasi K-Modes pada Dataset Marketing Campaign.



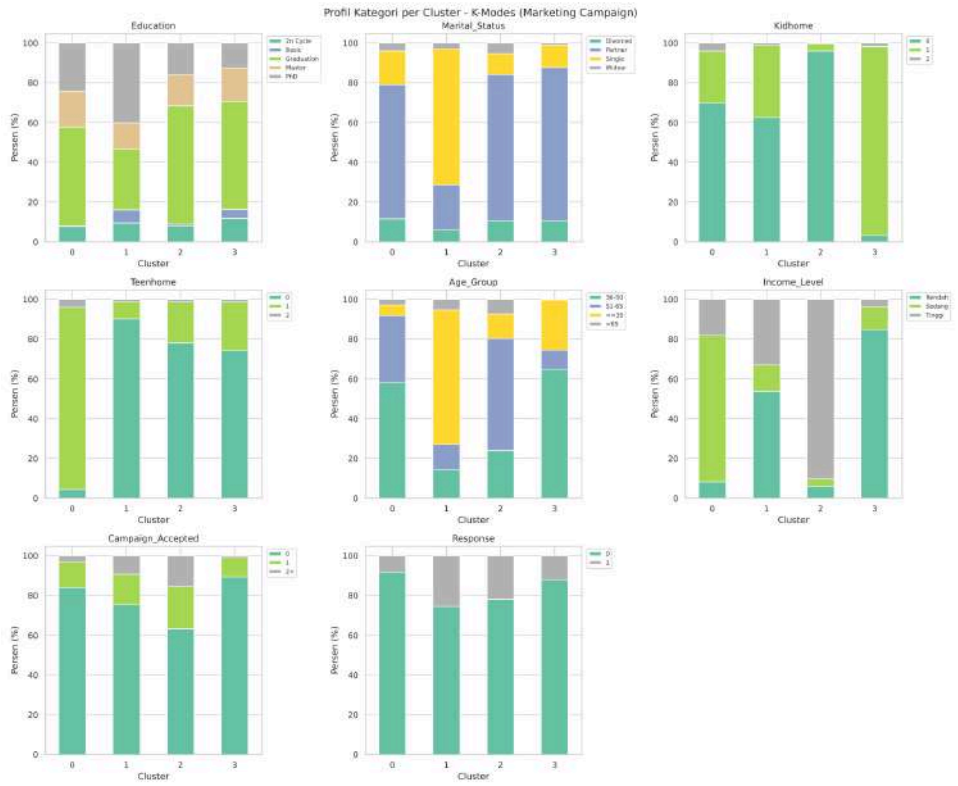
Gambar 3.9 Grafik Cost K-Modes pada Dataset Marketing Campaign.

3.4.2 Visualisasi Hasil Clustering

Hasil pengelompokan dengan 4 cluster divisualisasikan dalam bentuk diagram batang jumlah anggota dan diagram komposisi kategori setiap atribut pada tiap cluster. Karena seluruh atribut berupa kategori, visualisasi sebaran titik seperti pada Fuzzy C-Means tidak digunakan.



Gambar 3.10 Distribusi Anggota Cluster K-Modes pada Dataset Marketing Campaign.



Gambar 3.11 Profil Kategori Setiap Cluster K-Modes pada Dataset Marketing Campaign.

Visualisasi tersebut memperlihatkan bahwa perbedaan antar cluster terutama terlihat pada tingkat pendapatan, kelompok usia, status pernikahan, dan jumlah anak di rumah.

3.4.3 Karakteristik Setiap Cluster

Cluster	Jumlah Pelanggan	Persentase
C0	828	37,0%
C1	337	15,0%
C2	506	22,6%
C3	569	25,4%

Tabel 3.9 Jumlah Anggota Setiap Cluster K-Modes pada Dataset Marketing Campaign.

Cluster	Education	Marital_Status	Kidhome	Teenhome	Kelompok Usia	Tingkat Income
C0	Graduation (49,8%)	Partner (67,4%)	0 (69,8%)	1 (91,7%)	36-50 (58,1%)	Sedang (73,7%)
C1	PhD (40,1%)	Single (68,2%)	0 (62,6%)	0 (90,2%)	≤35 (67,7%)	Rendah (53,7%)
C2	Graduation (59,5%)	Partner (73,5%)	0 (96,0%)	0 (78,1%)	51-65 (56,5%)	Tinggi (90,3%)

Cluster	Education	Marital_Status	Kidhome	Teenhome	Kelompok Usia	Tingkat Income
C3	Graduation (54,7%)	Partner (77,0%)	1 (95,1%)	0 (74,3%)	36-50 (64,8%)	Rendah (84,9%)

Tabel 3.10 Kategori Dominan (Modus) Setiap Cluster K-Modes pada Dataset Marketing Campaign

Cluster	Menerima 0 Kampanye	Menerima 1 Kampanye	Menerima 2+ Kampanye	Response = 1
C0	83,9%	13,2%	2,9%	8,3%
C1	75,4%	15,4%	9,2%	25,5%
C2	63,2%	21,3%	15,4%	21,9%
C3	89,3%	9,8%	0,9%	11,9%

Tabel 3.11 Proporsi Penerimaan Kampanye dan Response Setiap Cluster K-Modes.

Berdasarkan profil cluster, diperoleh empat kelompok pelanggan dengan karakteristik yang berbeda.

- **Cluster 0** terdiri dari 828 pelanggan dan merupakan kelompok terbesar. Sebagian besar berpendidikan Graduation (49,8%), berstatus Partner (67,4%), berusia 36-50 tahun (58,1%), berpendapatan sedang (73,7%), dan memiliki remaja di rumah (91,7%). Kelompok ini paling jarang memberikan Response positif (8,3%).
- **Cluster 1** terdiri dari 337 pelanggan. Sebagian besar berstatus Single (68,2%), berusia 35 tahun ke bawah (67,7%), tidak memiliki anak maupun remaja di rumah, dan berpendidikan PhD (40,1%). Pendapatannya paling banyak berada di tingkat rendah (53,7%), tetapi 32,9% berpendapatan tinggi. Kelompok ini memiliki Response positif tertinggi (25,5%).
- **Cluster 2** terdiri dari 506 pelanggan. Sebagian besar berpendapatan tinggi (90,3%), berusia 51-65 tahun (56,5%), berstatus Partner (73,5%), dan hampir seluruhnya tidak memiliki anak kecil di rumah (96,0%). Kelompok ini paling sering menerima kampanye, dengan 36,8% menerima minimal satu kampanye (15,4% menerima dua atau lebih), dan Response positif sebesar 21,9%.
- **Cluster 3** terdiri dari 569 pelanggan. Sebagian besar berpendapatan rendah (84,9%), berusia 36-50 tahun (64,8%), berstatus Partner (77,0%), dan hampir seluruhnya memiliki satu anak kecil di rumah (95,1%). Kelompok ini paling jarang menerima kampanye (89,3% tidak menerima satu pun) dengan Response positif sebesar 11,9%.

Perlu diperhatikan bahwa K-Modes pada penelitian ini tidak memakai atribut jumlah pembelian produk (Mnt) maupun saluran pembelian, sehingga karakteristik cluster menggambarkan profil demografis dan respons terhadap kampanye, bukan perilaku belanja. Secara umum, K-Modes membagi pelanggan Marketing Campaign menjadi empat kelompok berdasarkan pendapatan, usia, status keluarga, dan keterlibatan pada kampanye pemasaran.

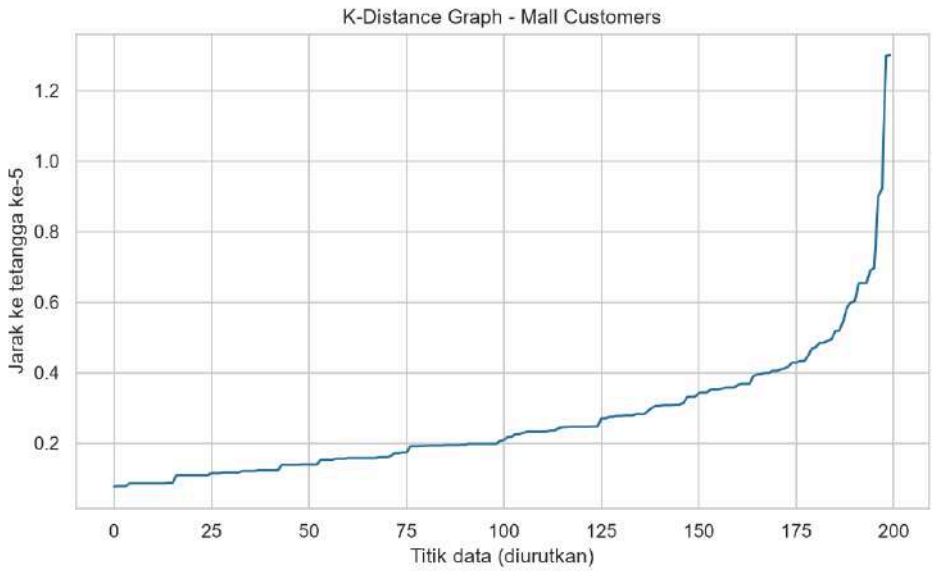
3.5 Hasil Clustering DBSCAN pada Dataset Mall Customers

Dataset Mall Customers terdiri dari 200 data pelanggan tanpa nilai kosong (missing values). Pada penerapan metode DBSCAN, atribut yang digunakan adalah Annual Income (k$) dan Spending Score (1-100) yang telah distandardisasi menggunakan StandardScaler agar rentang nilai pendapatan tahunan dan skor pengeluaran sebanding dalam perhitungan jarak Euclidean.

Langkah awal penentuan parameter dilakukan dengan memetakan K-Distance Graph (menggunakan k = 5 sebagai acuan awal) untuk mengamati titik tekuk (knee point) peningkatan jarak tetangga terdekat. Selanjutnya, dilakukan pengujian grid search terhadap 44 kombinasi parameter yang terdiri dari min_samples = [3, 5, 8, 10] dan eps = [0,2 hingga 1,2 dengan interval 0,1]. Berdasarkan hasil pengujian dengan kriteria jumlah cluster yang wajar (2 hingga 8 cluster) dan persentase noise di bawah 15%, diperoleh parameter terbaik yaitu eps = 0,4 dan min_samples = 8 yang membentuk 5 cluster utama serta mengidentifikasi 25 data (12,50%) sebagai noise.

3.5.1 Hasil Evaluasi Clustering

Grafik K-Distance pada Gambar 3.12 memperlihatkan bahwa jarak ke tetangga terdekat ke-5 meningkat secara landai pada rentang nilai 0,1 hingga 0,4, kemudian mulai menanjak tajam setelah melewati kisaran 0,4 hingga 0,5. Hal ini mengonfirmasi bahwa ambang batas kepadatan (eps) yang optimal berada di sekitar nilai 0,4.



Gambar 3.12 K-Distance Graph pada Dataset Mall Customers.

Dari 44 kombinasi parameter yang diuji melalui grid search, nilai eps yang terlalu kecil (misalnya eps = 0,2) menyebabkan sebagian besar data terbuang sebagai noise (38,5% hingga 64,5%), sedangkan nilai eps ≥ 0,6 menyebabkan seluruh titik menyatu menjadi 1 cluster tunggal sehingga Silhouette Score tidak dapat dihitung. Sepuluh kombinasi parameter dengan nilai Silhouette Score tertinggi ditampilkan pada Tabel 3.12.

eps	min_samples	Jumlah Cluster	Jumlah Noise	Persentase Noise	Silhouette Score
0,3	10	4	88	44,00%	0,6073
0,2	8	2	116	58,00%	0,6027
0,4	10	4	51	25,50%	0,5972

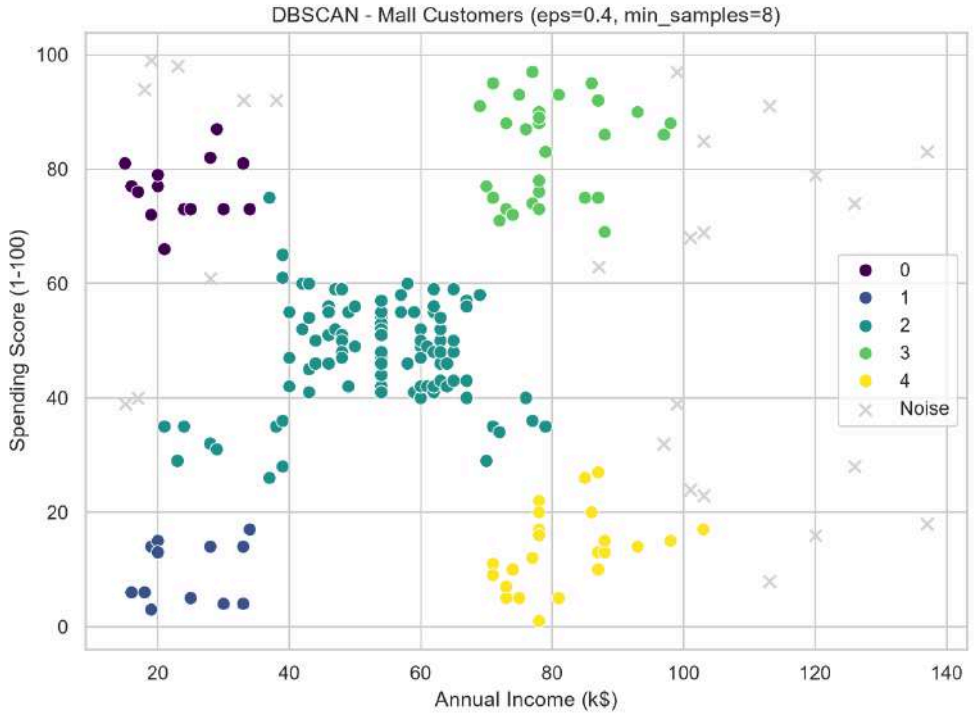
0,3	8	5	72	36,00%	0,5926
0,2	5	7	77	38,50%	0,5856
0,4	8	5	25	12,50%	0,5490
0,3	5	7	35	17,50%	0,5243
0,5	10	4	21	10,50%	0,5107
0,4	5	4	15	7,50%	0,4781
0,3	3	9	14	7,00%	0,4720

Tabel 3.12 Hasil Pengujian Grid Search Parameter DBSCAN pada Dataset Mall Customers.

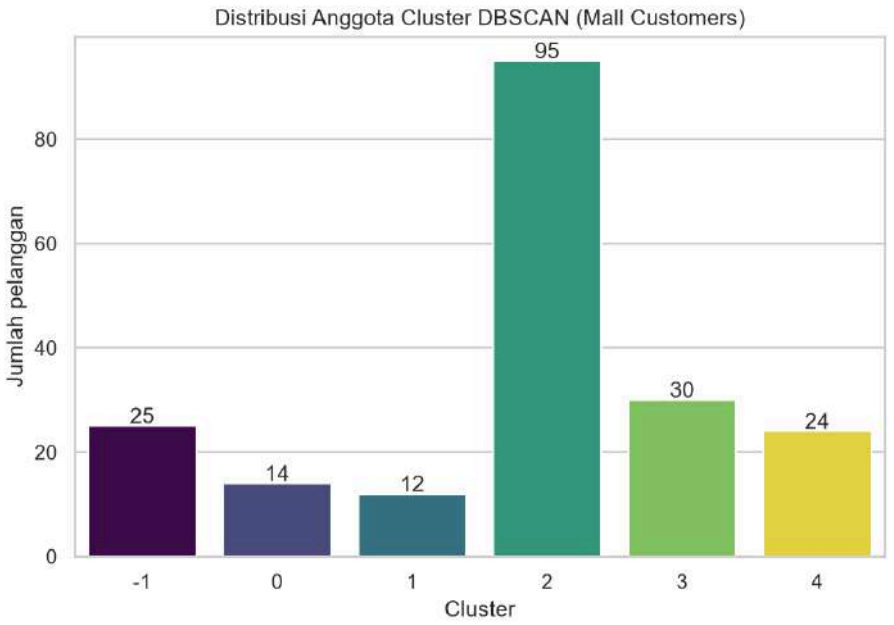
Meskipun kombinasi seperti eps = 0,3 dan min_samples = 10 menghasilkan Silhouette Score mencapai 0,6073, kombinasi tersebut membuang 44,00% data sebagai noise. Oleh karena itu, dipilih kombinasi eps = 0,4 dan min_samples = 8 karena menghasilkan Silhouette Score tertinggi (0,5490) dengan proporsi noise yang tetap terjaga di bawah 15% (25 data atau 12,50%), serta membentuk 5 cluster yang representatif. Pada titik-titik non-noise (175 pelanggan), model final DBSCAN memperoleh nilai Silhouette Score sebesar 0,5490, Davies-Bouldin Index (DBI) sebesar 0,5015, dan Calinski-Harabasz Index (CH) sebesar 222,1.

3.5.2 Visualisasi Hasil Clustering

Hasil pengelompokan DBSCAN dengan parameter eps = 0,4 dan min_samples = 8 divisualisasikan melalui scatter plot sebaran Annual Income terhadap Spending Score (Gambar 3.13) serta diagram batang distribusi jumlah anggota setiap cluster (Gambar 3.14). Pada scatter plot, lima kelompok pelanggan yang padat ditampilkan dengan warna berbeda (Cluster 0 hingga Cluster 4), sedangkan 25 titik pelanggan yang berada di area berkerapatan rendah ditandai dengan simbol silang abu-abu sebagai Noise (Cluster -1).



Gambar 3.13 Visualisasi Hasil Clustering DBSCAN pada Dataset Mall Customers.



Gambar 3.14 Distribusi Anggota Cluster DBSCAN pada Dataset Mall Customers.

Visualisasi tersebut menunjukkan bahwa DBSCAN mampu mengenali lima konsentrasi utama pelanggan sebagaimana pada metode K-Means dan Fuzzy C-Means, namun secara otomatis memisahkan titik-titik ekstrem di pinggiran (terutama pelanggan dengan pendapatan sangat tinggi di atas 100k$ yang letaknya berjauhan) sebagai data noise.

3.5.3 Karakteristik Setiap Cluster

Cluster	Jumlah Pelanggan	Persentase	Rata-rata Income (k$)	Rata-rata Spending Score	Rata-rata Usia
Noise (-1)	25	12,50%	83,04	60,48	33,44
C0	14	7,00%	23,64	76,43	24,43
C1	12	6,00%	24,58	9,58	48,75
C2	95	47,50%	53,25	47,77	42,48
C3	30	15,00%	79,53	83,13	32,73
C4	24	12,00%	81,88	12,96	41,21

Tabel 3.13 Profil dan Karakteristik Cluster DBSCAN pada Dataset Mall Customers.

Berdasarkan Tabel 3.13, karakteristik dari kelima cluster dan kelompok noise pada dataset Mall Customers dapat diinterpretasikan sebagai berikut:

Cluster 0 terdiri dari 14 pelanggan (7,00%) dengan rata-rata pendapatan rendah (23,64k$), tetapi memiliki skor pengeluaran tinggi (76,43) dan rata-rata usia paling muda (24,43 tahun). Kelompok ini merepresentasikan pelanggan muda yang konsumtif.

Cluster 1 terdiri dari 12 pelanggan (6,00%) dengan rata-rata pendapatan rendah (24,58k$), skor pengeluaran sangat rendah (9,58), dan rata-rata usia tertua (48,75 tahun). Kelompok ini menggambarkan pelanggan berpendapatan rendah yang sangat berhati-hati dalam berbelanja.

Cluster 2 merupakan kelompok terbesar yang mencakup 95 pelanggan (47,50%) dengan rata-rata pendapatan menengah (53,25k$), skor pengeluaran menengah (47,77), dan rata-rata

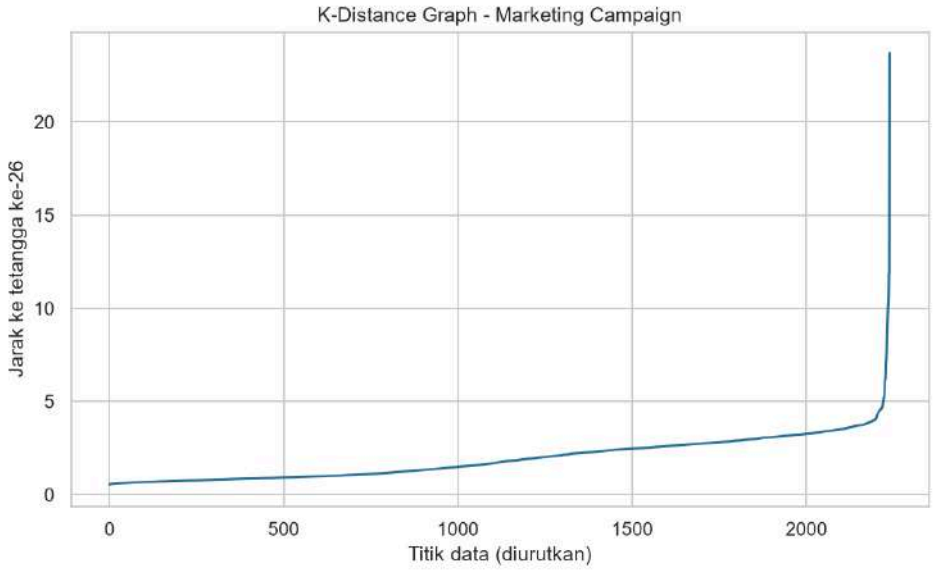
usia 42,48 tahun. Kelompok ini merupakan pelanggan reguler dengan kepadatan data paling tinggi di bagian tengah distribusi.
Cluster 3 terdiri dari 30 pelanggan (15,00%) dengan rata-rata pendapatan tinggi (79,53k$), skor pengeluaran sangat tinggi (83,13), dan rata-rata usia 32,73 tahun. Kelompok ini adalah segmen pelanggan potensial atau loyal (target utama pemasaran).
Cluster 4 terdiri dari 24 pelanggan (12,00%) dengan rata-rata pendapatan tinggi (81,88k$), namun skor pengeluarannya rendah (12,96) dan rata-rata usia 41,21 tahun. Kelompok ini merepresentasikan pelanggan mapan yang hemat di pusat perbelanjaan.
Kelompok Noise (-1) terdiri dari 25 pelanggan (12,50%) dengan rata-rata pendapatan 83,04k$ dan skor pengeluaran 60,48. Titik-titik ini merupakan pelanggan anomali atau pencilan (outlier), seperti pelanggan berpendapatan sangat tinggi (100k$–137k$) atau pelanggan di batas transisi antarcluster yang jaraknya terlalu renggang dari kelompok padat terdekat.

3.6 Hasil Clustering DBSCAN pada Dataset Marketing Campaign

Dataset Marketing Campaign memiliki 2.240 data pelanggan. Pada penerapan DBSCAN, digunakan 13 atribut numerik yang sama dengan Fuzzy C-Means, meliputi Income, Recency, 6 atribut nominal pembelian produk (MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds), 4 atribut frekuensi saluran pembelian (NumDealsPurchases, NumWebPurchases, NumCatalogPurchases, NumStorePurchases), dan NumWebVisitsMonth. Sebanyak 24 nilai kosong pada atribut Income diisi menggunakan nilai median (median imputation), kemudian seluruh 13 fitur distandardisasi menggunakan StandardScaler.
Mengingat jumlah dimensi fitur yang cukup tinggi (13 fitur), penentuan kandidat min_samples mengacu pada aturan umum Sander et al. yaitu sekitar 2 × jumlah fitur (2 × 13 = 26). Pengujian grid search dilakukan terhadap 65 kombinasi parameter dari min_samples = [15, 20, 26, 35, 50] dan eps = [1,0 hingga 4,0]. Berdasarkan hasil pengujian dengan kriteria jumlah cluster wajar (2–8 cluster) dan batas toleransi noise di bawah 30%, diperoleh parameter terbaik eps = 2,2 dan min_samples = 26 yang menghasilkan 2 cluster serta 653 titik noise (29,15%).

3.6.1 Hasil Evaluasi Clustering

Gambar 3.15 menampilkan K-Distance Graph dengan k = 26 pada dataset Marketing Campaign. Grafik menunjukkan peningkatan jarak ke tetangga ke-26 secara bertahap dari 0,5 hingga sekitar 3,5, lalu melonjak sangat curam hingga melampaui jarak 20 pada titik-titik ekstrem di ujung kanan. Pola rentang jarak yang lebar ini terjadi akibat fenomena curse of dimensionality pada ruang 13 dimensi.



Gambar 3.15 K-Distance Graph pada Dataset Marketing Campaign.

Berdasarkan pengujian 65 kombinasi parameter pada ruang 13 fitur, hampir seluruh kombinasi hanya membentuk 1 cluster besar dan mengelompokkan sisanya sebagai noise. Hanya terdapat 2 kombinasi parameter yang berhasil membentuk ≥ 2 cluster valid sehingga nilai Silhouette Score dapat dihitung, sebagaimana dirangkum pada Tabel 3.14.

eps	min_samples	Jumlah Cluster	Jumlah Noise	Persentase Noise	Silhouette Score
1,8	15	1	867	38,71%	- (1 cluster)
2,0	15	2	723	32,28%	0,2638
2,2	15	1	515	22,99%	- (1 cluster)
2,0	26	1	806	35,98%	- (1 cluster)
2,2	26	2	653	29,15%	0,3936
2,5	26	1	357	15,94%	- (1 cluster)
2,2	35	1	704	31,43%	- (1 cluster)
2,5	35	1	409	18,26%	- (1 cluster)

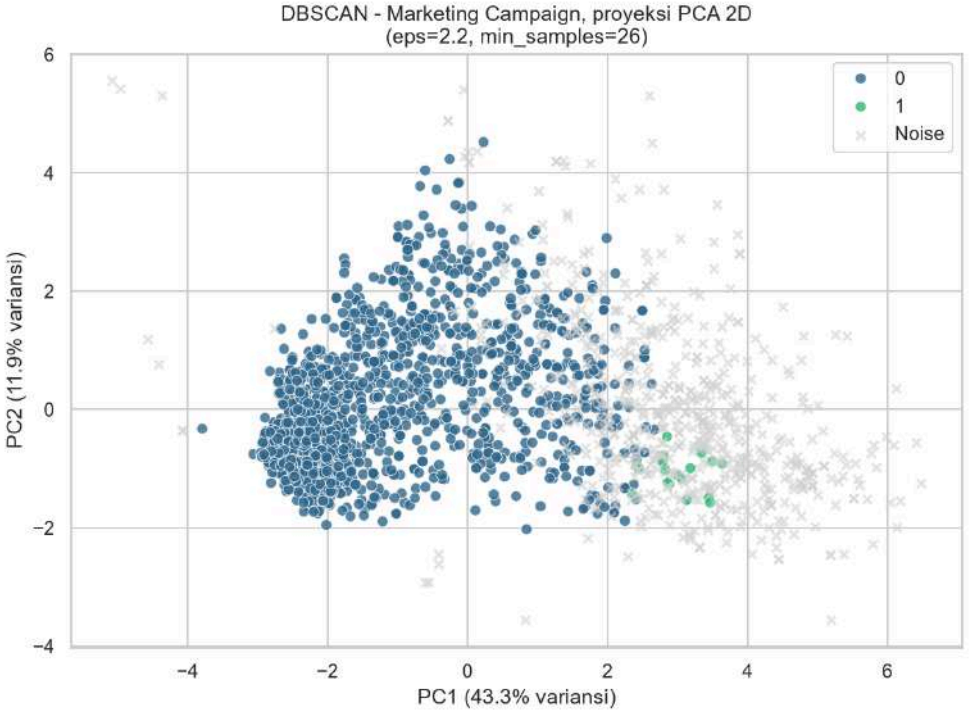
Tabel 3.14 Ringkasan Hasil Grid Search Parameter DBSCAN pada Dataset Marketing Campaign.

Kombinasi eps = 2,2 dan min_samples = 26 dipilih sebagai model final karena merupakan satu-satunya kombinasi yang membentuk 2 cluster dengan persentase noise di bawah 30% (653 data atau 29,15%) dan menghasilkan Silhouette Score lebih tinggi (0,3936) dibandingkan kombinasi eps = 2,0 dan min_samples = 15 (0,2638). Evaluasi metrik pada data non-noise (1.587 pelanggan) menghasilkan Silhouette Score sebesar 0,3936, Davies-Bouldin Index (DBI) sebesar 0,8993, dan Calinski-Harabasz Index (CH) sebesar 72,4.

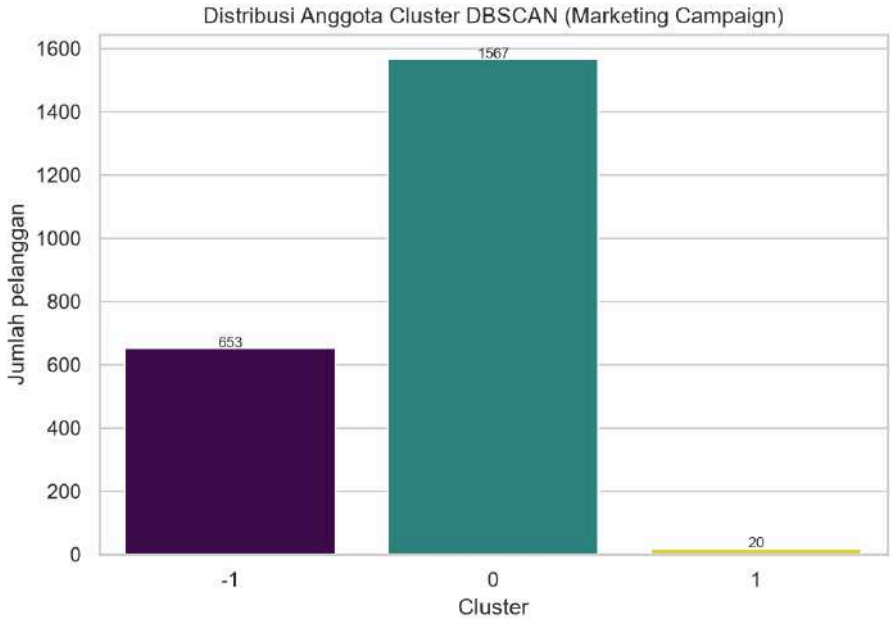
3.6.2 Visualisasi Hasil Clustering

Karena proses clustering dilakukan pada 13 fitur numerik, visualisasi sebaran hasil pengelompokan dilakukan dengan mereduksi dimensi data ke dalam 2 komponen utama menggunakan Principal Component Analysis (PCA) yang menjelaskan 55,2% total variansi

data (PC1 sebesar 43,3% dan PC2 sebesar 11,9%). Proyeksi PCA hanya digunakan untuk keperluan visualisasi pada Gambar 3.16, sedangkan distribusi jumlah anggota tiap cluster ditampilkan pada Gambar 3.17.



Gambar 3.16 Visualisasi Proyeksi PCA 2D Hasil Clustering DBSCAN pada Dataset Marketing Campaign.



Gambar 3.17 Distribusi Anggota Cluster DBSCAN pada Dataset Marketing Campaign.

Berdasarkan Gambar 3.16 dan Gambar 3.17, terlihat ketimpangan ukuran cluster yang sangat mencolok. Cluster 0 mendominasi sisi kiri proyeksi PCA dengan 1.567 pelanggan (69,96%), sedangkan Cluster 1 hanya berupa kelompok sangat kecil di sisi kanan bawah yang berisi 20 pelanggan (0,89%), dan 653 pelanggan lainnya (29,15%) tersebar di sisi kanan sebagai Noise (-1).

3.6.3 Karakteristik Setiap Cluster

Cluster	Jumlah (%)	Income	Recency	MntWines	MntMeat	WebPurch	CatalogPurch	StorePurch	WebVisits
Noise (-1)	653 (29,15 %)	73.563 ,71	49,59	616,39	397,35	5,60	5,68	8,23	3,83
C0	1.567 (69,96 %)	43.030 ,32	48,95	168,95	64,71	3,45	1,36	4,74	5,98
C1	20 (0,89 %)	77.372 ,75	45,75	678,40	655,10	4,25	6,30	8,60	1,85

Tabel 3.15 Profil Rata-rata Fitur Utama Setiap Cluster DBSCAN pada Dataset Marketing Campaign.

Berdasarkan Tabel 3.15 serta profil lengkap ke-13 fitur, karakteristik masing-masing kelompok pada dataset Marketing Campaign adalah sebagai berikut:

Cluster 0 merupakan kelompok mayoritas yang terdiri dari 1.567 pelanggan (69,96%) dengan rata-rata pendapatan menengah ke bawah sebesar 43.030,32. Pelanggan pada kelompok ini memiliki pengeluaran produk yang rendah di seluruh kategori (rata-rata MntWines 168,95; MntMeatProducts 64,71; MntFishProducts 14,62; MntFruits 10,05; MntSweetProducts 10,11; dan MntGoldProds 26,14), jarang berbelanja lewat katalog (1,36 kali), namun memiliki frekuensi kunjungan web bulanan tertinggi (5,98 kali) dan pembelian diskon tertinggi (2,45 kali). Pola perilaku belanja yang seragam dengan nilai rendah membuat titik-titik data mereka sangat rapat sehingga menyatu ke dalam satu cluster besar.

Cluster 1 merupakan kelompok mikro yang hanya terdiri dari 20 pelanggan (0,89%) dengan rata-rata pendapatan tinggi sebesar 77.372,75, pengeluaran wine (678,40) dan daging (655,10) yang sangat tinggi, frekuensi pembelian toko (8,60 kali) dan katalog (6,30 kali) yang tinggi, serta kunjungan web sangat rendah (1,85 kali) dan pembelian diskon paling rendah (1,00 kali). Kedua puluh pelanggan ini kebetulan memiliki kombinasi nilai pengeluaran tinggi yang sangat mirip satu sama lain sehingga memenuhi ambang batas kepadatan min_samples = 26 di sekitar titik intinya.

Kelompok Noise (-1) mencakup 653 pelanggan (29,15%) dengan rata-rata pendapatan tinggi sebesar 73.563,71 serta rata-rata pengeluaran produk yang tinggi (MntWines 616,39; MntMeatProducts 397,35; MntGoldProds 87,17; MntFishProducts 91,62). Pelanggan berpendapatan dan berpengeluaran tinggi memiliki variasi preferensi belanja yang sangat beragam antarindividu di ruang 13 fitur, sehingga jarak antartitik mereka menjadi renggang dan oleh DBSCAN dianggap sebagai noise, padahal secara bisnis mereka adalah segmen pelanggan bernilai tinggi (high-value customers).

3.7 Analisis Perbandingan Kinerja Metode Clustering terhadap K-Means

Untuk menjawab permasalahan mengenai apakah metode clustering lain (Fuzzy C-Means dan DBSCAN) memberikan akurasi atau kualitas pengelompokan yang lebih baik dibandingkan metode K-Means (baseline pada fitur numerik yang sama), dilakukan perbandingan metrik evaluasi Silhouette Score, Davies-Bouldin Index (DBI), Calinski-Harabasz Index (CH), serta proporsi data yang ter-cluster pada kedua dataset sebagaimana disajikan pada Tabel 3.16.

Dataset	Metode	Jumlah Cluster	Silhouette Score	DBI	Calinski-Harabasz	Data Noise

Mall Customers	K-Means (Baseline)	5	0,5547	0,5722	248,6	0 (0,0%)
Mall Customers	Fuzzy C-Means	5	0,5547	0,5722	248,6	0 (0,0%)
Mall Customers	DBSCAN (eps=0,4; min=8)	5	0,5490	0,5015	222,1	25 (12,5%)
Marketing Campaign	K-Means (Baseline)	2	0,3617	1,2844	1.168,0	0 (0,0%)
Marketing Campaign	Fuzzy C-Means	2	0,3577	1,2822	1.166,8	0 (0,0%)
Marketing Campaign	DBSCAN (eps=2,2; min=26)	2	0,3936*	0,8993*	72,4*	653 (29,2%)

*Tabel 3.16 Perbandingan Evaluasi K-Means, Fuzzy C-Means, dan DBSCAN pada Kedua Dataset (*dihitung tanpa titik noise).*

Berdasarkan Tabel 3.16, hasil analisis perbandingan kinerja metode clustering terhadap K-Means pada masing-masing dataset adalah sebagai berikut:

1. Analisis pada Dataset Mall Customers: Metode K-Means dan Fuzzy C-Means menghasilkan kualitas pengelompokan yang identik dan paling optimal dengan jumlah 5 cluster, nilai Silhouette Score sebesar 0,5547, DBI sebesar 0,5722, dan CH sebesar 248,6 tanpa membuang satu pun data pelanggan. Sementara itu, metode DBSCAN memperoleh nilai Silhouette Score yang sedikit lebih rendah yaitu 0,5490 (meskipun nilai DBI sedikit lebih baik yaitu 0,5015 karena 25 titik pencilan di pinggiran cluster dikeluarkan sebagai noise). Pada dataset Mall Customers yang memiliki 5 gerombolan data berbentuk cenderung membulat (spherical) dengan tingkat kepadatan yang relatif merata, metode berbasis titik pusat (K-Means dan Fuzzy C-Means) terbukti lebih unggul dan stabil dibandingkan DBSCAN yang bergantung pada perbedaan kerapatan lokal.
2. Analisis pada Dataset Marketing Campaign: Metode K-Means menghasilkan Silhouette Score sebesar 0,3617 (sedikit lebih tinggi dibandingkan Fuzzy C-Means sebesar 0,3577) dengan membagi seluruh 2.240 pelanggan ke dalam 2 segmen yang seimbang dan mudah diinterpretasikan (pelanggan pengeluaran rendah vs pengeluaran tinggi). Secara angka, DBSCAN memang mencatat nilai Silhouette Score yang tampak lebih tinggi yaitu 0,3936 dan DBI lebih rendah yaitu 0,8993. Namun, angka tersebut bersifat semu (menyesatkan apabila dibaca tanpa melihat distribusi anggota), karena metrik evaluasi DBSCAN hanya dihitung pada titik non-noise setelah membuang 653 pelanggan (29,15%) sebagai noise, serta menghasilkan pembagian cluster yang sangat timpang (Cluster 0 berisi 1.567 pelanggan, sedangkan Cluster 1 hanya berisi 20 pelanggan atau 1,3% dari data ter-cluster). Tingginya Silhouette Score pada DBSCAN semata-mata dipicu oleh 20 titik pada Cluster 1 yang sangat rapat, sementara mayoritas pelanggan bernilai tinggi justru terbuang sebagai noise akibat efek curse of dimensionality pada 13 fitur numerik. Hal ini juga tercermin dari nilai Calinski-Harabasz DBSCAN yang jatuh ke angka 72,4 dibandingkan K-Means sebesar 1.168,0.

3. Kesimpulan Perbandingan Terhadap K-Means: Penggunaan metode lain (Fuzzy C-Means dan DBSCAN) pada kedua dataset ini tidak menghasilkan peningkatan akurasi atau kualitas segmentasi yang lebih baik secara praktis dibandingkan metode K-Means. Fuzzy C-Means memberikan performa yang setara dengan K-Means dengan nilai tambah berupa informasi derajat keanggotaan (membership degree) bagi pelanggan yang berada di batas antarcluster. Sementara itu, DBSCAN unggul dalam mendeteksi pelanggan anomali atau outlier (noise), tetapi kurang efektif untuk segmentasi pelanggan secara menyeluruh pada data dengan kepadatan seragam maupun data berdimensi tinggi (13 fitur) dibandingkan K-Means.