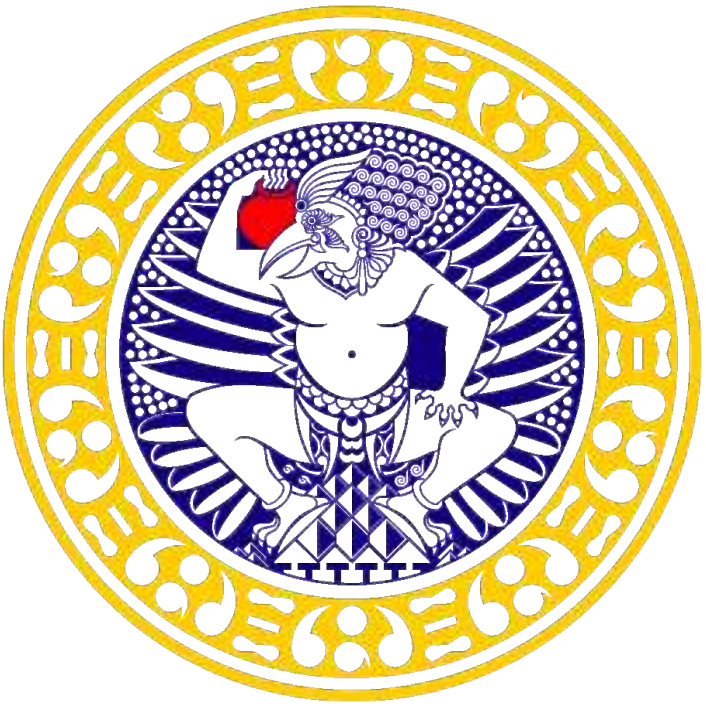
LAPORAN
PRAKTIKUM PEMBELAJARAN MESIN
REGRESI



Dosen Pengampu :
Barry Nuqoba, S.Si., M.Kom., Ph.D

Disusun Oleh :

MELLINDA IMPIAWATI DWINORI	434231032
OCTAVIA NUZULUL AZMI	434241040
GLENNOVIAN BENHUR UNITED L.	434241044

PROGRAM STUDI D4 TEKNIK INFORMATIKA
FAKULTAS VOKASI
UNIVERSITAS AIRLANGGA SURABAYA

TAHUN AJARAN 2026/2027

DAFTAR ISI

1.1 Latar Belakang.....3
1.2 Rumusan Masalah.....3
1.3 Tujuan Penelitian.....4
1.4 Manfaat Penelitian.....4
1.5 Batasan Masalah.....4
2.1 Alur Penelitian.....6
2.2 Dataset Penelitian.....6
2.3 Metode Regresi yang Digunakan.....7
2.3.1 XGBoost Regressor.....7
2.3.2 LightGBM Regressor.....8
2.4 Tahapan Preprocessing Data.....9
2.4.1 Pemeriksaan Struktur Dataset.....9
2.4.2 Pemeriksaan Missing Values dan Data Duplikat.....10
2.4.3 Analisis Outlier.....10
2.4.4 Pemisahan Fitur dan Target.....11
2.4.5 Pembagian Data Training dan Testing.....11
2.4.6 Penanganan Missing Values dengan Imputasi Median.....12
2.5 Penerapan Metode Regresi.....12
2.5.1 Training dan Testing Model.....12
2.5.2 Evaluasi Model.....14
1. Mean Absolute Error (MAE).....14
2.6 Perancangan UI/UX.....15
3.1 Hasil Preprocessing Dataset.....17
3.1.4 Hasil Seleksi Fitur dan Target.....18
3.1.5 Hasil Pembagian Data Training dan Testing.....18
3.1.6 Hasil Penanganan Missing Value.....18
3.1.7 Hasil Validasi dan Penyimpanan Data.....19
3.2 Hasil Prediksi XGBoost.....19
3.2.1 Hasil Evaluasi Model.....20
3.2.2 Visualisasi Hasil Prediksi.....21
3.3 Hasil Prediksi LightGBM.....23
3.3.1 Hasil Evaluasi Model.....24
3.3.2 Visualisasi Hasil Prediksi.....26
3.4 Perbandingan dan Penentuan Model Terbaik.....32
3.5 Implementasi UI/UX Model Terbaik.....32
3.6 Kesimpulan dan Saran.....37

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah mendorong pemanfaatan data dalam berbagai bidang, termasuk bidang properti. Salah satu informasi yang penting dalam bidang properti adalah harga rumah. Harga rumah dapat dipengaruhi oleh berbagai faktor, seperti jumlah kamar tidur, jumlah kamar mandi, luas bangunan, luas tanah, lokasi, kondisi bangunan, serta tahun pembangunan rumah.

Penentuan harga rumah secara manual dapat menjadi sulit karena banyaknya faktor yang perlu dipertimbangkan. Oleh karena itu, diperlukan suatu metode yang dapat membantu memperkirakan harga rumah berdasarkan data yang tersedia. Salah satu pendekatan yang dapat digunakan adalah Machine Learning dengan metode regresi.

Pada penelitian ini, dilakukan penerapan algoritma XGBoost dan LightGBM untuk memprediksi harga rumah berdasarkan karakteristik rumah. Kedua algoritma tersebut merupakan metode berbasis gradient boosting yang dapat digunakan untuk menyelesaikan permasalahan regresi.

Sebelum proses pemodelan dilakukan, dataset terlebih dahulu melalui tahap data understanding dan preprocessing. Tahapan ini meliputi pemeriksaan struktur data, identifikasi missing values, pemeriksaan data duplikat, identifikasi outlier, pemilihan fitur dan target, serta pembagian data menjadi data training dan testing.

Melalui penelitian ini, diharapkan dapat dibangun model regresi yang mampu menghasilkan prediksi harga rumah dengan tingkat kesalahan yang rendah.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana melakukan data understanding dan preprocessing terhadap dataset harga rumah?
2. Bagaimana menerapkan algoritma XGBoost dan LightGBM untuk memprediksi harga rumah?
3. Bagaimana mengevaluasi performa model regresi menggunakan metrik MAE, MAPE, MSE, RMSE, dan R^2?
4. Bagaimana membandingkan performa algoritma XGBoost dan LightGBM untuk menentukan model terbaik?

1.3 Tujuan Penelitian

1. Melakukan tahapan data understanding dan preprocessing pada dataset harga rumah, yang meliputi analisis karakteristik variabel, penanganan nilai yang hilang (missing values), penyelarasan format data melalui teknik encoding, serta pembagian dataset menjadi data latih (training set) dan data uji (testing set) agar siap digunakan dalam pemodelan.
2. Menerapkan algoritma XGBoost (eXtreme Gradient Boosting) dan LightGBM (Light Gradient Boosting Machine) untuk membangun model prediktif regresi yang mampu mengestimasi nilai atau harga rumah berdasarkan fitur-fitur properti yang tersedia.
3. Mengevaluasi performa model regresi yang dihasilkan secara komprehensif menggunakan metrik evaluasi Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE), dan Coefficient of Determination (R^2).
4. Membandingkan performa antara algoritma XGBoost dan LightGBM berdasarkan tingkat akurasi prediksi, nilai kesalahan (eror), serta efisiensi waktu komputasi guna menentukan model terbaik yang paling optimal untuk prediksi harga rumah.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Manfaat bagi peneliti: menambah pemahaman dan pengalaman dalam menerapkan tahapan Machine Learning, khususnya pada permasalahan regresi.
2. Manfaat bagi pengguna: memberikan gambaran mengenai pemanfaatan Machine Learning untuk memperkirakan harga rumah berdasarkan karakteristik properti.
3. Manfaat akademis: menjadi bahan pembelajaran mengenai data preprocessing, penerapan algoritma regresi, dan evaluasi performa model Machine Learning.

1.5 Batasan Masalah

Agar penelitian ini lebih terarah dan tidak menyimpang dari tujuan yang telah ditentukan, batasan masalah dalam penelitian ini adalah :

1. Dataset yang digunakan merupakan dataset harga rumah dalam format CSV dengan nama file kc_house_data_NaN.csv.
2. Variabel target yang digunakan untuk proses predikasi adalah price, yaitu harga rumah.
3. Variabel prediktor yang digunakan terdiri dari 18 fitur yang menggambarkan karakteristik rumah, seperti jumlah kamar tidur, jumlah kamar mandi, luas bangunan, luas tanah, kondisi rumah, serta informasi lokasi.
4. Tahapan preprocessing meliputi pemeriksaan struktur dataset, pemeriksaan missing values, pemeriksaan data duplikat, identifikasi outlier, penghapusan kolom yang tidak digunakan, penentuan fitur dan target, serta penanganan missing values.
5. Missing values ditangani menggunakan metode median imputation.
6. Pembagian dataset dilakukan menggunakan perbandingan 80% data training 20% data testing.

7. Metode regresi yang digunakan dalam penelitian ini adalah XGBoost Regressor dan LightGBM Regressor.
8. Evaluasi performa model menggunakan MAE, MAPE, MSE, RMSE, dan R-Squared.

BAB II
METODOLOGI PENELITIAN

2.1 Alur Penelitian

Penelitian ini dilakukan melalui beberapa tahapan yang saling berhubungan, mulai dari pengumpulan dataset hingga evaluasi model. Tahapan penelitian yang dilakukan adalah sebagai berikut:

1. **Pengumpulan Dataset**
   Dataset harga rumah diperoleh dalam bentuk file CSV dengan nama kc_house_data_NaN.csv. Dataset tersebut digunakan sebagai sumber data untuk proses penelitian.
2. **Data Understanding**
   Tahap ini dilakukan untuk memahami karakteristik dataset melalui pemeriksaan jumlah baris dan kolom, tipe data, statistik deskriptif, serta kondisi data.
3. **Exploratory Data Analysis (EDA)**
   EDA dilakukan untuk mengetahui distribusi data dan hubungan antarvariabel. Pada tahap ini digunakan visualisasi berupa histogram, boxplot, dan heatmap korelasi.
4. **Data Preprocessing**
   Tahap preprocessing meliputi pemeriksaan missing values, pemeriksaan data duplikat, identifikasi outlier, penghapusan kolom yang tidak digunakan, serta penentuan fitur dan target.
5. **Pembagian Data**
   Dataset dibagi menjadi data training sebesar 80% dan data testing sebesar 20%. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk mengevaluasi hasil prediksi.
6. **Pemodelan Machine Learning**
   Data hasil preprocessing digunakan oleh anggota kelompok untuk membangun model menggunakan algoritma XGBoost dan LightGBM.
7. **Evaluasi dan Perbandingan Model**
   Model dievaluasi menggunakan MAE, MAPE, MSE, RMSE, dan R^2. Hasil evaluasi kemudian dibandingkan untuk menentukan model terbaik.

2.2 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah dataset *House Sales*, yaitu dataset yang berisi informasi mengenai karakteristik properti dan harga jual rumah. Dataset tersebut digunakan untuk membangun model regresi yang bertujuan memprediksi harga rumah berdasarkan berbagai atribut yang tersedia.

File dataset yang digunakan dalam penelitian ini bernama kc_house_data_NaN.csv. Dataset awal memiliki 21.613 baris data dan 22 kolom, yang terdiri atas atribut karakteristik rumah serta atribut harga sebagai variabel target.

Sebelum digunakan dalam proses pemodelan, dataset diperiksa untuk mengetahui struktur data, tipe data, jumlah nilai kosong (*missing value*), dan karakteristik setiap atribut. Pemeriksaan ini dilakukan agar data yang digunakan sesuai dengan kebutuhan proses analisis dan pemodelan regresi.

Pada tahap persiapan data, beberapa kolom yang tidak digunakan dalam pemodelan, yaitu Unnamed: 0, id, dan date, dihapus. Setelah proses tersebut, diperoleh 18 atribut fitur dan satu variabel target, yaitu price.
Variabel target price merupakan harga rumah yang akan diprediksi oleh model, sedangkan atribut lainnya digunakan sebagai variabel input untuk membantu model mempelajari hubungan antara karakteristik rumah dan harga jualnya.

2.3 Metode Regresi yang Digunakan

2.3.1 XGBoost Regressor

Regresi adalah teknik *supervised learning* untuk memprediksi nilai kontinu dari satu atau beberapa fitur. Pada penelitian ini, nilai yang diprediksi adalah harga rumah (`price`). Salah satu pendekatannya adalah *ensemble learning*, yaitu menggabungkan banyak model lemah, umumnya pohon keputusan (*decision tree*), menjadi satu model yang lebih kuat dan presisi (Modul TM11 Regresi).

Gradient Boosting membangun pohon secara berurutan, di mana setiap pohon baru memperbaiki kesalahan (residu) pohon sebelumnya menggunakan *gradient descent* pada fungsi kerugian. *XGBoost* (*Extreme Gradient Boosting*) adalah implementasi Gradient Boosting yang telah dioptimasi (Chen & Guestrin, 2016) dengan tiga keunggulan utama, yaitu regularisasi L1 dan L2 untuk mencegah *overfitting*, komputasi paralel yang cepat, dan penanganan *missing value* secara otomatis. Prediksi XGBoost merupakan penjumlahan keluaran dari *K* pohon (Persamaan 2.1).

$$\hat{y}_i = \Sigma_{k=1,\ldots,K} f_k(x_i) \tag{2.1}$$

dengan ŷ adalah harga prediksi dan *f* adalah pohon keputusan. Setiap pohon dilatih untuk meminimalkan fungsi kerugian ditambah penalti kompleksitas (regularisasi) agar model tidak terlalu rumit. Karakteristik XGBoost menurut modul TM11 dirangkum pada Tabel 2.1.

Tabel 2.1 Karakteristik XGBoost Regressor

Karakteristik	XGBoost
Pendekatan utama	Gradient Boosting teroptimasi dengan regularisasi
Pertumbuhan pohon	*Level-wise* / *depth-wise* (melebar per level)
Kecepatan dan efisiensi	Sangat cepat dan efisien dalam memori
Pencegahan *overfitting*	Regularisasi L1 (Lasso) dan L2 (Ridge) bawaan
Penanganan *missing value*	Otomatis secara internal
Skala data ideal	Data tabular sedang hingga besar

Dataset penelitian berupa data tabular berukuran sedang (21.613 baris, 18 fitur numerik) sehingga sesuai dengan skala data ideal XGBoost. Pada Python digunakan kelas `XGBRegressor` dari pustaka `xgboost` yang dilatih dengan `.fit()` dan digunakan memprediksi dengan `.predict()`, sesuai alur modul TM11. Meskipun XGBoost dapat menangani *missing value*, data telah diimputasi dengan median pada tahap *preprocessing* (subbab 2.4.6) agar XGBoost dan LightGBM memakai data yang identik.

2.3.2 LightGBM Regressor

LightGBM (*Light Gradient Boosting Machine*) adalah kerangka kerja *gradient boosting* berbasis pohon keputusan (*decision tree*) yang dirancang untuk meningkatkan efisiensi komputasi dan menekan penggunaan memori pada dataset berukuran menengah hingga besar (Ke et al., 2017). Serupa dengan XGBoost, LightGBM membangun sejumlah pohon keputusan secara berurutan di mana setiap pohon baru dilatih untuk meminimalkan residu dari kumpulan pohon sebelumnya. Perbedaan utama antara LightGBM dan algoritma *gradient boosting* konvensional terletak pada arah pertumbuhan struktur pohon serta teknik pemindaian titik pemisahan data (*split finding*).

Apabila XGBoost pada konfigurasi bawaan menumbuhkan pohon secara *level-wise* (*depth-wise*) dengan memecah seluruh simpul pada tingkat kedalaman yang sama secara serentak, LightGBM menerapkan strategi pertumbuhan *leaf-wise* (*best-first*). Pada pendekatan *leaf-wise*, algoritma mencari satu simpul daun (*leaf*) dari seluruh daun yang tersedia yang menghasilkan penurunan fungsi kerugian (*loss reduction* atau *split gain*) paling besar, kemudian hanya memecah simpul daun tersebut. Strategi ini menghasilkan struktur pohon yang tidak simetris, tetapi mampu menurunkan kesalahan prediksi lebih cepat dengan jumlah iterasi yang setara. Untuk mencegah pohon tumbuh terlalu dalam dan memicu *overfitting* pada data berukuran sedang, kompleksitas pohon dikendalikan secara langsung melalui parameter batas jumlah daun maksimum (`num_leaves`) dan jumlah sampel minimum pada setiap daun (`min_child_samples`).

Selain strategi pertumbuhan *leaf-wise*, LightGBM menggunakan algoritma berbasis histogram (*histogram-based algorithm*) yang mengelompokkan nilai fitur kontinu ke dalam sejumlah keranjang diskrit (*bins*). Pendekatan ini memangkas kompleksitas komputasi pencarian titik potong dari $O(\#data \times \#fitur)$ menjadi $O(\#bins \times \#fitur)$. Efisiensi tersebut didukung oleh dua mekanisme utama dalam arsitektur LightGBM:

1. Gradient-based One-Side Sampling (GOSS): Mempertahankan seluruh baris data yang memiliki gradien atau residu besar karena baris tersebut belum terpelajari dengan baik, serta mengambil sampel acak hanya pada sebagian baris data yang memiliki gradien kecil. Dengan cara ini, perhitungan *information gain* tetap akurat tanpa harus memindai seluruh baris data pada setiap pembentukan cabang.

2. Exclusive Feature Bundling (EFB): Menggabungkan fitur-fitur yang bersifat *mutually exclusive* (jarang memiliki nilai bukan nol secara bersamaan) ke dalam satu bundel fitur tunggal sehingga jumlah fitur efektif yang perlu dipindai menjadi lebih sedikit tanpa menghilangkan informasi asli.

Pada permasalahan regresi harga rumah, setiap pohon keputusan dalam LightGBM dilatih untuk meminimalkan fungsi kerugian *Mean Squared Error* (L2 *loss*) yang disertai penalti regularisasi L1 (`reg_alpha`) dan L2 (`reg_lambda`), sebagaimana ditunjukkan pada Persamaan 2.2:

$$L = \Sigma\,(yi - \hat{y}i)^2 + \alpha\,\Sigma\,|wk| + \tfrac{1}{2}\,\lambda\,\Sigma\,wk^2 \qquad \textit{(Persamaan 2.2)}$$

dengan yi adalah harga rumah aktual pada data ke-i, $\hat{y}i$ adalah harga rumah hasil prediksi dari akumulasi K pohon keputusan, wk adalah bobot keluaran pada daun pohon ke-k, serta α dan λ

masing-masing merupakan parameter penalti regularisasi L1 dan L2. Karakteristik LightGBM Regressor dirangkum pada Tabel 2.2.

Tabel 2.2 Karakteristik LightGBM Regressor

Karakteristik	LightGBM
Pendekatan utama	Gradient Boosting berbasis histogram dengan optimasi GOSS dan EFB
Pertumbuhan pohon	Leaf-wise / best-first (memecah daun dengan penurunan loss terbesar)
Kecepatan dan efisiensi	Komputasi sangat cepat dan hemat memori melalui diskritisasi bin
Pencegahan overfitting	Pengaturan num_leaves, min_child_samples, serta regularisasi L1 dan L2
Penanganan missing value	Otomatis mengalokasikan nilai kosong ke cabang dengan gain terbesar
Skala data ideal	Data tabular berukuran menengah hingga besar (puluhan ribu baris ke atas)

Dataset penelitian yang telah melalui tahapan *preprocessing* terdiri atas 17.290 baris data latih dan 4.323 baris data uji dengan 18 fitur numerik, sehingga sesuai dengan karakteristik kerja LightGBM. Pada Python digunakan kelas `LGBMRegressor` dari pustaka `lightgbm` yang dilatih menggunakan metode `.fit()` dan diuji menggunakan metode `.predict()`. Sama seperti pada pengujian XGBoost, nilai kosong pada dataset telah diimputasi menggunakan nilai median pada tahap *preprocessing* (Subbab 2.4.6) agar kedua algoritma diuji pada matriks data yang identik.

2.4 Tahapan Preprocessing Data

Preprocessing merupakan tahapan pengolahan data yang dilakukan sebelum proses pemodelan. Tahapan ini bertujuan untuk memastikan bahwa dataset memiliki kualitas dan struktur yang sesuai sehingga dapat digunakan oleh algoritma regresi.

Pada penelitian ini, preprocessing dilakukan menggunakan bahasa pemrograman Python dengan bantuan library Pandas, NumPy, dan Scikit-learn. Proses preprocessing meliputi penghapusan kolom yang tidak diperlukan, pemeriksaan data duplikat, penanganan missing value, analisis outlier, pemisahan fitur dan target, serta pembagian dataset menjadi data training dan testing.

2.4.1 Pemeriksaan Struktur Dataset

Tahapan pertama dilakukan dengan membaca dataset dan memeriksa jumlah baris, jumlah kolom, tipe data, serta beberapa sampel data. Hasil pemeriksaan menunjukkan bahwa dataset memiliki 21.613 baris dan 22 kolom.

```
df = pd.read_csv(RAW_PATH)

print(f"Lokasi dataset : {RAW_PATH}")
print(f"Ukuran dataset : {df.shape[0]:,} baris x {df.shape[1]} kolom")

print("\n5 data pertama:")
print(df.head())

print("\nInformasi tipe data:")
df.info()
```

Gambar 2.1 Struktur Dataset

2.4.2 Pemeriksaan Missing Values dan Data Duplikat

Pemeriksaan missing value dilakukan untuk mengetahui jumlah nilai kosong pada setiap atribut. Berdasarkan hasil pemeriksaan awal, ditemukan 13 missing value pada atribut bedrooms dan 10 missing value pada atribut bathrooms, sehingga total missing value berjumlah 23.

Selain itu, dilakukan pemeriksaan data duplikat untuk mengetahui apakah terdapat baris data yang memiliki isi sama. Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki data duplikat.

```
missing_values = df.isnull().sum()
print(missing_values[missing_values > 0].sort_values(ascending=False))

# Memeriksa dan menangani data duplikat
jumlah_duplikat = int(df.duplicated().sum())

print(f"\nJumlah baris duplikat: {jumlah_duplikat:,}")
```

Gambar 2.2 Pemeriksaan Missing Values dan Data Duplikat

2.4.3 Analisis Outlier

Analisis outlier dilakukan untuk mengidentifikasi nilai ekstrem pada beberapa atribut numerik. Metode yang digunakan adalah Interquartile Range (IQR), yaitu metode yang menentukan batas bawah dan batas atas berdasarkan kuartil pertama (Q1) dan kuartil ketiga (Q3).

Pada penelitian ini, outlier dianalisis dan dicatat sebagai bagian dari pemeriksaan karakteristik dataset, tetapi tidak dihapus. Hal ini dilakukan agar informasi yang terdapat pada data tetap dipertahankan.

```python
q1 = df[column].quantile(0.25)
q3 = df[column].quantile(0.75)

iqr = q3 - q1

lower_bound = q1 - 1.5 * iqr
upper_bound = q3 + 1.5 * iqr

mask = (
    (df[column] < lower_bound) |
    (df[column] > upper_bound)
)

outlier_rows.append({
    "kolom": column,
    "Q1": q1,
    "Q3": q3,
    "IQR": iqr,
    "batas_bawah": lower_bound,
    "batas_atas": upper_bound,
    "jumlah_outlier": int(mask.sum()),
    "persentase_outlier": float(mask.mean() * 100)
})
```

Gambar 2.3 Analisis Outlier

2.4.4 Pemisahan Fitur dan Target

Setelah proses pemeriksaan data, dilakukan pemisahan antara variabel fitur dan variabel target. Sebanyak 18 atribut digunakan sebagai fitur atau variabel input, sedangkan atribut price digunakan sebagai target atau variabel yang akan diprediksi.

```python
X = df_model.drop(
    columns=[TARGET]
)

y = df_model[TARGET].copy()

# Memastikan seluruh fitur bersifat numerik
non_numeric_columns = X.select_dtypes(
    exclude=np.number
).columns.tolist()

if non_numeric_columns:
    raise ValueError(
        "Terdapat fitur non-numerik yang perlu ditangani: "
        f"{non_numeric_columns}"
    )
```

Gambar 2.4 Pemisahan fitur dan target serta pembagian data

2.4.5 Pembagian Data Training dan Testing

Dataset kemudian dibagi menjadi data training dan data testing dengan perbandingan 80:20. Data training digunakan untuk melatih model regresi, sedangkan data testing digunakan untuk menguji kemampuan model dalam memprediksi data yang belum pernah

digunakan selama proses pelatihan. Pembagian data dilakukan menggunakan fungsi train_test_split dari Scikit-learn dengan nilai random_state=42 agar pembagian data dapat direproduksi.

```
X_train_raw, X_test_raw, y_train, y_test = train_test_split(
    X,
    y,
    test_size=TEST_SIZE,
    random_state=RANDOM_STATE
)
```

Gambar 2.5 Pembagian Data Training dan Testing

2.4.6 Penanganan Missing Values dengan Imputasi Median

Penanganan missing value dilakukan menggunakan metode imputasi median melalui SimpleImputer. Median dipilih karena relatif tidak sensitif terhadap nilai ekstrem dibandingkan rata-rata.

Proses imputasi dilakukan setelah pembagian data. Nilai median dihitung berdasarkan data training, kemudian diterapkan pada data training dan data testing. Dengan demikian, informasi dari data testing tidak digunakan untuk menentukan nilai imputasi selama proses pelatihan.

Setelah seluruh tahapan preprocessing selesai, diperoleh 17.290 data training dan 4.323 data testing dengan masing-masing 18 atribut fitur. Hasil preprocessing kemudian disimpan dalam bentuk file CSV untuk digunakan pada tahap pemodelan regresi.

```
imputer = SimpleImputer(strategy="median")

X_train = pd.DataFrame(
    imputer.fit_transform(X_train_raw),
    columns=X_train_raw.columns,
    index=X_train_raw.index
)

X_test = pd.DataFrame(
    imputer.transform(X_test_raw),
    columns=X_test_raw.columns,
    index=X_test_raw.index
)
```

Gambar 2.6 Penanganan Missing Values

2.5 Penerapan Metode Regresi

2.5.1 Training dan Testing Model

Alur regresi pada modul TM11 diterapkan pada berkas `02_xgboost.py` dalam lima tahap berikut.

1. **Persiapan data.** Memuat `X_train.csv`, `X_test.csv`, `y_train.csv`, dan `y_test.csv` dari folder `data/processed/` hasil `01_preprocessing.py` (18 fitur, target `price`).
2. **Pembagian data.** 80% data latih (17.290) dan 20% data uji (4.323) dengan `random_state=42`, dilakukan pada subbab 2.4.5 dan dipakai sama oleh LightGBM.

3. **Training** model `XGBRegressor` dengan `.fit()`.
4. **Testing** dengan `.predict()` pada data uji dan data latih, lalu menghitung MAE, MAPE, RMSE, MSE, dan R^2 (rumus pada subbab 2.5.2).
5. **Visualisasi** hasil prediksi serta penyimpanan model dan hasil evaluasi.

Konfigurasi dan proses training

Hiperparameter pada Tabel 2.2 ditetapkan secara manual sebagai model dasar (*baseline*) dan belum melalui *hyperparameter tuning*. Proses *training* dilakukan dengan `model.fit(X_train, y_train)`, yaitu membangun 600 pohon secara berurutan pada data latih.

Tabel 2.x Hiperparameter XGBoost Regressor

Parameter	Nilai	Fungsi
`n_estimators`	600	Jumlah pohon (*boosting rounds*)
`learning_rate`	0.05	Pengecil kontribusi tiap pohon
`max_depth`	6	Kedalaman maksimum pohon
`min_child_weight`	3	Bobot minimum simpul anak (semakin besar, semakin konservatif)
`subsample`	0.8	Proporsi baris data per pohon
`colsample_bytree`	0.8	Proporsi fitur per pohon
`reg_alpha` / `reg_lambda`	0.1 / 1.0	Regularisasi L1 / L2
`objective`	reg:squarederror	Fungsi kerugian kuadrat untuk regresi
`tree_method`	hist	Algoritma berbasis histogram (lebih cepat)
`random_state`, `n_jobs`	42, -1	Hasil dapat direproduksi; memakai semua inti prosesor

```
model = XGBRegressor(
    n_estimators=600,
    learning_rate=0.05,
    max_depth=6,
    min_child_weight=3,
    subsample=0.8,
    colsample_bytree=0.8,
    reg_alpha=0.1,
    reg_lambda=1.0,
    objective="reg:squarederror",
    tree_method="hist",
    random_state=RANDOM_STATE,
    n_jobs=-1,
)
print("\n[TRAINING] Melatih XGBoost Regressor ...")
t0 = time.time()
model.fit(X_train, y_train)
waktu_latih = time.time() - t0
print(f"[TRAINING] Selesai dalam {waktu_latih:.2f} detik")


y_pred_train = model.predict(X_train)
y_pred = model.predict(X_test)
```

Gambar 2.7 Kode Pembangunan, Training, dan Testing Model XGBoost

```
[TRAINING] Melatih XGBoost Regressor ...
[TRAINING] Selesai dalam 3.74 detik
```

Gambar 2.8 Proses Training Model XGBoost

Proses testing dan penyimpanan hasil

Pada tahap *testing*, `model.predict(X_test)` menghasilkan harga prediksi yang dibandingkan dengan harga aktual pada fungsi `hitung_metrik()`. MAE, MSE, dan R^2 dihitung dengan fungsi Scikit-learn, RMSE adalah akar kuadrat MSE, dan MAPE dihitung dengan NumPy sebagai rata-rata persentase kesalahan absolut. Evaluasi juga dilakukan pada data latih untuk mengamati kemungkinan *overfitting*. Skrip lalu menyimpan model (`models/xgboost_model.pkl`), metrik (`results/xgboost_metrics.json`), prediksi (`results/xgboost_predictions.csv`), dan empat grafik (`results/xgboost_*.png`).

Eksperimen dijalankan dengan Python 3.14, `xgboost` 3.4.1, `scikit-learn` 1.9.1, `pandas` 3.0.5, dan `numpy` 2.5.3.

2.5.2 Evaluasi Model

Evaluasi model merupakan tahapan yang dilakukan untuk mengetahui tingkat kemampuan model regresi dalam menghasilkan prediksi yang mendekati nilai sebenarnya. Pada penelitian ini, evaluasi dilakukan terhadap model XGBoost dan LightGBM menggunakan lima metrik, yaitu Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE), dan koefisien determinasi (R^2).

Penggunaan beberapa metrik evaluasi bertujuan untuk memberikan gambaran yang lebih menyeluruh mengenai tingkat kesalahan prediksi dan kemampuan model dalam menjelaskan variasi harga rumah.

1. **Mean Absolute Error (MAE)**

Mean Absolute Error (MAE) merupakan metrik yang digunakan untuk menghitung rata-rata nilai kesalahan absolut antara harga rumah sebenarnya dengan harga rumah hasil prediksi. Semakin kecil nilai MAE, semakin baik kemampuan model dalam melakukan prediksi.

2. **Mean Absolute Percentage Error (MAPE)**

Mean Absolute Percentage Error (MAPE) merupakan metrik yang digunakan untuk mengukur rata-rata persentase kesalahan absolut antara nilai aktual dan nilai prediksi. Nilai MAPE dinyatakan dalam bentuk persentase. Semakin kecil nilai MAPE, semakin baik hasil prediksi model.

3. **Mean Squared Error (MSE)**

Mean Squared Error (MSE) merupakan metrik yang menghitung rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. Metrik ini memberikan penalti lebih besar terhadap kesalahan prediksi yang bernilai besar.

4. **Root Mean Squared Error (RMSE)**

Root Mean Squared Error (RMSE) merupakan akar kuadrat dari nilai MSE. Metrik ini digunakan untuk mengetahui besarnya rata-rata kesalahan prediksi dalam satuan yang sama dengan variabel target, yaitu harga rumah.

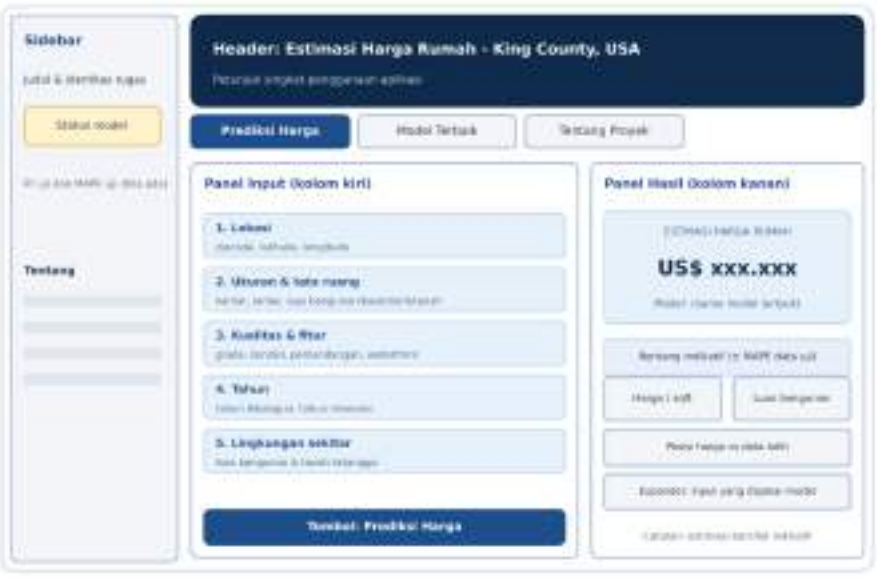
5. **R-Squared (R^2)**

R-squared (R^2) merupakan metrik yang digunakan untuk mengukur seberapa besar variasi pada variabel target dapat dijelaskan oleh model regresi. Nilai R^2 yang semakin mendekati 1 menunjukkan bahwa model mampu menjelaskan variasi data dengan lebih baik.

2.6 Perancangan UI/UX

Berdasarkan modul TM11, *User Interface* (UI) adalah tampilan visual yang memungkinkan pengguna memasukkan variabel input secara intuitif, sedangkan *User Experience* (UX) adalah pengalaman pengguna agar proses prediksi berjalan lancar, mudah dipahami, dan hasilnya informatif. Antarmuka dibangun dengan Streamlit, yaitu pustaka Python untuk membuat aplikasi web interaktif langsung dari kode Python, dan dirancang dari model dengan performa terbaik hasil perbandingan XGBoost dan LightGBM. Pengguna yang dituju adalah pihak yang ingin memperoleh perkiraan harga rumah tanpa perlu memahami proses pemodelan.

Aplikasi berlayout lebar dengan bilah samping (identitas tugas dan status model), bagian kepala (judul dan status model), serta tiga tab: **Prediksi Harga** (panel input di kiri, panel hasil di kanan), **Model Terbaik** (algoritma, hiperparameter, metrik, perbandingan model, dan grafik), dan **Tentang Proyek** (alur proyek dan penjelasan fitur). Rancangannya ditunjukkan pada Gambar 2.9, dan pemetaan fitur ke komponen input pada Tabel 2.3.



Gambar 2.9 Rancangan Tata Letak (Wireframe) Aplikasi Estimasi Harga Rumah

Tabel 2.3 Pemetaan Fitur Model ke Komponen Input

Kelompok	Fitur model	Komponen input
Lokasi	`zipcode`, `lat`, `long`	Pilihan kode pos; latitude dan longitude terisi otomatis dari kode pos, boleh diubah
Ukuran dan tata ruang	`bedrooms`, `bathrooms`, `floors`, `sqft_living`, `sqft_basement`, `sqft_lot`	Kolom angka dengan batas rentang
	`sqft_above`	Dihitung otomatis (`sqft_living` − `sqft_basement`)

Kelompok	Fitur model	Komponen input
Kualitas dan fitur	`grade`	*Slider* 1 sampai 13
	`condition`, `view`	*Select slider* berlabel (1 sampai 5; 0 sampai 4)
	`waterfront`	*Toggle* (0 atau 1)
Tahun	`yr_built`, `yr_renovated`	Kolom angka (0 = belum direnovasi)
Lingkungan sekitar	`sqft_living15`, `sqft_lot15`	Kolom angka

Alur kerja dan integrasi

1. Aplikasi memuat `models/best_model.pkl` (hasil `04_compare_models.py`) dengan `joblib` dan menyimpannya pada *cache*.
2. Nama dan urutan fitur diambil langsung dari model sehingga selalu cocok dengan data latih. Metrik dibaca dari `models/best_model_info.json` atau `results/<model>_metrics.json`.
3. Pengguna mengisi formulir, lalu input disusun menjadi `DataFrame` satu baris sesuai urutan fitur model.
4. Tombol **Prediksi Harga** memanggil `model.predict()`, dan hasilnya ditampilkan dalam USD bersama informasi pendukung.

Dengan rancangan ini, aplikasi kompatibel dengan model XGBoost maupun LightGBM tanpa perubahan kode, apa pun model yang dipilih sebagai model terbaik.

BAB III
HASIL DAN PEMBAHASAN

3.1 Hasil Preprocessing Dataset

Tahap data preparation dilakukan untuk mempersiapkan dataset sebelum digunakan dalam proses pemodelan regresi. Proses ini meliputi pemeriksaan dataset, penanganan missing value, pemeriksaan data duplikat, analisis outlier, pemisahan fitur dan target, pembagian data training dan testing, serta imputasi missing value.

3.1.1 Hasil Pemeriksaan Dataset

Dataset yang digunakan merupakan dataset House Sales yang disimpan dalam file kc_house_data_NaN.csv. Dataset memiliki 21.613 baris dan 22 kolom sebelum dilakukan preprocessing. Pemeriksaan awal dilakukan untuk mengetahui ukuran dataset, struktur kolom, tipe data, dan beberapa contoh data.



Gambar 3.1 Hasil Dataset

3.1.2 Hasil Pemeriksaan Missing Value dan Data Duplikat

Pemeriksaan missing value dilakukan untuk mengetahui jumlah data kosong pada setiap kolom. Hasil pemeriksaan menunjukkan terdapat 13 missing value pada kolom bedrooms dan 10 missing value pada kolom bathrooms, sehingga total terdapat 23 missing value. Selain itu, dilakukan pemeriksaan data duplikat. Hasilnya menunjukkan tidak ditemukan data duplikat pada dataset.

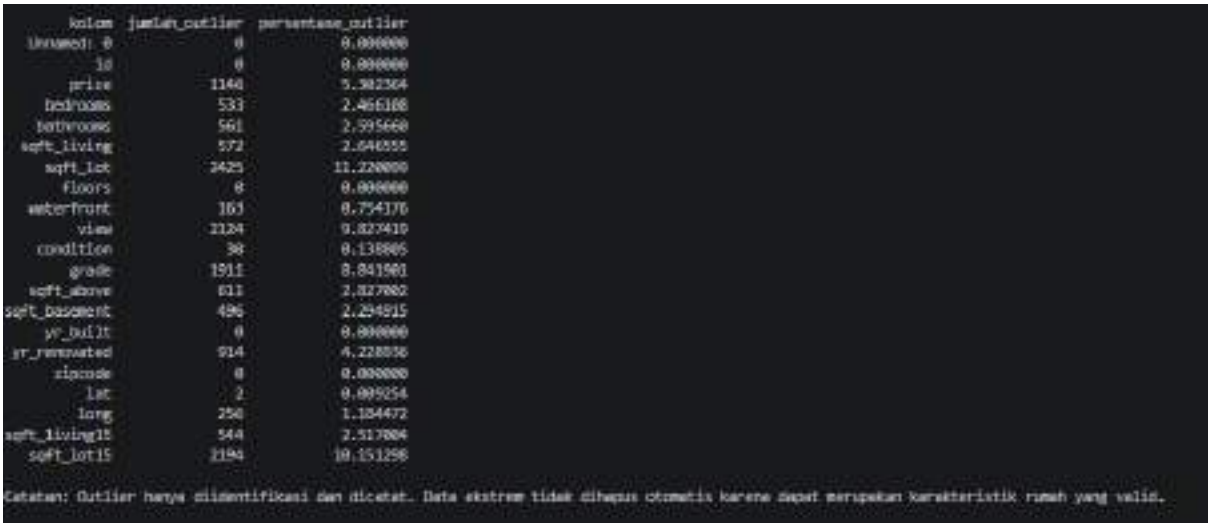
```
Jumlah missing values setiap kolom:
bedrooms     13
bathrooms    10
dtype: int64

Jumlah baris duplikat: 0
Tidak ditemukan data duplikat.
```

Gambar 3.2 Hasil Pemeriksaan Missing Value dan Data Duplikat

3.1.3 Hasil Analisis Outlier

Analisis outlier dilakukan menggunakan metode Interquartile Range (IQR). Metode ini digunakan untuk mengidentifikasi data yang berada di luar batas bawah dan batas atas berdasarkan kuartil pertama (Q1) dan kuartil ketiga (Q3). Hasil analisis disimpan dalam file outlier_summary.csv. Pada tahap ini, outlier hanya diidentifikasi dan dicatat, tidak dihapus secara otomatis dari dataset.



kolom	jumlah_outlier	persentase_outlier
Unnamed: 0	0	0.000000
id	0	0.000000
price	1146	5.302364
bedrooms	533	2.466108
bathrooms	561	2.595660
sqft_living	572	2.646555
sqft_lot	3425	11.220000
floors	0	0.000000
waterfront	163	0.754176
view	2124	9.827410
condition	30	0.138805
grade	1911	8.841901
sqft_above	611	2.827002
sqft_basement	496	2.294915
yr_built	0	0.000000
yr_renovated	914	4.228856
zipcode	0	0.000000
lat	2	0.009254
long	256	1.184472
sqft_living15	544	2.517004
sqft_lot15	2194	10.151298

Catatan: Outlier hanya diidentifikasi dan dicatat. Data ekstrem tidak dihapus otomatis karena dapat merupakan karakteristik rumah yang valid.

Gambar 3.3 Hasil Analisis Outlier Menggunakan Metode IQR

3.1.4 Hasil Seleksi Fitur dan Target

Pada tahap ini dilakukan seleksi fitur untuk menentukan variabel yang digunakan dalam proses pemodelan regresi. Kolom Unnamed: 0, id, dan date dihapus karena tidak digunakan sebagai fitur dalam proses prediksi.

Selanjutnya, dataset dipisahkan menjadi variabel fitur (X) dan variabel target (y). Variabel fitur terdiri dari 18 kolom yang digunakan sebagai dasar prediksi, sedangkan variabel target adalah kolom price yang menunjukkan harga rumah.

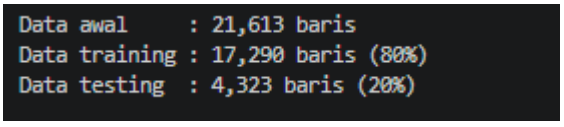


Gambar 3.4 Hasil Seleksi Fitur dan Target

3.1.5 Hasil Pembagian Data Training dan Testing.

Setelah proses seleksi fitur dan target selesai, tahap selanjutnya adalah membagi dataset menjadi data training dan data testing. Pembagian data dilakukan menggunakan fungsi train_test_split dari library Scikit-learn dengan rasio 80:20.

Sebanyak 80% data digunakan untuk melatih model regresi, sedangkan 20% sisanya digunakan untuk menguji kemampuan model dalam melakukan prediksi terhadap data yang belum pernah dipelajari. Pembagian data menggunakan parameter random_state=42 agar hasil pembagian tetap konsisten ketika program dijalankan kembali.



Gambar 3.5 Hasil Pembagian Data Training dan Testing

3.1.6 Hasil Penanganan Missing Value.

Setelah data dibagi menjadi data training dan data testing, tahap selanjutnya adalah menangani missing value atau data kosong yang terdapat pada variabel fitur. Penanganan missing value dilakukan menggunakan metode imputasi median dengan bantuan fungsi

SimpleImputer dari library Scikit-learn. Metode median dipilih karena dapat mengisi nilai kosong berdasarkan nilai tengah dari masing-masing kolom numerik.

Proses imputasi dilakukan dengan menyesuaikan nilai median berdasarkan data training. Selanjutnya, nilai median tersebut diterapkan pada data training dan data testing agar tidak terjadi kebocoran informasi (data leakage).

```
Missing values pada data training sebelum imputasi:
bedrooms     8
bathrooms    7
dtype: int64

Missing values setelah imputasi:
Training: 0
Testing : 0
```

Gambar 3.6 Hasil Penanganan Missing Value

3.1.7 Hasil Validasi dan Penyimpanan Data

Setelah proses preprocessing selesai, dilakukan tahap validasi untuk memastikan bahwa dataset telah siap digunakan dalam proses pemodelan regresi. Validasi dilakukan dengan memeriksa beberapa kondisi, yaitu tidak terdapat missing value pada data training dan testing, tidak terdapat missing value pada variabel target, jumlah baris fitur dan target sesuai, serta seluruh nilai pada dataset merupakan nilai yang valid.

```
Validasi missing values : LULUS
Validasi jumlah data    : LULUS
Validasi nama fitur     : LULUS
Validasi nilai numerik  : LULUS
```

Gambar 3.7 Hasil Validasi

Setelah seluruh pemeriksaan berhasil dilewati, data hasil preprocessing disimpan ke dalam folder data/processed/ agar dapat digunakan pada tahap pembangunan model regresi.

```
X_train : (17290, 18)
X_test  : (4323, 18)
y_train : (17290,)
y_test  : (4323,)

Jumlah fitur: 18

File preprocessing berhasil disimpan di:
C:\ML_kelmpok\ML_KELOMPOK10\regresi\data\processed
```

Gambar 3.8 Hasil Penyimpanan Data

3.2 Hasil Prediksi XGBoost

Model XGBoost dilatih pada 17.290 data latih dan diuji pada 4.323 data uji dengan 18 fitur. Proses *training* berlangsung sekitar 3,7 detik. Harga aktual pada data uji berkisar dari US$82.500 hingga US$5.570.000 dengan median US$455.000. Tabel 3.1 menampilkan lima prediksi pertama sebagai contoh; selisih dihitung sebagai harga aktual dikurangi harga prediksi sehingga nilai negatif berarti model memprediksi lebih tinggi.

Tabel 3.1 Contoh Hasil Prediksi XGBoost pada Data Uji

No.	Harga aktual	Harga prediksi	Selisih	Galat relatif
1	US$365.000	US$389.909	−US$24.909	6,82%
2	US$865.000	US$908.076	−US$43.076	4,98%
3	US$1.038.000	US$1.098.002	−US$60.002	5,78%
4	US$1.490.000	US$1.901.065	−US$411.065	27,59%
5	US$711.000	US$795.322	−US$84.322	11,86%

Pada lima contoh tersebut galat relatif berkisar 4,98% hingga 27,59%. Contoh nomor 1 sama dengan baris `[CONTOH]` pada keluaran terminal. Kinerja keseluruhan model diukur pada subbab 3.2.1 menggunakan seluruh data uji.

3.2.1 Hasil Evaluasi Model

Evaluasi memakai lima metrik pada data latih dan data uji (Tabel 3.2). Keluaran terminalnya ditunjukkan pada Gambar 3.9.

```
=== Evaluasi Data LATIH (training) ===
Mean Absolute Error (MAE)           : 39,508.65
Mean Absolute Percentage Error (MAPE): 8.83%
Root Mean Squared Error (RMSE)      : 55,624.05
Mean Squared Error (MSE)            : 3,094,034,701.39
R2 Score                            : 0.9763

=== Evaluasi Data UJI (testing) ===
Mean Absolute Error (MAE)           : 66,979.96
Mean Absolute Percentage Error (MAPE): 12.23%
Root Mean Squared Error (RMSE)      : 142,928.44
Mean Squared Error (MSE)            : 20,428,538,317.50
R2 Score                            : 0.8649

[CONTOH] Rumah uji ke-1 -> aktual: $365,000 | prediksi: $389,909
```

Gambar 3.9 Hasil Evaluasi Model XGBoost pada Terminal

Tabel 3.2 Hasil Evaluasi Model XGBoost

Metrik	Data latih (17.290)	Data uji (4.323)
MAE	US$39.508,65	US$66.979,96
MAPE	8,83%	12,23%
RMSE	US$55.624,05	US$142.928,44
MSE	US$3.094.034.701,39	US$20.428.538.317,50
R^2	0,9763	0,8649

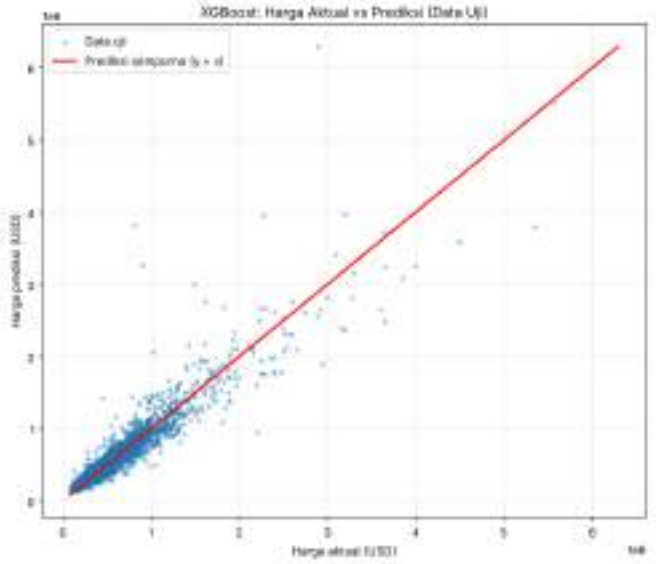
- **MAE US$66.979,96** atau sekitar 12,5% dari rata-rata harga data latih (US$537.768,05).
- **MAPE 12,23%**: rata-rata penyimpangan harga prediksi terhadap harga aktual.
- **RMSE US$142.928,44** bernilai 2,13 kali MAE, menandakan sebagian kecil prediksi memiliki kesalahan sangat besar. Kesalahan terbesar terjadi pada rumah berharga sangat tinggi.
- **R^2 0,8649**: model menjelaskan sekitar 86,49% variasi harga pada data uji.

R^2 data latih (0,9763) lebih tinggi daripada data uji (0,8649) dan MAPE data uji lebih tinggi 3,40 poin persentase, yang mengindikasikan *overfitting* tingkat sedang, tetapi kemampuan generalisasi model tetap baik. Berdasarkan `results/xgboost_predictions.csv`, sekitar 57% rumah uji diprediksi dengan galat relatif tidak lebih dari 10% dan sekitar 83% tidak lebih dari 20%. Kesalahan absolut membesar pada rumah mahal, yaitu MAE sekitar US$38.600 untuk harga di bawah median dan sekitar US$221.600 untuk harga di atas persentil ke-90 (US$895.000).

Sebagai catatan, 177 `id` rumah muncul lebih dari satu kali (dijual ulang) sehingga rumah yang sama dapat berada pada data latih dan uji, dan hasil uji dapat sedikit lebih optimistis. Perbandingan dengan LightGBM disajikan pada subbab 3.4.

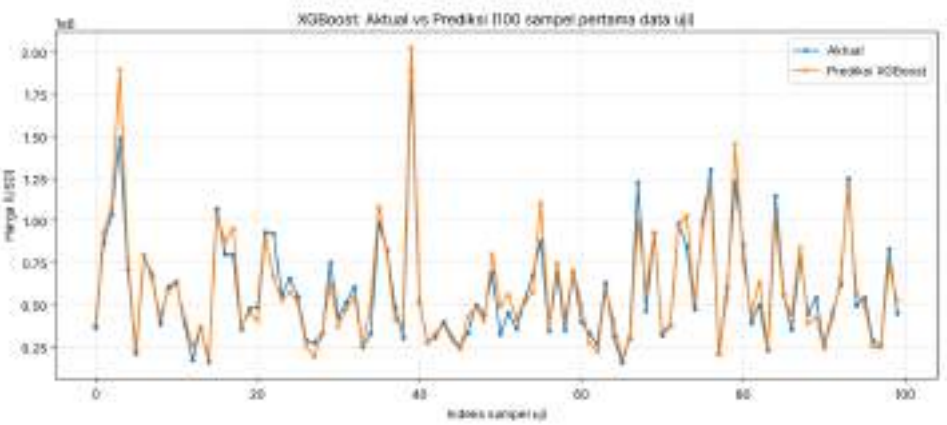
3.2.2 Visualisasi Hasil Prediksi

Empat visualisasi berikut dihasilkan oleh `02_xgboost.py` dan tersimpan di folder `results/`.



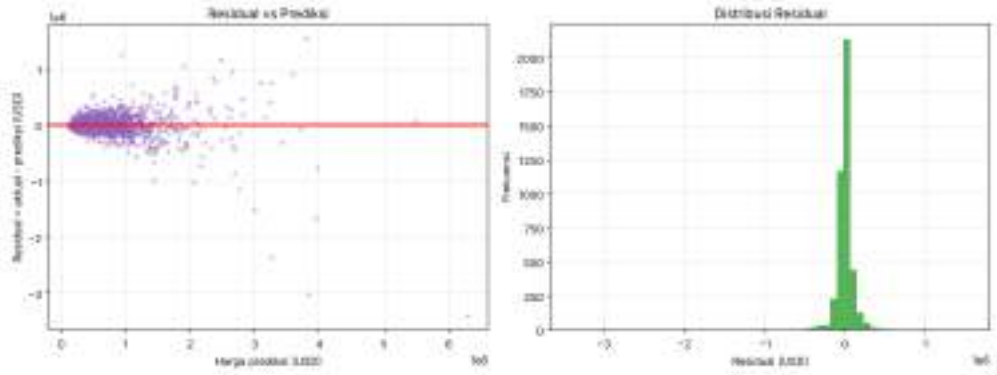
Gambar 3.10 Grafik Sebar Harga Aktual vs Prediksi XGBoost

Pada Gambar 3.10, titik berkumpul rapat di sekitar garis merah (prediksi sempurna) untuk harga di bawah US$1 juta dan menyebar pada harga yang lebih tinggi. Beberapa rumah mahal diprediksi terlalu rendah, dan sebagian kecil lainnya diprediksi terlalu tinggi.



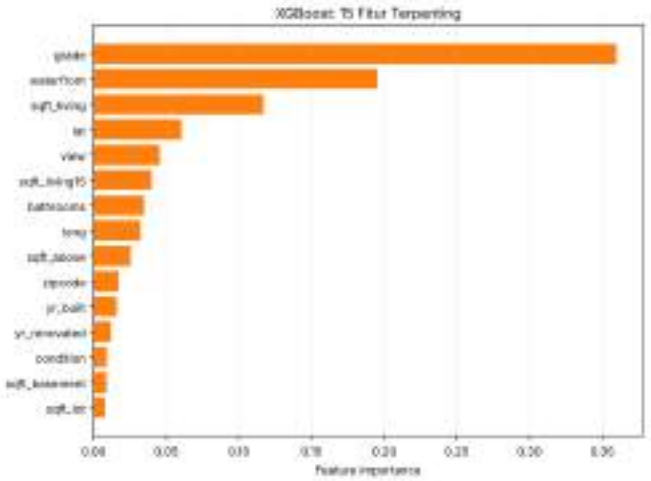
Gambar 3.11 Perbandingan Harga Aktual dan Prediksi pada 100 Sampel Pertama Data Uji

Pada Gambar 3.11, garis aktual dan prediksi bergerak searah dan puncak harga tinggi umumnya ikut terprediksi, meskipun pada beberapa sampel selisihnya terlihat jelas.



Gambar 3.12 Grafik Residual XGBoost (Aktual − Prediksi)

Pada Gambar 3.12, residual rapat di sekitar nol untuk harga prediksi di bawah sekitar US$1,5 juta dan melebar pada harga yang lebih tinggi. Histogram residual berpusat di sekitar nol dengan ekor panjang, sesuai rata-rata selisih yang mendekati nol dan RMSE yang jauh di atas MAE.



Gambar 3.13 Kepentingan Fitur pada Model XGBoost

Pada Gambar 3.13, fitur terpenting adalah `grade` (36,01%), `waterfront` (19,50%), dan `sqft_living` (11,69%), yang bersama-sama menyumbang 67,2%. Fitur `lat` dan `view` melengkapi lima teratas. Fitur `waterfront` hanya dimiliki sekitar 0,75% rumah, tetapi berperan besar membedakan rumah berharga tinggi. Nilai kepentingan menunjukkan seberapa besar fitur dipakai model dan bukan hubungan sebab-akibat.

3.3 Hasil Prediksi LightGBM

Pelatihan dan pengujian model LightGBM dijalankan melalui terminal menggunakan perintah `python 03_lightgbm.py`. Berdasarkan keluaran program, model dilatih menggunakan 17.290 baris data latih dan diuji pada 4.323 baris data uji dengan melibatkan 18 atribut fitur properti. Proses pelatihan 600 pohon keputusan dengan `num_leaves=63` selesai dalam waktu 2,19 detik. Tampilan hasil eksekusi terminal pada file `03_lightgbm.py` ditunjukkan pada Gambar 3.9.

```
PS D:\TI\SEMESTER 5\Machine Learning PRAK\ML_KELOMPOK10\regresi> python 03_lightgbm.py
[INFO] Memuat data hasil preprocessing dari data/processed/ ...
[DATA] Baris mentah: None | outlier dibuang: None | train: 17290 | test: 4323
[DATA] Jumlah fitur: 18 -> ['bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade'
, 'sqft_above', 'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode', 'lat', 'long', 'sqft_living15', 'sqft_lot15']

[TRAINING] Melatih LightGBM Regressor ...
[TRAINING] Selesai dalam 2.19 detik

=== Evaluasi Data LATIH (training) ===
Mean Absolute Error (MAE)           : 33,990.38
Mean Absolute Percentage Error (MAPE): 7.74%
Root Mean Squared Error (RMSE)      : 52,556.50
Mean Squared Error (MSE)            : 2,762,194,886.66
R2 Score                            : 0.9789

=== Evaluasi Data UJI (testing) ===
Mean Absolute Error (MAE)           : 66,603.27
Mean Absolute Percentage Error (MAPE): 12.33%
Root Mean Squared Error (RMSE)      : 140,754.08
Mean Squared Error (MSE)            : 19,811,709,662.57
R2 Score                            : 0.8689

[CONTOH] Rumah uji ke-1 -> aktual: $365,000 | prediksi: $387,507

[SIMPAN] Model    : models/lightgbm_model.pkl
[SIMPAN] Metrik   : results/lightgbm_metrics.json
[SIMPAN] Prediksi : results/lightgbm_predictions.csv
[SIMPAN] Grafik   : results/lightgbm_*.png
```

Gambar 3.14 Hasil Eksekusi Terminal Pelatihan dan Pengujian LightGBM (03_lightgbm.py)

Berdasarkan hasil prediksi terhadap 4.323 sampel rumah pada data uji yang tersimpan dalam file `results/lightgbm_predictions.csv`, rata-rata harga rumah aktual pada data uji adalah USD 549.367,44 (rentang USD 82.500 hingga USD 5.570.000), sedangkan rata-rata harga hasil prediksi model LightGBM adalah USD 551.577,87 (rentang USD 137.292,22 hingga USD 6.095.426,00) dengan nilai median residu sebesar USD -2.049,32. Pada keluaran terminal Gambar 3.9 terlihat bahwa untuk rumah uji pertama (indeks ke-0) yang memiliki harga aktual USD 365.000, model LightGBM memprediksi harga sebesar USD 387.507 (tepatnya USD 387.506,84), sehingga terdapat selisih sebesar USD -22.506,84 atau meleset sekitar 6,17% dari harga sebenarnya. Sepuluh sampel pertama hasil prediksi model LightGBM pada data uji disajikan pada Tabel 3.1.

Tabel 3.1 Sepuluh Sampel Pertama Hasil Prediksi Harga Rumah dengan LightGBM pada Data Uji

Indeks Uji	Harga Aktual (USD)	Harga Prediksi (USD)	Residual / Selisih (USD)	Galat Absolut (%)
0	365.000,00	387.506,84	-22.506,84	6,17%
1	865.000,00	926.066,04	-61.066,04	7,06%
2	1.038.000,00	1.145.074,70	-107.074,70	10,32%
3	1.490.000,00	1.896.282,40	-406.282,40	27,27%
4	711.000,00	752.321,34	-41.321,34	5,81%
5	211.000,00	239.044,78	-28.044,78	13,29%
6	790.000,00	826.228,15	-36.228,15	4,59%
7	680.000,00	629.730,65	50.269,35	7,39%
8	384.500,00	451.051,03	-66.551,03	17,31%
9	605.000,00	576.334,86	28.665,14	4,74%

Data pada Tabel 3.1 menunjukkan bahwa pada properti dengan kisaran harga menengah antara USD 350.000 hingga USD 900.000 (seperti indeks ke-0, ke-1, ke-4, ke-6, ke-7, dan ke-9), model LightGBM mampu menghasilkan estimasi dengan persentase kesalahan absolut di bawah 8%. Adapun pada properti dengan harga di atas USD 1.400.000 seperti pada indeks ke-3, nilai residu absolut menjadi lebih besar karena jumlah transaksi rumah mewah pada dataset jauh lebih sedikit dan memiliki variasi fitur yang lebih ekstrem.

3.3.1 Hasil Evaluasi Model

Evaluasi performa model LightGBM dilakukan menggunakan lima metrik kuantitatif, yaitu MAE, MAPE, RMSE, MSE, dan R^2, baik pada data latih (17.290 baris) maupun pada data uji (4.323 baris). Pengukuran pada kedua bagian data tersebut bertujuan untuk mengetahui tingkat ketepatan prediksi sekaligus mengevaluasi kemampuan generalisasi

model terhadap data baru. Ringkasan hasil evaluasi model LightGBM berdasarkan file `results/lightgbm_metrics.json` disajikan pada Tabel 3.2.

Tabel 3.2 Hasil Evaluasi Model LightGBM pada Data Latih dan Data Uji

Metrik Evaluasi	Data Latih (Training Set)	Data Uji (Testing Set)
Mean Absolute Error (MAE)	33.990,38	66.603,27
Mean Absolute Percentage Error (MAPE)	7,78%	12,11%
Root Mean Squared Error (RMSE)	52.556,58	140.754,08
Mean Squared Error (MSE)	2.762.194.406,66	19.811.709.662,57
R-Squared (R^2)	0,9789	0,8689

Berdasarkan nilai metrik pada Tabel 3.2, hasil evaluasi model LightGBM pada data uji dapat diuraikan sebagai berikut:

1. Mean Absolute Error (MAE): Nilai MAE pada data uji tercatat sebesar USD 66.603,27 (dan USD 33.990,38 pada data latih). Angka ini menunjukkan bahwa rata-rata selisih absolut antara harga rumah hasil prediksi LightGBM dan harga rumah sebenarnya pada data uji adalah sebesar USD 66.603,27 per unit properti.

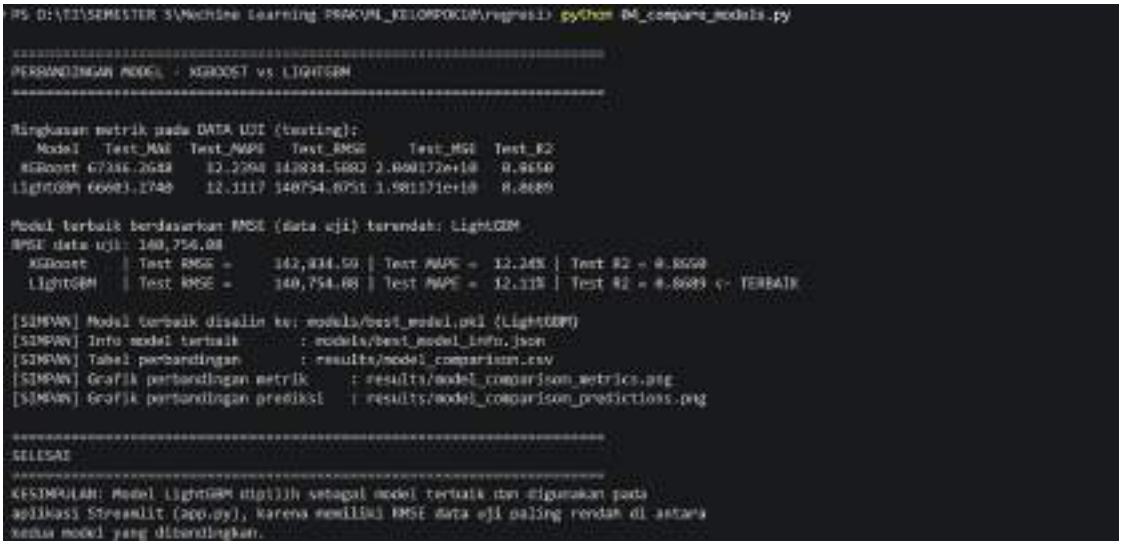
2. Mean Absolute Percentage Error (MAPE): Nilai MAPE sebesar 12,11% pada data uji dan 7,78% pada data latih menandakan bahwa rata-rata persentase penyimpangan prediksi terhadap harga rumah aktual berada pada angka 12,11%. Nilai MAPE di bawah 15% menunjukkan bahwa estimasi harga yang dihasilkan model memiliki tingkat akurasi relatif yang baik.

3. Mean Squared Error (MSE) dan Root Mean Squared Error (RMSE): Model menghasilkan nilai MSE sebesar 19.811.709.662,57 dan nilai RMSE sebesar USD 140.754,08 pada data uji. Nilai RMSE yang lebih tinggi dibandingkan MAE (USD 140.754,08 berbanding USD 66.603,27) terjadi karena adanya penalti kuadratik terhadap sejumlah kecil data *outlier* berupa rumah berharga jutaan dolar yang tidak dihapus pada tahap *preprocessing* (Subbab 2.4.3).

4. R-Squared (R^2): Nilai koefisien determinasi (R^2) mencapai 0,9789 pada data latih dan 0,8689 pada data uji. Hal ini membuktikan bahwa 18 fitur karakteristik properti yang digunakan dalam model LightGBM mampu menjelaskan 86,89% variasi harga rumah pada data uji, sedangkan 13,11% sisanya dipengaruhi oleh faktor lain di luar atribut dataset. Selisih nilai R^2 antara data latih dan data uji (0,1100) menunjukkan bahwa penggunaan parameter regularisasi (`subsample=0.8`, `colsample_bytree=0.8`, `reg_alpha=0.1`, dan

`reg_lambda=1.0`) mampu menjaga model agar tetap memiliki generalisasi yang kuat pada data uji.

Selanjutnya, hasil eksekusi program pembanding `04_compare_models.py` pada Gambar 3.10 mengonfirmasi bahwa model LightGBM mengungguli model XGBoost pada seluruh metrik evaluasi data uji, yakni memiliki RMSE lebih rendah USD 2.080,51 (USD 140.754,08 dibandingkan USD 142.834,59), MAE lebih rendah USD 742,99 (USD 66.603,27 dibandingkan USD 67.346,26), MAPE lebih rendah 0,13% (12,11% dibandingkan 12,24%), dan R^2 lebih tinggi 0,0039 (0,8689 dibandingkan 0,8650). Oleh karena itu, model LightGBM ditetapkan sebagai model terbaik dan disalin ke `models/best_model.pkl`.



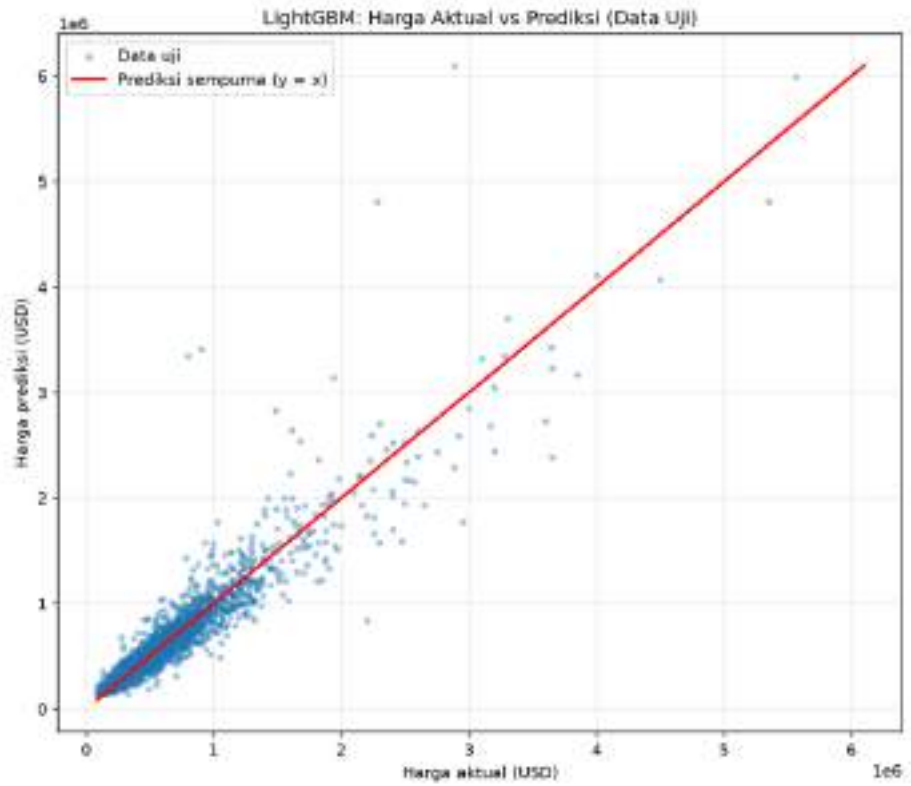
Gambar 3.15 Hasil Eksekusi Terminal Perbandingan Model XGBoost dan LightGBM (04_compare_models.py)

3.3.2 Visualisasi Hasil Prediksi

Evaluasi visual terhadap kinerja model LightGBM dilakukan melalui empat grafik yang dihasilkan oleh `03_lightgbm.py` serta dua grafik perbandingan model yang dihasilkan oleh `04_compare_models.py`.

1. Scatter Plot Harga Aktual vs Prediksi Data Uji

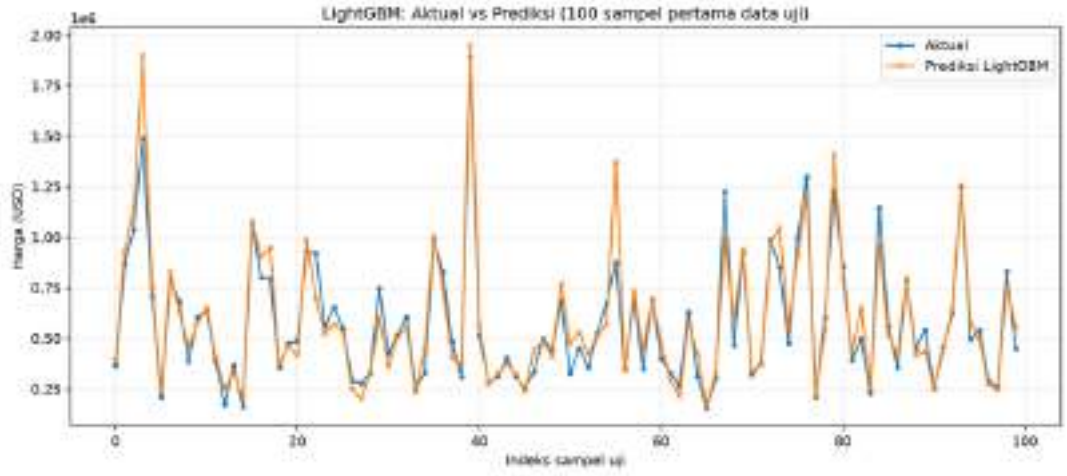
Gambar 3.11 memperlihatkan diagram pencar (*scatter plot*) antara harga rumah aktual pada sumbu horizontal dan harga prediksi LightGBM pada sumbu vertikal untuk 4.323 sampel data uji. Titik-titik biru tampak terkonsentrasi rapat mengikuti garis diagonal merah ($y = x$) pada rentang harga di bawah USD 1.500.000. Pada rentang harga di atas USD 2.000.000, titik-titik data mulai menyebar lebih renggang di sekitar garis referensi. Pola tersebut menunjukkan bahwa model memiliki ketepatan prediksi yang sangat konsisten pada kelompok harga rumah mayoritas, namun mengalami peningkatan varians pada segmen rumah mewah yang jumlah datanya terbatas.



Gambar 3.16 Scatter Plot Harga Aktual vs Harga Prediksi LightGBM pada Data Uji

2. Grafik Garis Aktual vs Prediksi pada 100 Sampel Pertama Data Uji

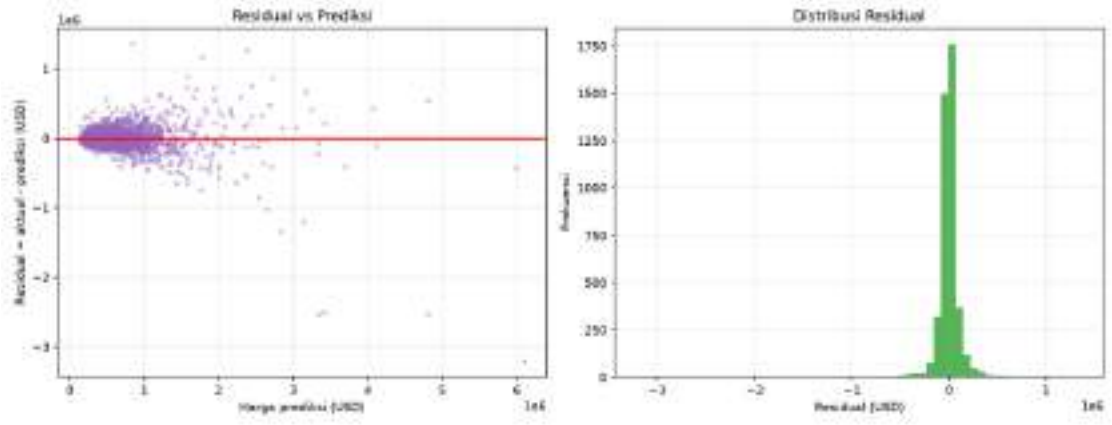
Gambar 3.12 menampilkan perbandingan grafik garis antara harga aktual (garis biru bertanda lingkaran) dan harga prediksi LightGBM (garis oranye bertanda silang) pada 100 sampel pertama data uji. Kurva prediksi LightGBM mampu mengikuti naik-turunnya harga aktual secara presisi, baik pada rumah berharga rendah di kisaran USD 200.000 hingga USD 400.000 maupun pada lonjakan tajam seperti pada indeks ke-39 (sekitar USD 1.900.000) dan indeks ke-93 (sekitar USD 1.250.000). Selisih yang cukup terlihat hanya terjadi pada beberapa titik ekstrem seperti indeks ke-3 dan indeks ke-55, di mana prediksi model berada di atas nilai aktual.



Gambar 3.17 Grafik Garis Harga Aktual vs Prediksi LightGBM pada 100 Sampel Pertama Data Uji

3. Analisis Residual vs Prediksi dan Distribusi Residual

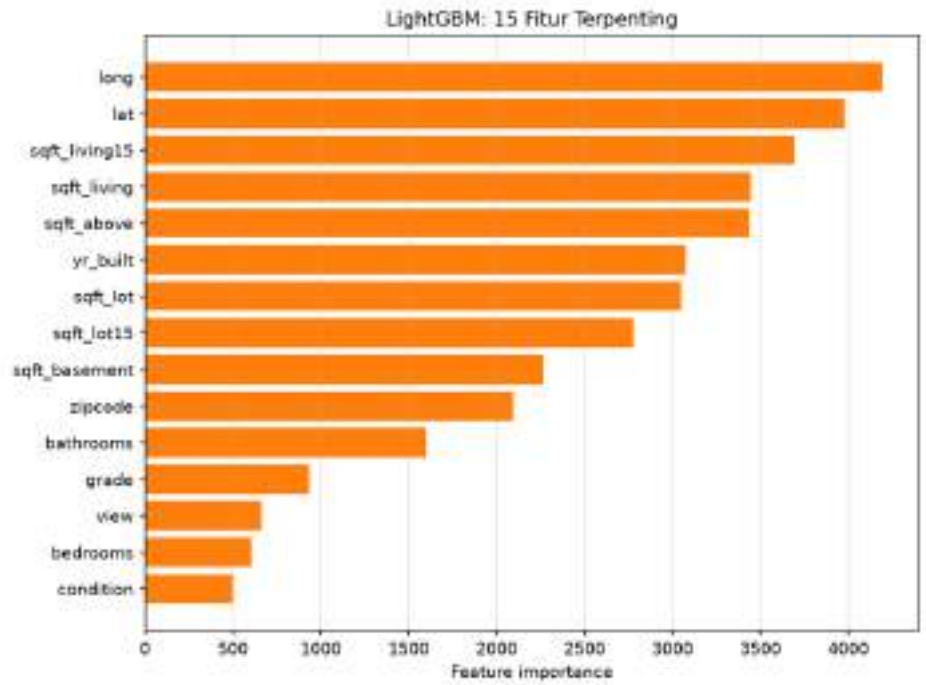
Gambar 3.13 menyajikan dua grafik analisis kesalahan prediksi (*residual = aktual - prediksi*). Pada grafik sebelah kiri (*Residual vs Prediksi*), mayoritas titik residu tersebar secara acak dan seimbang di sekitar garis merah horizontal (*residual = 0*) untuk harga prediksi hingga USD 1.500.000, dengan rata-rata residu keseluruhan hanya sebesar USD -2.210,43. Adapun pada grafik sebelah kanan (*Distribusi Residual*), histogram membentuk distribusi lonceng tunggal yang sangat lancip dan simetris tepat di titik 0 USD, di mana 50% data uji memiliki residu yang berada di antara kuartil pertama USD -39.579,12 hingga kuartil ketiga USD 34.337,54. Hal ini menandakan bahwa kesalahan prediksi model LightGBM tidak memiliki bias sistematis.



Gambar 3.18 Plot Residual vs Prediksi (Kiri) dan Histogram Distribusi Residual LightGBM (Kanan)

4. Tingkat Kepentingan Fitur (Feature Importance LightGBM)

Gambar 3.14 memvisualisasikan 15 fitur terpenting pada model LightGBM berdasarkan frekuensi *split*, yaitu berapa kali suatu atribut digunakan sebagai titik pemisahan cabang di seluruh 600 pohon keputusan. Rincian lengkap jumlah *split* untuk seluruh 18 fitur disajikan pada Tabel 3.3.



Gambar 3.19 Grafik 15 Fitur Terpenting pada Model LightGBM Berdasarkan Frekuensi Split

Tabel 3.3 Urutan Feature Importance (Frekuensi Split) seluruh Fitur pada Model LightGBM

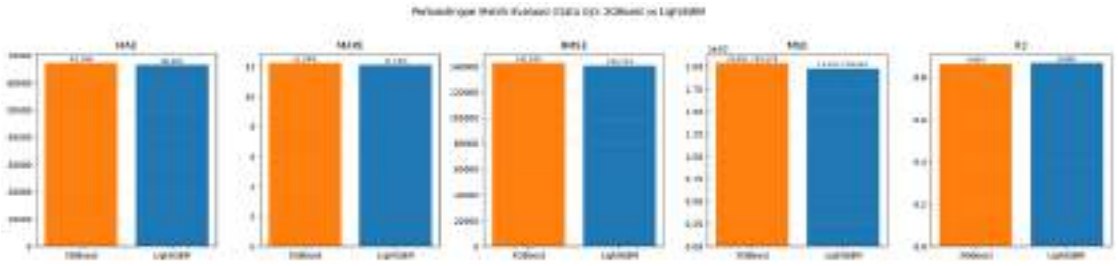
Peringkat	Nama Fitur	Frekuensi Split	Deskripsi Atribut Properti
1	`long`	4.191	Koordinat garis bujur lokasi rumah (Barat-Timur)
2	`lat`	3.977	Koordinat garis lintang lokasi rumah (Utara-Selatan)
3	`sqft_living15`	3.693	Rata-rata luas bangunan dari 15 rumah tetangga terdekat
4	`sqft_living`	3.448	Luas total bangunan tempat tinggal (dalam satuan sqft)
5	`sqft_above`	3.439	Luas bangunan di atas permukaan tanah (sqft)

6	yr_built	3.076	Tahun pertama kali rumah dibangun
7	sqft_lot	3.050	Luas keseluruhan tanah properti (sqft)
8	sqft_lot15	2.778	Rata-rata luas tanah dari 15 rumah tetangga terdekat
9	sqft_basement	2.269	Luas ruangan bawah tanah / basement (sqft)
10	zipcode	2.092	Kode pos lokasi properti di King County
11	bathrooms	1.596	Jumlah kamar mandi
12	grade	933	Skor mutu konstruksi dan desain bangunan (skala 1-13)
13	view	663	Skor kualitas pemandangan dari properti (skala 0-4)
14	bedrooms	603	Jumlah kamar tidur
15	condition	496	Skor kondisi fisik bangunan secara umum (skala 1-5)
16	floors	429	Jumlah tingkat atau lantai bangunan
17	yr_renovated	312	Tahun renovasi bangunan (0 jika belum pernah direnovasi)
18	waterfront	155	Status lokasi rumah di tepi perairan (0 = tidak, 1 = ya)

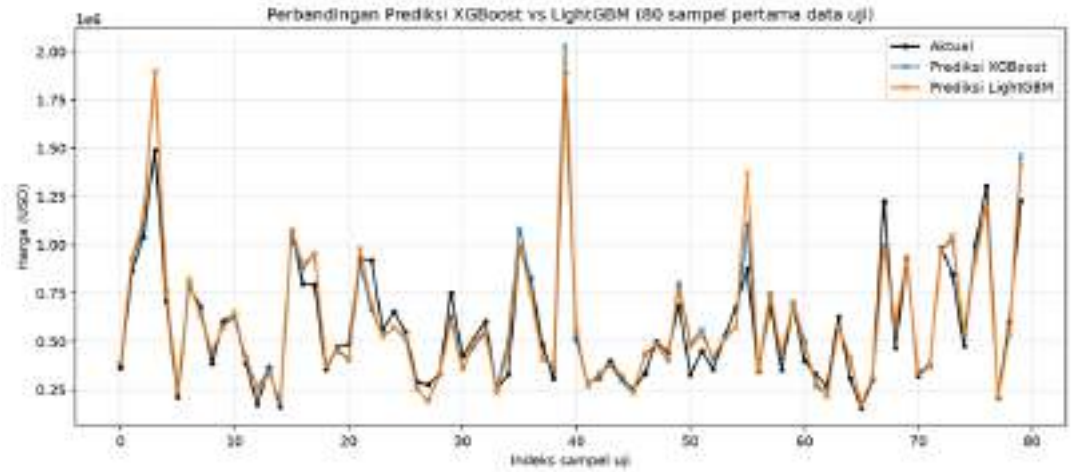
Berdasarkan Gambar 3.14 dan Tabel 3.3, lima fitur yang paling sering digunakan oleh LightGBM untuk membagi simpul keputusan adalah `long` (4.191 *splits*), `lat` (3.977 *splits*), `sqft_living15` (3.693 *splits*), `sqft_living` (3.448 *splits*), dan `sqft_above` (3.439 *splits*). Temuan ini menunjukkan bahwa strategi pertumbuhan *leaf-wise* pada LightGBM sangat aktif mengeksplorasi fitur koordinat spasial (`long` dan `lat`) serta dimensi luas bangunan (`sqft_living15`, `sqft_living`, dan `sqft_above`) untuk membedakan klaster harga rumah antarwilayah di King County secara detail.

5. Visualisasi Perbandingan Metrik dan Prediksi XGBoost vs LightGBM

Sebagai bagian dari tugas komparasi model pada `04_compare_models.py`, dihasilkan pula dua grafik perbandingan langsung antara XGBoost dan LightGBM pada data uji, sebagaimana ditunjukkan pada Gambar 3.15 dan Gambar 3.16.



Gambar 3.20 Grafik Perbandingan Lima Metrik Evaluasi Data Uji antara XGBoost dan LightGBM



Gambar 3.21 Grafik Perbandingan Prediksi XGBoost vs LightGBM pada 80 Sampel Pertama Data Uji

Diagram batang pada Gambar 3.15 memperlihatkan bahwa batang biru (LightGBM) konsisten memiliki nilai kesalahan yang lebih rendah dibandingkan batang oranye (XGBoost) pada metrik MAE (66.603 vs 67.346), MAPE (12,11% vs 12,24%), RMSE (140.754 vs 142.835), dan MSE (19.811.709.663 vs 20.401.719.578), serta mencatat skor R^2 yang lebih tinggi (0,869 vs 0,865). Sementara itu, Gambar 3.16 menunjukkan bahwa garis prediksi kedua model bergerak sangat berdekatan mengikuti garis hitam harga aktual pada 80 sampel pertama data uji, namun LightGBM menghasilkan penyimpangan rata-rata kuadratik yang lebih kecil sehingga dipilih sebagai model utama pada aplikasi Streamlit.

3.4 Perbandingan dan Penentuan Model Terbaik

Pada tahap ini dilakukan perbandingan performa antara dua algoritma machine learning, yaitu XGBoost dan LightGBM, yang digunakan untuk memprediksi harga rumah pada dataset King County House Sales. Perbandingan dilakukan berdasarkan lima metrik evaluasi, yaitu Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE), dan Coefficient of Determination (R^2).

Pengujian dilakukan menggunakan data testing untuk mengetahui kemampuan masing-masing model dalam memprediksi data yang belum pernah digunakan selama proses pelatihan. Hasil perbandingan kedua model ditampilkan pada Tabel 3.1 berikut.

Metrik Evaluasi	XGBoost	LightGBM
MAE	67.346,26	66.603,27
MAPE	12,24%	12,11%
MSE	20.401.719.577,93	19.811.709.662,57
RMSE	142.834,59	140.754,08
R^2	0,8650	0,8689

Tabel 3.1 Hasil Perbandingan Model XGBoost dan LightGBM.

Berdasarkan hasil evaluasi pada Tabel 3.1, LightGBM menunjukkan performa yang lebih baik dibandingkan XGBoost pada seluruh metrik yang digunakan. Hal ini terlihat dari nilai MAE, MAPE, MSE, dan RMSE LightGBM yang lebih rendah dibandingkan XGBoost. Nilai kesalahan prediksi yang lebih rendah menunjukkan bahwa hasil prediksi model LightGBM memiliki selisih yang lebih kecil terhadap harga rumah sebenarnya.

Selain itu, LightGBM memperoleh nilai R^2 sebesar 0,8689, sedangkan XGBoost memperoleh nilai R^2 sebesar 0,8650. Nilai tersebut menunjukkan bahwa LightGBM mampu menjelaskan sekitar 86,89% variasi harga rumah pada data testing, sementara XGBoost mampu menjelaskan sekitar 86,50%.

Dengan mempertimbangkan hasil dari kelima metrik evaluasi tersebut, LightGBM dipilih sebagai model terbaik dalam penelitian ini. Pemilihan tersebut didasarkan pada nilai kesalahan prediksi yang lebih rendah serta nilai R^2 yang lebih tinggi dibandingkan XGBoost.

Model LightGBM selanjutnya digunakan sebagai model utama dalam aplikasi prediksi harga rumah karena memberikan performa yang lebih baik berdasarkan hasil pengujian pada data testing.

3.5 Implementasi UI/UX Model Terbaik

Antarmuka diimplementasikan pada `app.py` menggunakan Streamlit dan dijalankan dengan perintah berikut, lalu dibuka pada `http://localhost:8501`.

```
streamlit run app.py
```

Aplikasi mengikuti alur proyek 01 sampai 04. Model terbaik dibaca dari `models/best_model.pkl` yang dibuat `04_compare_models.py`, sedangkan nilai awal

input dan statistik pendukung dibaca dari hasil `01_preprocessing.py` di `data/processed/`. Komponen utama implementasi dirangkum pada Tabel 3.3.

Berdasarkan perbandingan pada subbab 3.4, model terbaik adalah LightGBM karena memiliki RMSE data uji terendah (US$140.754 dibandingkan US$142.835 pada XGBoost), sehingga aplikasi menampilkan LightGBM sebagai model aktif.

Tabel 3.3 Komponen Implementasi Aplikasi Streamlit

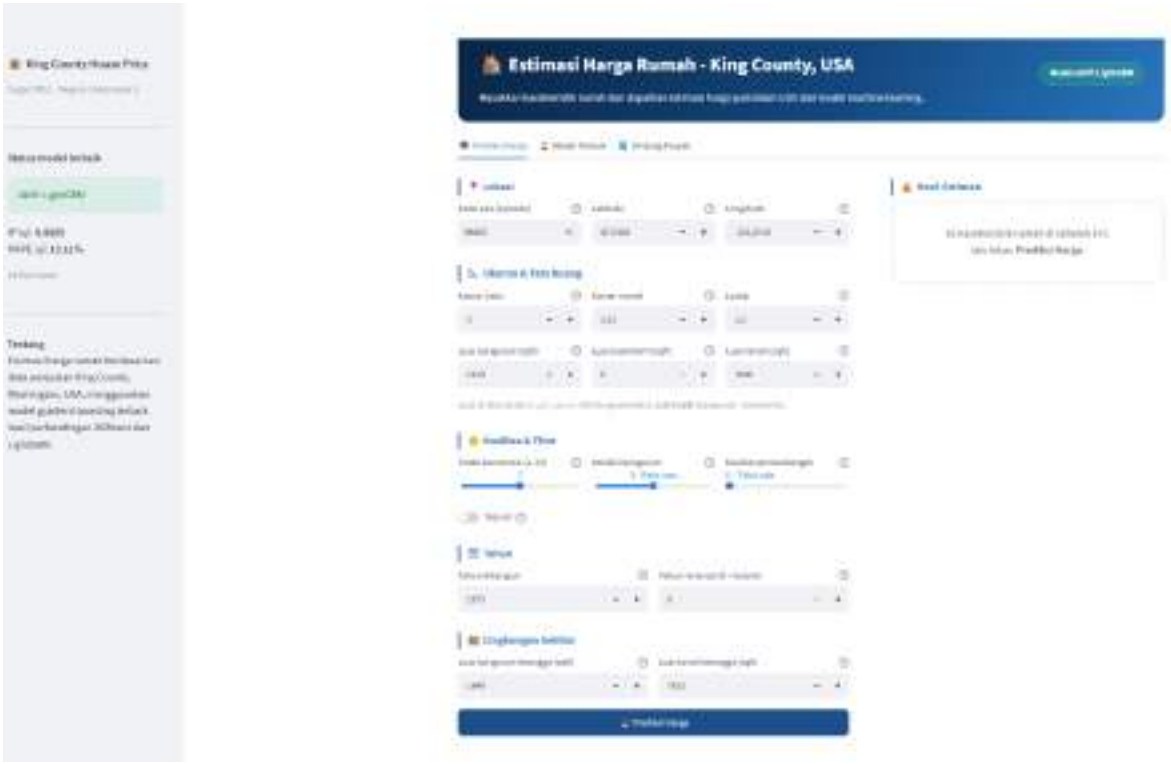
Komponen	Implementasi pada app.py
Pemuatan model	`joblib.load` pada `best_model.pkl` dengan `st.cache_resource`; kegagalan pemuatan ditampilkan sebagai pesan kesalahan.
Fitur dan nilai awal	Nama fitur diambil dari model; nilai awal dari median data latih (`X_train.csv`) dan `preprocessing_metadata.json`.
Formulir input	`st.selectbox`, `st.number_input`, `st.slider`, `st.select_slider`, dan `st.toggle` dalam lima kelompok.
Prediksi dan hasil	Input disusun menjadi `DataFrame`, `model.predict()` dipanggil saat tombol ditekan, lalu harga USD, rentang ± MAPE, harga per sqft, dan posisi harga ditampilkan.
Tab Model Terbaik	Metrik uji dan latih, hiperparameter dari model, tabel perbandingan, serta grafik aktual vs prediksi, residual, dan fitur terpenting.
Kondisi khusus	Tombol dinonaktifkan dan status berkas pipeline ditampilkan bila model belum ada; peringatan untuk input tidak konsisten.

Kode inti dan tampilan aplikasi ditunjukkan pada Gambar di bawah ini:

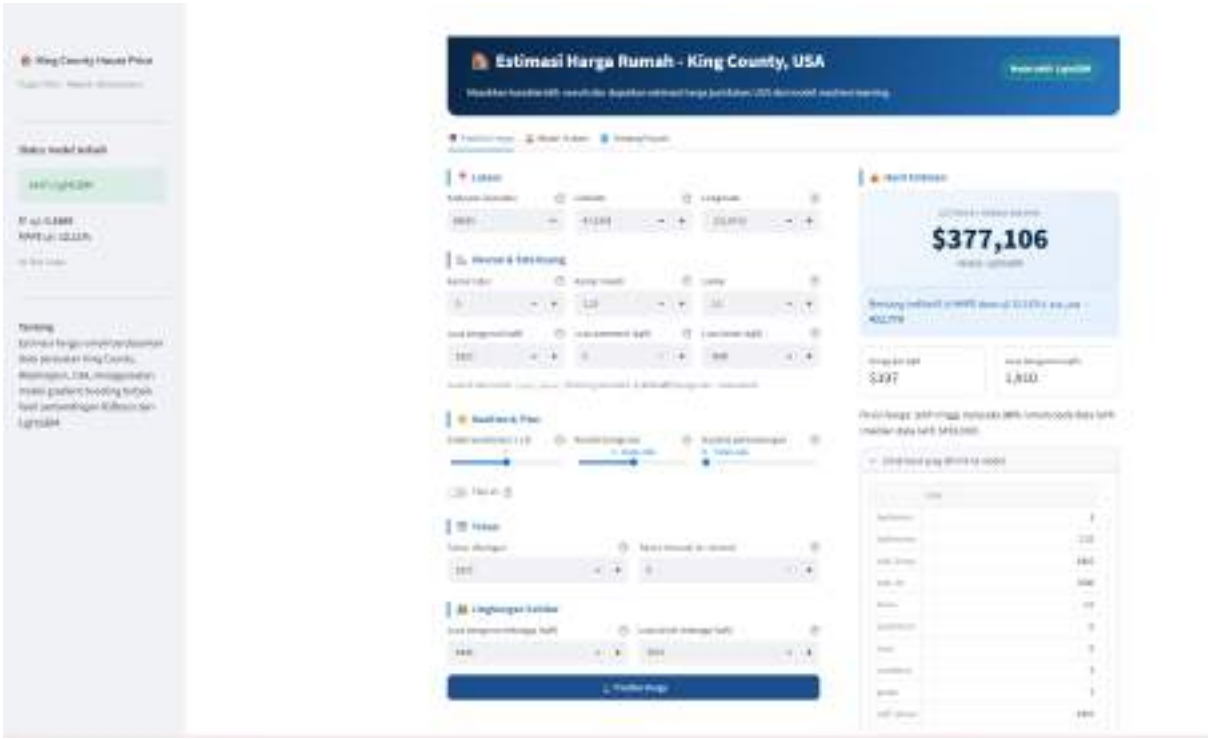
```
def load_best_model():
    """Mengembalikan (model, pesan_error). Keduanya None bila best_model.pkl belum ada."""
    if not BEST_MODEL_PATH.exists():
        return None, None
    try:
        return _load_model(str(BEST_MODEL_PATH), BEST_MODEL_PATH.stat().st_mtime), None
    except Exception as exc:  # file rusak, atau xgboost/lightgbm belum terpasang
        return None, f"{type(exc).__name__}: {exc}"
```

```
        try:
            row = {n: values.get(n, default_of(n)) for n in feature_columns}
            X_input = pd.DataFrame([row], columns=feature_columns)
            price = predict_price(model, X_input, info["target_transform"])
            st.session_state["result"] = {"price": price, "inputs": row, "model": info["name"]}
        except Exception as exc:
            st.session_state.pop("result", None)
```

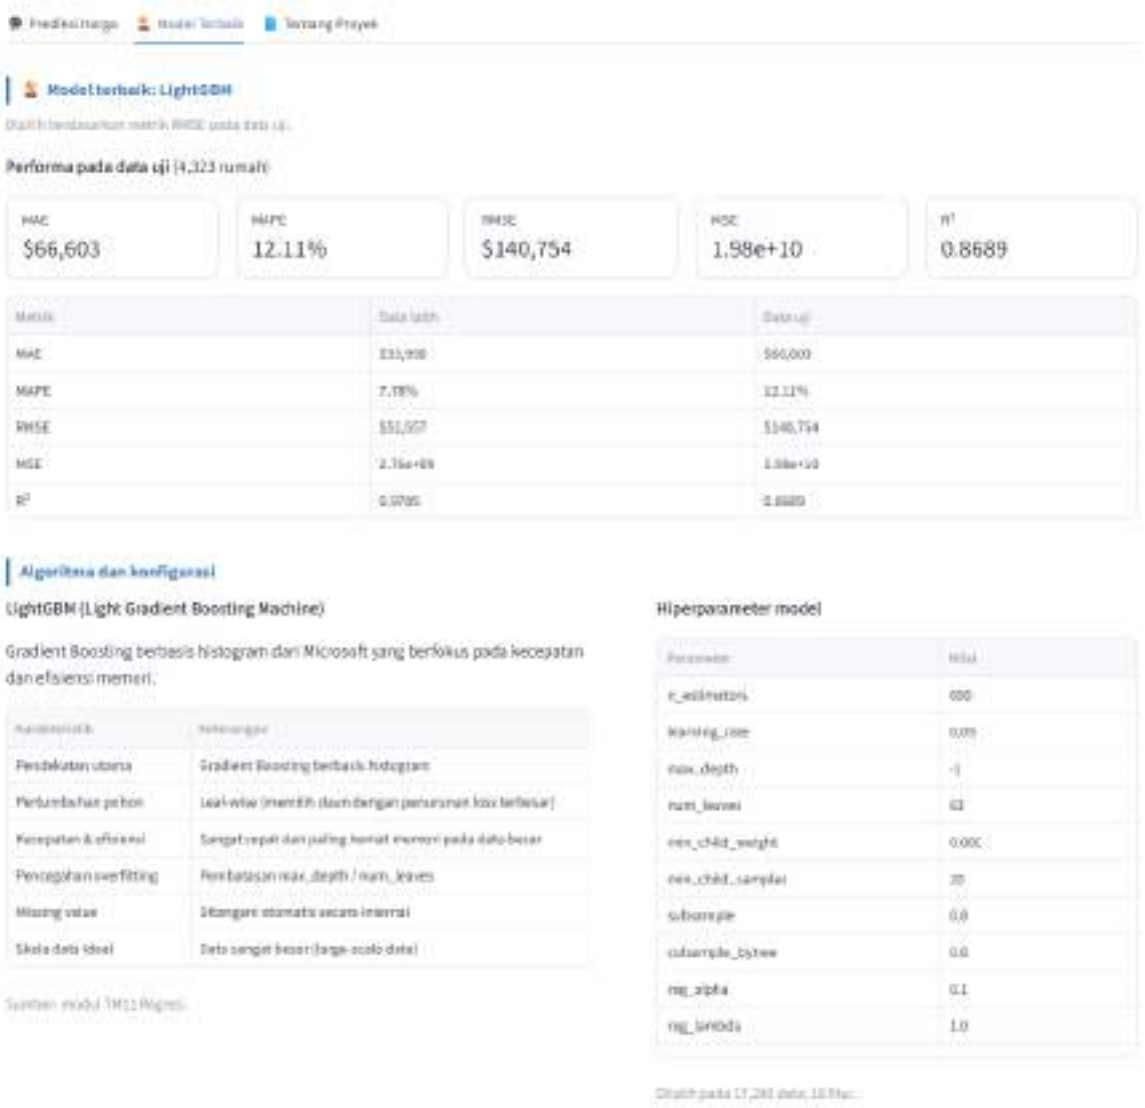
Gambar 3.22 Kode Pemuatan Model Terbaik dan Proses Prediksi pada app.py



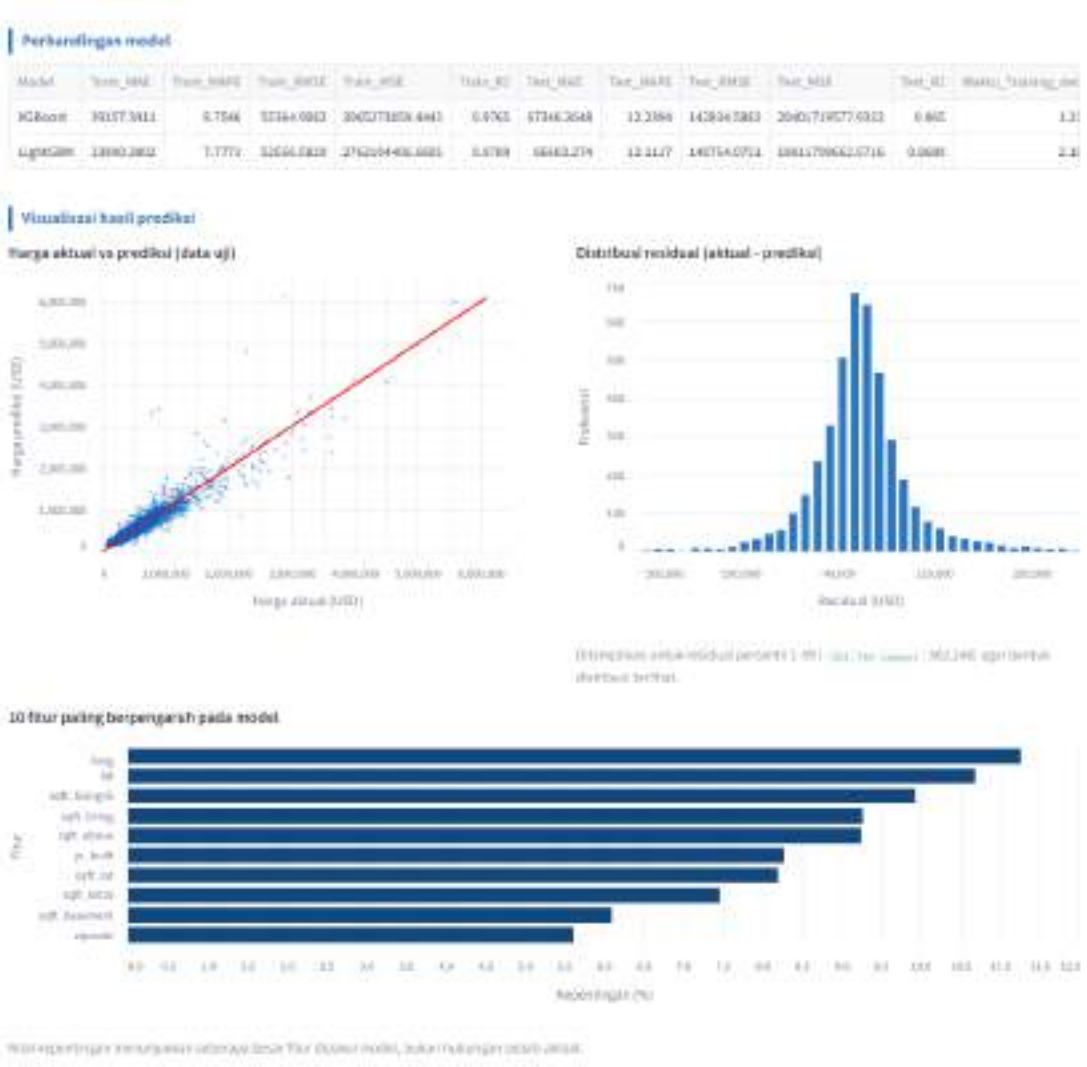
Gambar 3.23 Formulir Input Karakteristik Rumah



Gambar 3.24 Tampilan Hasil Estimasi Harga Rumah



Gambar 3.25 Tampilan Tab Model Terbaik: Metrik dan Algoritma



Gambar 3.26 Tampilan Tab Model Terbaik: Perbandingan dan Grafik

Pengujian

Pengujian dilakukan secara fungsional (*black-box*) menggunakan pengujian otomatis Streamlit (`AppTest`) pada `app.py`, dengan membandingkan perilaku aplikasi terhadap hasil yang diharapkan (Tabel 3.4).

Tabel 3.4 Skenario dan Hasil Pengujian Aplikasi

No.	Skenario uji	Hasil yang diharapkan	Hasil pengujian
1	Membuka aplikasi tanpa `best_model.pkl`	Aplikasi terbuka, peringatan tampil, tombol prediksi nonaktif	Sesuai. Tidak ada kesalahan, peringatan tampil di halaman dan sidebar, tombol nonaktif, dan tab Model Terbaik menampilkan status berkas pipeline.
2	Klik Prediksi Harga dengan input bawaan	Harga USD dan informasi pendukung tampil	Sesuai. Harga US$377.106 (rentang ± 12,11%: US$331.432 sampai US$422.779), harga per sqft US$197, identik dengan `model.predict()` pada skrip terpisah.

No.	Skenario uji	Hasil yang diharapkan	Hasil pengujian
3	Mengganti kode pos	Latitude dan longitude ikut berubah	Sesuai. Kode pos 98065 memberi latitude 47,5338, dan kode pos 98001 memberi latitude 47,3152.
4	Tahun renovasi lebih awal dari tahun dibangun; basement lebih besar dari luas bangunan	Peringatan validasi tampil	Sesuai. Peringatan tampil untuk renovasi 1950 dengan tahun dibangun 1975, dan untuk basement 2.500 sqft dengan bangunan 2.000 sqft.
5	Variasi ukuran dan grade rumah	Harga berubah searah karakteristik rumah	Sesuai. 1.000 sqft grade 6: US$298.512; 1.910 sqft grade 7: US$377.106; 3.500 sqft grade 10: US$678.821; 5.000 sqft grade 12: US$1.072.773.
6	Kompatibilitas model dan fitur	Fitur diambil dari model, tanpa kesalahan ketidaksesuaian fitur	Sesuai. `best_model.pkl` (LightGBM, hasil `04_compare_models.py`) termuat dan memprediksi dengan 18 fitur tanpa perubahan kode. Model XGBoost juga diuji dan berjalan.
7	Membuka tab Model Terbaik	Metrik, hiperparameter, dan grafik tampil	Sesuai. Metrik uji model terbaik LightGBM (R^2 0,8689, MAPE 12,11%) dan grafik tampil dari `best_model_info.json` dan `lightgbm_predictions.csv`.

Pembahasan

Seluruh skenario yang diuji berjalan sesuai harapan. Aplikasi tetap dapat dibuka tanpa model terbaik dan mencegah prediksi dengan menonaktifkan tombol, sedangkan setelah model tersedia harga yang ditampilkan konsisten dengan keluaran `model.predict()`. Peringatan validasi membantu pengguna menghindari input yang tidak masuk akal, dan perubahan harga mengikuti ukuran dan kualitas rumah. Keterbatasannya, estimasi bersifat indikatif karena dilatih dari data penjualan 2014 sampai 2015, dan input di luar rentang data latih kurang andal karena model berbasis pohon tidak mengekstrapolasi dengan baik. Rentang ± MAPE hanya perkiraan kasar dan bukan interval kepercayaan statistik.

3.6 Kesimpulan dan Saran

A. Kesimpulan

Berdasarkan tahapan data preparation yang telah dilakukan pada dataset House Sales, dapat disimpulkan bahwa proses persiapan data berhasil dilakukan sebelum dataset digunakan dalam pemodelan regresi. Tahapan yang dilakukan meliputi pemeriksaan struktur dataset, identifikasi missing value, pemeriksaan data duplikat, analisis outlier menggunakan metode Interquartile Range (IQR), seleksi fitur dan target, pembagian data, serta penanganan missing value.

Dataset awal terdiri dari 21.613 baris dan 22 kolom. Hasil pemeriksaan menemukan 23 missing value, yaitu 13 pada kolom bedrooms dan 10 pada kolom bathrooms, serta tidak ditemukan data duplikat. Analisis outlier dilakukan untuk mengidentifikasi nilai yang berada di luar batas IQR. Outlier yang ditemukan dicatat tanpa dihapus secara otomatis.

Pada tahap seleksi fitur, kolom yang tidak digunakan, yaitu Unnamed: 0, id, dan date, dihapus sehingga diperoleh 18 fitur dengan price sebagai variabel target. Selanjutnya, dataset

dibagi menjadi 80% data training sebanyak 17.290 baris dan 20% data testing sebanyak 4.323 baris.

Penanganan missing value dilakukan menggunakan metode imputasi median dengan SimpleImputer. Setelah proses preprocessing dan validasi selesai, data training dan testing tidak lagi memiliki missing value serta berhasil disimpan dalam folder data/processed/. Dengan demikian, dataset telah dipersiapkan untuk digunakan dalam proses pembangunan model regresi.

B. Saran

Berdasarkan proses data preparation yang telah dilakukan, terdapat beberapa saran untuk pengembangan penelitian selanjutnya:

1. Pemeriksaan kualitas data sebaiknya dilakukan secara menyeluruh agar data yang digunakan dalam pemodelan memiliki kualitas yang baik.
2. Analisis outlier dapat dikembangkan dengan membandingkan beberapa metode penanganan untuk mengetahui pengaruhnya terhadap hasil prediksi model.
3. Proses preprocessing perlu dilakukan secara konsisten pada data training dan testing untuk menghindari data leakage.
4. Penelitian selanjutnya dapat menggunakan metode regresi lain sebagai pembanding untuk memperoleh hasil prediksi harga rumah yang lebih optimal.
5. Evaluasi model sebaiknya dilakukan menggunakan beberapa metrik, seperti MAE, MAPE, MSE, RMSE, dan R^2, agar performa model dapat dianalisis secara lebih menyeluruh.